Análisis convexo y aplicaciones

Franz Chouly

En Construcción (8 de abril de 2026)

Tabla de contenido

Tabla de contenido **3**

1. Introducción **7**

2. Conjuntos convexos **9**
2.1. Definición y propiedades 10
2.1.1. Para empezar 10
2.1.2. Interior y clausura de un conjunto convexo 11
2.2. Envoltura convexa 12
2.2.1. Caracterización 12
2.2.2. Técnicas para calcular la envoltura convexa . . . 13
2.2.3. Algoritmo de Graham Scan 14
2.2.4. Algoritmo QuickHull 17
2.2.5. Aplicaciones 19
2.3. Para profundizar 19

3. Funciones convexas **21**
3.1. Caso general 21
3.1.1. Definición, ejemplos y propiedades 21
3.1.2. Propiedades de continuidad 25
3.1.3. Subdiferencial de funciones convexas 27
3.1.4. Caracterización de mínimos 29
3.2. Casos continuo y diferenciable 31

4. Métodos de minimización **33**
4.1. Gradiente descendente 33
4.2. Método de Newton 34
4.3. Método de punto fijo 34
4.4. Método de penalización 35
4.5. Método de Lagrange 35
4.6. Métodos cuasi-Newton (BFGS) 36

5. Medida y análisis funcional **37**
5.1. Medida 37
5.2. Medida y funciones 38
5.2.1. Funciones BV 38
5.2.2. Continuidad absoluta 38
5.2.3. Teorema de aproximación de Lebesgue 39
5.2.4. Teorema de Lebesgue 39
5.2.5. Teorema de Rademacher 40
5.2.6. Resumen de Relaciones entre Propiedades 40
5.3. Hahn–Banach 41
5.4. Espacios de Hilbert 41
5.5. Espacios de Lebesgue 41
5.6. Derivada débil 42
5.7. Espacios de Sobolev 42
5.8. Ejemplos 42
5.8.1. Generales 42
5.8.2. Indicador 43
5.9. Más espacios funcionales 44
5.9.1. Espacios de Sobolev $H^s(\mathbb{R})$ 44
5.9.2. Espacios de Besov $\mathcal{B}^s_{p,q}(\mathbb{R})$ 45
5.9.3. Exponente de Hölder 45
5.10. Fractales 45
5.10.1. Función de Weierstrass 45
5.10.2. Función de Takagi 46
5.10.3. Movimiento browniano fraccionario 46
5.10.4. Conjunto de Cantor 47
5.10.5. Función de Cantor-Lebesgue 47
5.11. Ecuaciones elípticas 47

6. Dimensión infinita **49**

7. Desigualdades variacionales **51**
7.1. El obstáculo 51
7.1.1. Formulación fuerte 51
7.1.2. Desigualdad variacional 51
7.1.3. Existencia y unicidad 52
7.1.4. Aproximación de Galerkin 52

7.1.5. Penalización 52
7.1.6. Newton semi-suave 52
7.1.7. Implementación en scikit-fem 53
7.1.8. Comentarios adicionales 54

8. Control óptimo 57

9. Conclusión y perspectivas 59
9.1. Optimización matemática 59
9.2. Control y sistemas dinámicos 59
9.3. Aprendizaje Automático 60
9.4. Economía y finanzas 60
9.5. Teoría de juegos 60
9.6. Geometría y computación 60
9.7. Procesamiento de señales e imágenes 61
9.8. Teoría de la Información 61

Referencias bibliográficas 63

Capítulo 1
Introducción

El **análisis convexo** es una rama fundamental de las matemáticas que estudia funciones y conjuntos convexos, ofreciendo herramientas teóricas y prácticas para resolver problemas complejos en ciencia, ingeniería y economía. Este libro aborda desde los fundamentos matemáticos del análisis convexo hasta sus aplicaciones más avanzadas, incluyendo optimización convexa, aprendizaje automático, geometría algorítmica y teoría de juegos.

Se presentan las definiciones y propiedades esenciales de conjuntos y funciones convexas, junto con conceptos clave como el subgradiente, la cáscara convexa y la dualidad. Estos fundamentos son la base para entender algoritmos de optimización y técnicas numéricas que se desarrollan en los capítulos posteriores. Se incluyen ejemplos ilustrativos, fórmulas matemáticas precisas y fragmentos de código en Python para facilitar la implementación de los métodos descritos.

El libro está diseñado para estudiantes de grado y posgrado. A lo largo del texto, se enfatiza la relación entre el análisis convexo y otras áreas de las matemáticas, como el análisis funcional, la teoría de la medida y la geometría computacional, mostrando cómo estas disciplinas se complementan para abordar desafíos modernos.

El enfoque pedagógico del libro facilita la comprensión de conceptos abstractos mediante ejemplos paso a paso, ejercicios propuestos y aplicaciones en contextos reales. Al final de cada capítulo, se proporcionan referencias bibliográficas clave para profundizar en los temas tratados, así como enlaces a recursos adicionales en línea, como repositorios de código y conjuntos de datos.

Capítulo 2

Conjuntos convexos

Los conjuntos convexos son fundamentales en geometría computacional, optimización y aprendizaje automático. Su estudio permite resolver problemas complejos mediante estructuras bien definidas y propiedades robustas. La importancia de estos conjuntos radica en su capacidad para modelar fenómenos reales de manera eficiente, desde la planificación de rutas hasta la clasificación de datos. Además, su definición intuitiva —un conjunto donde el segmento entre dos puntos cualesquiera siempre está contenido— facilita su aplicación en algoritmos y teoremas. En la práctica, los conjuntos convexos aparecen en problemas de minimización, donde garantizan la existencia de soluciones óptimas. Su utilidad se extiende también a la robótica, el procesamiento de imágenes y la inteligencia artificial, donde sirven como herramientas clave para el análisis y la toma de decisiones.

La cáscara convexa, (*convex hull*), es una de las aplicaciones más relevantes de estos conjuntos. Se trata del conjunto convexo más pequeño que contiene a un grupo dado de puntos, actuando como un envoltorio geométrico que preserva la estructura esencial del conjunto original. Este concepto es crucial en geometría computacional, donde permite resolver problemas como la detección de colisiones o la reconstrucción de superficies en tres dimensiones. En el aprendizaje automático, la cáscara convexa se utiliza para definir regiones de decisión en algoritmos de clasificación, como las máquinas de vectores de soporte. Su cálculo eficiente es posible gracias a algoritmos como el de Graham o QuickHull, que optimizan el proceso reduciendo la complejidad computacional. Además, su visualización intuitiva ayuda a comprender mejor la distribución de datos en espacios multidimensionales. Este capítulo explora tanto la teoría como las aplicaciones prácticas de los conjuntos convexos y la cáscara convexa. A través de ejemplos concretos y algoritmos, se busca proporcionar al lector una buena comprensión de estos conceptos.

2.1. Definición y propiedades

Los conjuntos convexos son uno de los conceptos más versátiles y poderosos en matemáticas, con aplicaciones que abarcan desde la optimización hasta el aprendizaje automático. Un conjunto es convexo si, intuitivamente, no presenta huecos ni entrantes: cualquier segmento de recta que una dos puntos del conjunto permanece completamente dentro de él. Esta propiedad, aparentemente simple, tiene implicaciones profundas en teoría y práctica, permitiendo resolver problemas de minimización, clasificación y modelado con garantías de eficiencia y robustez.

2.1.1. Para empezar

Definición 1 (Conjunto convexo)**.** *Un conjunto $C \subseteq \mathbb{R}^n$ es **convexo** si, para todo $x, y \in C$ y todo $\lambda \in [0,1]$, se cumple que:*

$$\lambda x + (1-\lambda)y \in C.$$

En otras palabras, el conjunto contiene todos los puntos del segmento de recta que une x e y.

Ejemplo 1. ***Ejemplos clásicos de conjuntos convexos:***

- *Un **segmento de recta** en $\mathbb{R}^n$: $[a,b] = \{\lambda a + (1-\lambda)b \mid \lambda \in [0,1]\}$.*
- *Un **disco** (o bola cerrada) en $\mathbb{R}^2$: $\{(x,y) \mid x^2 + y^2 \leq r^2\}$.*
- *Un **hiperplano** en $\mathbb{R}^n$: $\{x \mid a^T x = b\}$, donde $a \in \mathbb{R}^n$ y $b \in \mathbb{R}$.*
- *El **espacio vectorial** $\mathbb{R}^n$ en sí mismo.*

Teorema 1 (Intersección de conjuntos convexos)**.** *Sea $\{C_i\}_{i \in I}$ una familia de conjuntos convexos en $\mathbb{R}^n$. Entonces, su intersección $\bigcap_{i \in I} C_i$ también es un conjunto convexo.*

Demostración. Sea $x, y \in \bigcap_{i \in I} C_i$ y $\lambda \in [0,1]$. Por definición de intersección, $x, y \in C_i$ para todo $i \in I$. Como cada C_i es convexo,

$$\lambda x + (1-\lambda)y \in C_i$$

para todo $i \in I$. Por lo tanto, $\lambda x + (1-\lambda)y \in \bigcap_{i \in I} C_i$, lo que prueba que la intersección es convexa. $\square$

Definición 2 (Combinación convexa)**.** *Una* ***combinación convexa*** *de puntos* $x_1, x_2, \ldots, x_k \in \mathbb{R}^n$ *es una expresión de la forma:*

$$\sum_{i=1}^{k} \lambda_i x_i, \quad \textit{donde} \quad \lambda_i \geq 0 \quad \textit{y} \quad \sum_{i=1}^{k} \lambda_i = 1.$$

2.1.2. Interior y clausura de un conjunto convexo

Ahora exploramos propiedades esenciales de los conjuntos convexos: primero, su comportamiento respecto al interior y la clausura.

Proposición 1. *Sea* $C \subseteq \mathbb{R}^n$ *un conjunto convexo. Entonces, su interior* $\mathring{C}$ *y su clausura* $\overline{C}$ *son también conjuntos convexos.*

Demostración. Veamos ambos casos.

Sean $C \subseteq \mathbb{R}^n$ un conjunto convexo y $\mathring{C}$ su interior. Queremos demostrar que $\mathring{C}$ es convexo, es decir, que para todo $x, y \in \mathring{C}$ y todo $\lambda \in [0, 1]$, el punto $z = \lambda x + (1 - \lambda)y$ pertenece a $\mathring{C}$.

1. **Premisas:** Sean $x, y \in \mathring{C}$. Por definición de punto interior, existen bolas abiertas $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, donde $r_x, r_y > 0$. Sea $\lambda \in [0, 1]$. Definimos $z = \lambda x + (1 - \lambda)y$.

2. **Construcción de la bola centrada en z:** Sea $r = \text{mín}(r_x, r_y) > 0$. Consideremos la bola abierta $B(z, r)$. Para todo $w \in B(z, r)$, escribimos $w = z + v$, donde $\|v\| < r$.

3. **Expresión de w como combinación convexa:** Observamos que:

$$w = z + v = \lambda x + (1 - \lambda)y + v.$$

   Podemos descomponer v como:

$$v = \lambda v + (1 - \lambda)v,$$

   donde $\|v\| < r \leq r_x$ y $\|v\| < r \leq r_y$. Esto es posible porque $r = \text{mín}(r_x, r_y)$.

4. **Verificación de que $w \in C$:** Como $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, entonces:

$$x + v \in B(x, r_x) \subseteq C \quad \text{y} \quad y + v \in B(y, r_y) \subseteq C.$$

Por convexidad de C, la combinación convexa:

$$\lambda(x + v) + (1 - \lambda)(y + v) = z + v = w$$

también está en C.

Dado que para todo $w \in B(z, r)$ se tiene $w \in C$, entonces $B(z, r) \subseteq C$. Esto implica que $z \in \mathring{C}$. Como z es un punto arbitrario en el segmento $[x, y]$, se concluye que $[x, y] \subseteq \mathring{C}$.

Por lo tanto, $\mathring{C}$ es un conjunto convexo.

Caso de la clausura $\overline{C}$: Sean $x, y \in \overline{C}$ y $\lambda \in [0, 1]$. Existen sucesiones $\{x_k\}$ e $\{y_k\}$ en C tales que $x_k \to x$ e $y_k \to y$. Definimos $z_k = \lambda x_k + (1 - \lambda) y_k$. Como C es convexo, $z_k \in C$ para todo k. Además, $z_k \to \lambda x + (1 - \lambda) y = z$, por lo que $z \in \overline{C}$. □

2.2. Envoltura convexa

La **envoltura convexa** de un conjunto $S \subseteq \mathbb{R}^n$ es un concepto fundamental en análisis convexo y optimización. Permite caracterizar los conjuntos convexos minimales que contienen a S, y entender sus propiedades geométricas y analíticas.

2.2.1. Caracterización

Una definición posible de la envoltura (o cáscara) convexa es la siguiente.

Definición 3 (Caracterización de la envoltura convexa)**.** *Sea $S \subseteq \mathbb{R}^n$. Entonces,*

$$\operatorname{conv}(S) = \left\{ \sum_{i=1}^{k} \lambda_i x_i \;\middle|\; x_i \in S, \lambda_i \geq 0, \sum_{i=1}^{k} \lambda_i = 1, k \in \mathbb{N} \right\},$$

es un conjunto convexo que contiene a S, y es el más pequeño en el sentido de la inclusión.

El teorema siguiente ilustra que existen dos caracterizaciones equivalentes de $\mathrm{conv}(S)$: una por combinación convexa, y otra por intersección de conjuntos convexos que contienen a S (véase [1], [6], [10] por la demonstración).

Teorema 2 (Equivalencia por intersección)**.** *Además, la envoltura convexa de S satisface la siguiente caracterización:*

$$\mathrm{conv}(S) = \bigcap \{C \subseteq \mathbb{R}^n \mid \mathrm{conv}(C) = C \ y \ S \subseteq C\}.$$

El resultado siguiente, conocido como la *propiedad de los vértices*, también es un teorema (véase [5]).

Teorema 3 (Propiedad de los vértices en dimensión 2)**.** *En dimensión 2, si S es un conjunto finito de puntos en $\mathbb{R}^2$, entonces* $\mathrm{conv}(S)$ *es un polígono convexo cuyos vértices son un subconjunto de S.*

La figura 2.1 ilustra la envoltura convexa de un conjunto de puntos en $\mathbb{R}^2$. En ella, los vértices del pentágono convexo están marcados con cuadrados negros, los puntos interiores con rombos rojos, y los puntos originales del conjunto S con círculos negros.

2.2.2. Técnicas para calcular la envoltura convexa

A lo largo de los años, se han desarrollado numerosos métodos para calcular la envoltura convexa de un conjunto de puntos en el plano o en espacios de mayor dimensión. Las técnicas más antiguas, como el **método de fuerza bruta**, consisten en comparar todos los subconjuntos posibles de puntos, lo que resulta en una complejidad computacional extremadamente alta, del orden de $O(n^4)$ en dos dimensiones. Una mejora significativa llegó con el algoritmo de **envuelto de regalo (Jarvis March, 1973)** que construye la envoltura convexa recorriendo los puntos en orden angular, alcanzando una complejidad de $O(nh)$, donde n es el número total de puntos y h el número de puntos en la envoltura. Con el avance de la computación y la necesidad de mayor eficiencia, surgieron

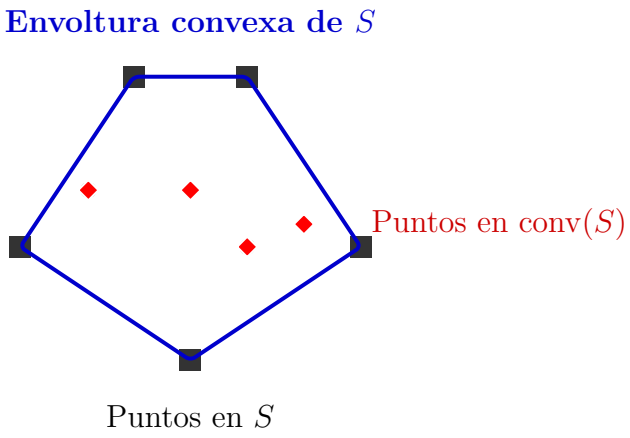

Figura 2.1: Visualización de la envoltura convexa de un conjunto de puntos en $\mathbb{R}^2$.

algoritmos más sofisticados, como el **scan de Graham (1972)**, que ordena los puntos por ángulo polar y construye la envoltura en $O(n \log n)$, y el **QuickHull**, que emplea una estrategia de "divide y vencerásçon una complejidad promedio similar. Entre las técnicas modernas destacan algoritmos híbridos como el de **Chan** que combina ideas de Graham y QuickHull para lograr una complejidad de $O(n \log h)$, o el **Andrew's monotone chain** una variante optimizada del scan de Graham para conjuntos de puntos ordenados. Además, en contextos específicos o dimensiones superiores, se recurre a métodos basados en programación lineal o técnicas estocásticas.

2.2.3. Algoritmo de Graham Scan

El **algoritmo de Graham Scan** es un método eficiente para calcular la **envoltura convexa** de un conjunto finito de puntos en el plano. Su complejidad es de $O(n \log n)$, donde n es el número de puntos en el conjunto S.

Idea general

El objetivo es encontrar el polígono convexo más pequeño que contiene todos los puntos de $S \subseteq \mathbb{R}^2$. La idea central es:

- **Ordenar los puntos** por su ángulo polar respecto a un **punto base** (generalmente el de menor coordenada y).
- **Construir la envoltura** recorriendo los puntos ordenados y eliminando aquellos que no contribuyen a la convexidad.

Etapas del algoritmo

1. **Selección del punto base p_0:**
   - Elegir el punto con la **coordenada y mínima** (y x mínima en caso de empate).
   - Este punto **siempre pertenece** a la envoltura convexa.
2. **Ordenamiento por ángulo polar:**
   - Calcular el ángulo que forma cada punto p_i con el punto base p_0 usando la función `atan2`.
   - Ordenar los puntos en **orden creciente de ángulo polar** respecto a p_0.
   - Si dos puntos tienen el mismo ángulo, conservar el más lejano.
3. **Construcción de la envoltura con una pila:**
   - Inicializar una pila con los primeros tres puntos ordenados (p_0, p_1, p_2).
   - Para cada punto p_i (desde p_3 hasta p_{n-1}):
     a) Mientras el ángulo formado por los últimos tres puntos en la pila sea **mayor a 180°** (es decir, hay un "doblez hacia adentro"), eliminar el punto del medio de la pila.
     b) Empujar p_i en la pila.
   - Para verificar la convexidad entre tres puntos consecutivos A, B, C en la pila, calcular el **producto cruzado**:

     $$\text{Producto cruzado} = (B_x - A_x)(C_y - B_y) - (B_y - A_y)(C_x - B_x)$$

     - Si el producto cruzado es **negativo**, el ángulo en B es mayor a 180° (no convexo).

- Si es **cero**, los puntos son colineales.
- Si es **positivo**, el ángulo es menor a 180° (convexo).

¿Qué representa n en la complejidad?

- n es el **número total de puntos** en el conjunto S.
- La complejidad del algoritmo es $O(n \log n)$, debido principalmente al **ordenamiento por ángulo polar**.
- La construcción de la pila es $O(n)$, ya que cada punto se empuja y se saca como máximo una vez.

Ejemplo paso a paso

Consideremos el conjunto de puntos

$$S = \{(0,0), (1,1), (2,0), (1,-1), (0{,}5, 0{,}5)\}.$$

1. Punto base: $p_0 = (0,0)$.
2. Ordenar por ángulo polar: $(2,0)$, $(1,-1)$, $(0{,}5, 0{,}5)$, $(1,1)$.
3. Construcción de la pila:
   - Empujar $(0,0)$, $(2,0)$, $(1,-1)$.
   - Para $(0{,}5, 0{,}5)$: Verificar convexidad entre $(0,0)$, $(2,0)$, $(1,-1)$. Eliminar $(2,0)$.
   - Empujar $(0{,}5, 0{,}5)$.
   - Para $(1,1)$: Verificar convexidad entre $(0,0)$, $(0{,}5, 0{,}5)$, $(1,-1)$. Empujar $(1,1)$.
4. Envoltura convexa final: $[(0,0), (0{,}5, 0{,}5), (1,1), (1,-1)]$.

2.2.4. Algoritmo QuickHull

El **algoritmo QuickHull** es un método eficiente para calcular la envoltura convexa de un conjunto de puntos en el plano, basado en una estrategia de **divide y vencerás**. Su nombre proviene de su similitud con el algoritmo de ordenamiento `Quicksort`, ya que también utiliza una partición recursiva del conjunto de puntos para construir la envoltura convexa.

Idea general

La idea central del QuickHull es:

- Identificar los puntos que forman los vértices de la envoltura convexa mediante la búsqueda de los puntos más alejados de los segmentos que unen pares de puntos.
- Dividir recursivamente el conjunto de puntos en subconjuntos más pequeños, cada uno asociado a un segmento de la envoltura parcial, y repetir el proceso hasta que no queden puntos externos.

Etapas del algoritmo

1. **Inicialización:**
   - Encontrar los puntos con las **coordenadas x mínima y máxima** en el conjunto S. Estos puntos **siempre pertenecen** a la envoltura convexa.
   - Estos dos puntos definen el **segmento inicial** de la envoltura convexa.
2. **División recursiva:**
   - Para cada segmento de la envoltura parcial (inicialmente, el segmento entre los puntos $x_{\text{mín}}$ y $x_{\text{máx}}$), encontrar el punto p más alejado del segmento.
   - Este punto p es un nuevo vértice de la envoltura convexa.
   - Dividir el conjunto de puntos en dos subconjuntos:

    - Los puntos que están a la **izquierda** del triángulo formado por el segmento y p.
    - Los puntos que están a la **derecha** del mismo triángulo.
  - Repetir el proceso recursivamente para cada subconjunto.

3. **Construcción final:**
   - Combinar los resultados de las divisiones recursivas para formar la envoltura convexa completa.

Complejidad

- En el **caso promedio**, la complejidad del QuickHull es $O(n \log n)$, similar al scan de Graham.
- En el **peor caso** (por ejemplo, cuando los puntos están en un círculo), la complejidad puede degradarse a $O(n^2)$.
- Sin embargo, en la práctica, suele ser más rápido que otros algoritmos debido a su naturaleza recursiva y su capacidad para descartar grandes conjuntos de puntos en cada iteración.

Ejemplo

Consideremos el conjunto de puntos

$$S = \{(0,0), (1,1), (2,0), (1,-1), (0{,}5, 0{,}5)\}.$$

1. Puntos iniciales: $x_{\text{mín}} = (0,0)$ y $x_{\text{máx}} = (2,0)$.
2. El punto más alejado del segmento $(0,0) - (2,0)$ es $(1,1)$.
3. Dividir S en dos subconjuntos:
   - Izquierda: $\{(0,0), (0{,}5, 0{,}5), (1,1)\}$.
   - Derecha: $\{(2,0), (1,-1), (0{,}5, 0{,}5)\}$.
4. Repetir el proceso para cada subconjunto hasta obtener la envoltura convexa final:
$$[(0,0), (1,1), (2,0), (1,-1)].$$

Ventajas y limitaciones

- **Ventajas:** Rápido en la práctica, fácil de implementar, y eficiente para conjuntos de puntos dispersos.
- **Limitaciones:** En el peor caso, puede ser lento ($O(n^2)$), y su rendimiento depende de la distribución de los puntos.

2.2.5. Aplicaciones

La **envoltura convexa** (o cáscara convexa) es esencial en:

- **Geometría computacional**: Para problemas de colisión, localización de puntos y clustering.
- **Visión por computadora**: En reconstrucción 3D y reconocimiento de formas.
- **Robótica**: Para planificación de caminos y evitación de obstáculos.
- **Aprendizaje automático**: En clustering (por ejemplo, el algoritmo DBSCAN).

2.3. Para profundizar

Recomendamos al lector interesado en profundizar en el tema consultar las siguientes obras: [1], [5], [6], [10].

Capítulo 3
Funciones convexas

Este capítulo aborda el análisis de funciones convexas en dimensión finita, un concepto central en optimización, economía matemática y aprendizaje automático. Se estudian dos contextos principales: el caso general (no necesariamente continuo) y el caso continuo. Para cada contexto, se presentan definiciones, propiedades fundamentales, caracterizaciones de mínimos locales y globales, y herramientas como el subgradiente y la Hessiana.

3.1. Caso general

Antes de abordar las propiedades específicas de las funciones convexas continuas, comenzaremos analizando el caso más general: funciones convexas que, aunque definidas sobre conjuntos convexos, no necesariamente cumplen con la propiedad de continuidad.

3.1.1. Definición, ejemplos y propiedades

> "La convexidad es el lenguaje natural de la optimización y el análisis de funciones en espacios vectoriales."
>
> Adaptado de *Convex Analysis* (Rockafellar, 1970)

Las funciones convexas son un pilar fundamental en el análisis matemático, la optimización y la inteligencia artificial. Su definición, aunque aparentemente simple, encierra profundas implicaciones geométricas y algebraicas, especialmente en espacios de dimensión finita. A continuación,

exploramos esta noción desde sus bases hasta ejemplos concretos, destacando el papel del dominio extendido y su relación con la convexidad de conjuntos.

Definición 4 (Función convexa en dimensión finita)**.** *Una función*

$$f : \mathbb{R}^n \to (-\infty, +\infty]$$

es ***convexa*** *si su* ***dominio extendido*** $dom(f) = \{x \in \mathbb{R}^n \mid f(x) < +\infty\}$ *es un conjunto convexo y, para todo* $x, y \in dom(f)$ *y todo* $\lambda \in [0, 1]$*, se cumple:*

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

El **dominio extendido** $\mathrm{dom}(f)$ incluye todos los puntos donde f no toma el valor $+\infty$. Este concepto es crucial porque:

- Permite manejar funciones definidas solo en subconjuntos específicos de $\mathbb{R}^n$ (por ejemplo, restricciones en optimización).
- Garantiza que la desigualdad de convexidad se aplique **solo** a pares de puntos donde f está bien definida.

Ejemplos ilustrativos

Ejemplo 2 (Función valor absoluto: $f(x) = |x|$)**.** *Tiene las cáracteristicas siguientes.*

- ***Dominio extendido:*** $dom(f) = \mathbb{R}$.
- ***Convexidad:*** *Cumple la desigualdad de convexidad (por desigualdad triangular):*

$$|\lambda x + (1 - \lambda)y| \leq \lambda|x| + (1 - \lambda)|y|.$$

- ***Visualización:***

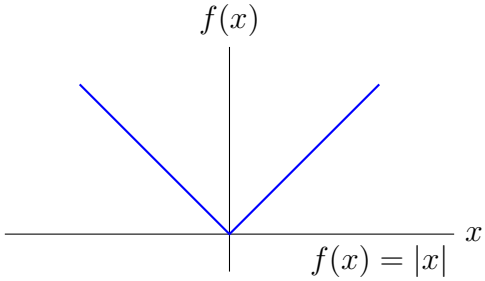

Ejemplo 3 (Función parte positiva: $f(x) = \text{máx}(x, 0)$)**.** *Tiene las cáracteristicas siguientes.*

- ***Dominio extendido:*** *$dom(f) = \mathbb{R}$.*
- ***Convexidad:*** *se verifica directamente con la définición.*
- ***Visualización:***

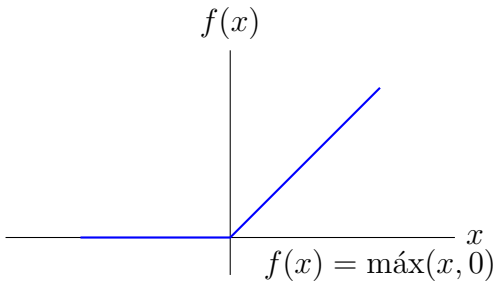

Ejemplo 4 (Función indicatriz de un conjunto convexo C)**.** *Se define así:*

$$f(x) = \begin{cases} 0 & si\ x \in C, \\ +\infty & si\ x \notin C. \end{cases}$$

- ***Dominio extendido:*** *$dom(f) = C$, que es convexo por definición.*
- ***Convexidad:*** *La desigualdad se cumple trivialmente (ambos lados son $+\infty$ o 0).*

Ejemplo 5 (Función norma euclidiana)**.** ***Función norma euclidiana:*** *Se define por $f(x) = \|x\|_2$.*

- ***Dominio extendido:*** *$dom(f) = \mathbb{R}^n$.*
- ***Convexidad:*** *Desigualdad triangular:*

$$\|\lambda x + (1 - \lambda)y\|_2 \leq \lambda\|x\|_2 + (1 - \lambda)\|y\|_2.$$

Las funciones convexas propias son un caso especialmente importante en optimización y análisis convexo, ya que combinan la convexidad con condiciones naturales sobre su dominio y valores. A continuación, presentamos su definición formal.

Definición 5 (Función convexa propia)**.** *Una función* $f : \mathbb{R}^n \to (-\infty, +\infty]$ *se denomina* ***convexa propia*** *si cumple las siguientes condiciones:*

1. ***Convexidad:*** f *es convexa en el sentido usual:*

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y), \quad \forall x, y \in \mathbb{R}^n, \forall \lambda \in [0,1].$$

2. ***Condición de no trivialidad:*** $f(x) < +\infty$ *para al menos un* $x \in \mathbb{R}^n$ *(es decir,* $dom(f) \neq \emptyset$*).*

El epígrafe de una función es, en términos sencillos, el 'volumen' o la región en el espacio que se forma por todos los puntos que están por encima de la gráfica de la función.

Definición 6 (Epígrafe de una función)**.** *El* ***epígrafe*** *de* f *se define como:*

$$epi(f) = \{(x, \alpha) \in \mathbb{R}^n \times \mathbb{R} \mid f(x) \leq \alpha\}.$$

Propiedades clave de funciones convexas

- **Cierre bajo sumas ponderadas:** Si f y g son convexas, entonces $\alpha f + \beta g$ también lo es para $\alpha, \beta \geq 0$.
- **Subniveles convexos:** El conjunto $\{x \mid f(x) \leq \alpha\}$ es convexo para todo $\alpha \in \mathbb{R}$.
- **Relación con la convexidad de conjuntos:** Una función es convexa si y solo si su **epígrafe** (conjunto de puntos por encima de su gráfica) es un conjunto convexo en $\mathbb{R}^{n+1}$.

Transición a propiedades avanzadas

La convexidad no solo simplifica el análisis de funciones, sino que también garantiza la existencia de mínimos globales en problemas de optimización. En lo siguiente, exploraremos cómo estas propiedades se aplican en algoritmos de optimización y aprendizaje automático, donde la convexidad es una condición suficiente para la eficiencia computacional.

3.1.2. Propiedades de continuidad

Las funciones convexas en dimensión finita poseen propiedades de continuidad que las distinguen de otras clases de funciones y son fundamentales en optimización y análisis convexo. A continuación, se presentan los resultados teóricos principales, sus demostraciones y ejemplos ilustrativos.

Teorema 4 (Continuidad en el interior del dominio)**.** *Sea*

$$f : \mathbb{R}^n \to (-\infty, +\infty]$$

una función convexa propia. Entonces, f es ***localmente lipschitziana*** *y por lo tanto* ***continua*** *en el interior de su dominio extendido $int(dom(f))$.*

Demostración. La prueba puede consultarse en [1, Sección 2.1.2]. □

Teorema 5 (Continuidad global en $\mathbb{R}^n$)**.** *Si $f : \mathbb{R}^n \to \mathbb{R}$ es una función convexa y $dom(f) = \mathbb{R}^n$, entonces f es* ***globalmente continua*** *en $\mathbb{R}^n$.*

Demostración. Véase [10, Teorema 10.1]. □

Ejemplos, contraejemplos y casos límite

Ejemplo 6 (Función convexa discontinua en la frontera)**.** *Consideremos la función indicatriz de un conjunto convexo C:*

$$f(x) = \begin{cases} 0 & si\ x \in C, \\ +\infty & si\ x \notin C. \end{cases}$$

- *f es convexa propia si C es no vacío y convexo.*
- *f es discontinua en todo punto $x \in \partial C$ (frontera de C), ya que $\lim_{y \to x, y \notin C} f(y) = +\infty$.*
- *Este ejemplo muestra que la continuidad solo se garantiza en el interior de $dom(f)$.*

Ejemplo 7 (Función convexa definida en $\mathbb{R}^n$)**.** *La función $f(x) = \|x\|_2^2$ es convexa y definida en $\mathbb{R}^n$. Por el Teorema 5, f es continua en todo $\mathbb{R}^n$.*

Ejemplo 8 (No convexidad de la función de Heaviside)**.** *Consideramos la función de Heaviside, definida como:*

$$H(x) = \begin{cases} 0 & si\ x < 0, \\ c & si\ x = 0, \\ 1 & si\ x > 0. \end{cases} \quad donde\ c \in \{0, 1\},$$

Demostramos que H no es convexa, independientemente del valor de c. ***Caso 1 :*** *$H(0) = 0$ Tomemos $x_1 = -1$, $x_2 = 2$, y $\lambda = 0{,}5$:*

$$H(0{,}5 \cdot (-1) + 0{,}5 \cdot 2) = H(0{,}5) = 1,$$

y

$$0{,}5 \cdot H(-1) + 0{,}5 \cdot H(2) = 0{,}5 \cdot 0 + 0{,}5 \cdot 1 = 0{,}5.$$

Aquí, $1 \not\leq 0{,}5$: la desigualdad de convexidad no se cumple. Por lo tanto, H no es convexa incluso si $H(0) = 0$.

Caso 2 : *$H(0) = 1$ Tomemos: - $x_1 = -1$ (donde $H(-1) = 0$), - $x_2 = 1$ (donde $H(1) = 1$), - $\lambda = 0{,}5$. Calculamos:*

$$H(\lambda x_1 + (1 - \lambda)x_2) = H(0) = 1,$$

y

$$0{,}5 \cdot H(-1) + 0{,}5 \cdot H(1) = 0{,}5 \cdot 0 + 0{,}5 \cdot 1 = 0{,}5.$$

La desigualdad de convexidad exige:

$$1 \leq 0{,}5,$$

lo cual es falso. Por lo tanto, H no es convexa si $H(0) = 1$. Independientemente del valor de $H(0)$ (0 o 1), la función de Heaviside no satisface la desigualdad de convexidad para ciertos puntos. Por lo tanto, nunca es convexa.

Implicaciones en optimización

- **Existencia de mínimos:** Si f es convexa propia y $C \subset \mathbb{R}^n$ es un conjunto convexo cerrado no vacío, entonces f alcanza su mínimo sobre C si $C \cap \mathrm{dom}(f) \neq \emptyset$ [10].

- **Estabilidad numérica:** La continuidad de f en el interior de su dominio garantiza la convergencia de algoritmos como el de gradiente descendente.

- **Subgradientes:** En puntos donde f no es diferenciable (por ejemplo, $f(x) = |x|$ en $x = 0$), la convexidad permite definir subgradientes, que son herramientas clave en optimización.

3.1.3. Subdiferencial de funciones convexas

La noción de subdiferencial generaliza el concepto de gradiente a funciones convexas que no son necesariamente diferenciables. Esta herramienta es fundamental en optimización convexa, ya que permite caracterizar óptimos incluso en presencia de no diferenciabilidad.

Definición 7 (Subgradiente)**.** *Sea $f : \mathbb{R}^n \to (-\infty, +\infty]$ una función convexa. Un vector $g \in \mathbb{R}^n$ es un* ***subgradiente*** *de f en x si*

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in \mathbb{R}^n.$$

El conjunto de todos los subgradientes de f en x se denota $\partial f(x)$ y se llama ***subdiferencial*** *de f en x.*

Intuitivamente, un subgradiente define un hiperplano de soporte al epígrafo de la función en el punto considerado. Cuando la función es diferenciable, el subdiferencial se reduce a un singleton que contiene el gradiente clásico.

A continuación, resumimos algunas propiedades fundamentales del subdiferencial en dimensión finita.

Propiedades clave. Sea $f : \mathbb{R}^n \to (-\infty, +\infty]$ convexa y $x \in \mathrm{dom}(f)$. Entonces:

- El conjunto $\partial f(x)$ es convexo y cerrado.
- Si f es diferenciable en x, entonces
$$\partial f(x) = \{\nabla f(x)\}.$$
- La condición de optimalidad de primer orden se escribe:
$$0 \in \partial f(x) \quad \Longleftrightarrow \quad x \text{ es un minimizador global de } f.$$
- La aplicación $x \mapsto \partial f(x)$ es monótona en el sentido de operadores:
$$(g_1 - g_2)^T(x_1 - x_2) \geq 0 \quad \text{para todo } g_i \in \partial f(x_i).$$

Para ilustrar esta noción, presentamos ahora algunos ejemplos clásicos de cálculo de subdiferenciales.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$ con $x \in \mathbb{R}$. Entonces:
$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{-1\} & \text{si } x < 0, \\ [-1, 1] & \text{si } x = 0. \end{cases}$$
- **Parte positiva.** Sea $f(x) = \text{máx}(0, x)$. Entonces:
$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{0\} & \text{si } x < 0, \\ [0, 1] & \text{si } x = 0. \end{cases}$$
- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ un conjunto convexo cerrado y
$$\iota_C(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$
Entonces, para $x \in C$, el subdiferencial está dado por el cono normal:
$$\partial \iota_C(x) = N_C(x) = \{g \in \mathbb{R}^n \mid g^T(y - x) \leq 0, \ \forall y \in C\}.$$

Estos ejemplos muestran cómo el subdiferencial captura la falta de diferenciabilidad mediante conjuntos de pendientes admisibles, lo cual resulta esencial en el análisis y la resolución de problemas de optimización convexa no suave.

3.1.4. Caracterización de mínimos

Una de las principales ventajas del subdiferencial es que permite formular condiciones de optimalidad de primer orden sin requerir diferenciabilidad. En el contexto de funciones convexas, esta caracterización es particularmente simple y poderosa. El siguiente resultado establece una condición necesaria y suficiente de optimalidad global.

Teorema 6 (Caracterización de mínimos)**.** *Sea* $f : \mathbb{R}^n \to (-\infty, +\infty]$ *una función convexa. Un punto* $x^* \in \mathrm{dom}(f)$ *es un mínimo global de* f *si y solo si*

$$0 \in \partial f(x^*).$$

Este resultado generaliza la condición clásica $\nabla f(x^*) = 0$ del caso diferenciable. En efecto, cuando f es diferenciable en x^*, se tiene $\partial f(x^*) = \{\nabla f(x^*)\}$, y la condición anterior se reduce a la conocida anulación del gradiente.

Idea de la demostración. La demostración se basa directamente en la definición de subgradiente.

- (*Suficiencia*) Si $0 \in \partial f(x^*)$, entonces por definición:

  $$f(y) \geq f(x^*) \quad \forall y \in \mathbb{R}^n,$$

  lo que implica que x^* es un mínimo global.

- (*Necesidad*) Si x^* es un mínimo global, entonces

  $$f(y) \geq f(x^*) \quad \forall y,$$

  lo que corresponde exactamente a la desigualdad de subgradiente con $g = 0$.

Para una demostración más detallada y en un marco más general (espacios vectoriales normados), se puede consultar textos clásicos de optimización convexa como [6].

Interpretación geométrica. La condición $0 \in \partial f(x^*)$ significa que existe un hiperplano de soporte horizontal al epígrafo de f en x^*. Intuitivamente, esto indica que no existe ninguna dirección de descenso, lo que caracteriza un mínimo global en el caso convexo.

A continuación, ilustramos esta caracterización con ejemplos clásicos.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$. Entonces:

  $$\partial f(0) = [-1, 1].$$

  Como $0 \in [-1, 1]$, se concluye que $x^* = 0$ es un mínimo global. En cambio, si $x \neq 0$, entonces $\partial f(x)$ no contiene al cero, lo que confirma que no son minimizadores.

- **Parte positiva.** Sea $f(x) = \text{máx}(0, x)$. Se tiene:

  $$\partial f(0) = [0, 1].$$

  Dado que $0 \in \partial f(0)$, el punto $x^* = 0$ es un mínimo global (de hecho, $f(x) \geq 0$ para todo x).

- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ convexo cerrado y $f = \iota_C$. Entonces:

  $$\partial f(x) = N_C(x).$$

  La condición de optimalidad se escribe:

  $$0 \in N_C(x^*),$$

  lo cual equivale a decir que

  $$0^T(y - x^*) \leq 0 \quad \forall y \in C,$$

  condición que es siempre verdadera. Esto refleja el hecho de que todo punto de C es minimizador de ι_C.

Comentario. Este criterio es fundamental en optimización convexa y sirve como base para numerosos algoritmos (métodos de subgradiente, métodos proximales, etc.). Su simplicidad contrasta con su gran generalidad, ya que sigue siendo válido incluso en ausencia de diferenciabilidad.

3.2. Casos continuo y diferenciable

Definición 8 (Función convexa diferenciable)**.** *Si $f : \mathbb{R}^n \to \mathbb{R}$ es convexa y diferenciable en x, entonces*

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad \forall y \in \mathbb{R}^n.$$

Además, $\nabla f(x)$ es el único subgradiente de f en x.

Definición 9 (Función convexa dos veces diferenciable)**.** *Si $f : \mathbb{R}^n \to \mathbb{R}$ es convexa y dos veces diferenciable, entonces su matriz Hessiana $\nabla^2 f(x)$ es* ***semidefinida positiva*** *para todo $x \in \mathbb{R}^n$. Recíprocamente, si $\nabla^2 f(x)$ es semidefinida positiva para todo x, entonces f es convexa.*

Teorema 7 (Caracterización de mínimos con gradiente)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global de f si y solo si*

$$\nabla f(x^*) = 0.$$

Teorema 8 (Caracterización de mínimos con Hessiana)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y dos veces diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global estricto de f si y solo si*

$$\nabla f(x^*) = 0 \quad y \quad \nabla^2 f(x^*) \text{ es definida positiva.}$$

Capítulo 4
Métodos de minimización

Los métodos de minimización son herramientas fundamentales en matemática aplicada, optimización, aprendizaje automático y ciencia de datos. Este capítulo aborda los principios y algoritmos más relevantes para resolver problemas de minimización de funciones, desde enfoques clásicos hasta técnicas avanzadas basadas en análisis convexo y métodos numéricos. Cada sección incluye las fórmulas clave de los métodos y, cuando es posible, su relación con ecuaciones diferenciales que modelan la dinámica de la minimización.

4.1. Gradiente descendente

El **gradiente descendente** es un método iterativo para minimizar una función $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable. El algoritmo se define como:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k),$$

donde $\alpha_k > 0$ es el tamaño de paso (o tasa de aprendizaje) y $\nabla f(x_k)$ es el gradiente de f en x_k.

Vínculo con ecuaciones diferenciales: El método de gradiente descendente puede interpretarse como una discretización de la ecuación diferencial ordinaria (EDO) asociada al flujo gradiente:

$$\frac{dx}{dt} = -\nabla f(x(t)).$$

La solución de esta EDO, bajo condiciones adecuadas, converge a un mínimo local de f.

4.2. Método de Newton

El **método de Newton** utiliza aproximaciones cuadráticas locales para acelerar la convergencia. La iteración se define como:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k),$$

donde $\nabla^2 f(x_k)$ es la matriz Hessiana de f en x_k. Este método converge cuadráticamente cerca de mínimos locales.

Vínculo con ecuaciones diferenciales: El método de Newton puede verse como una aproximación de la dinámica de segundo orden:

$$\frac{d^2x}{dt^2} + \gamma \frac{dx}{dt} = -\nabla f(x),$$

donde γ es un parámetro de amortiguamiento. Esta ecuación modela el movimiento de una partícula en un paisaje de energía potencial f.

4.3. Método de punto fijo

El **método de punto fijo** busca resolver $x = g(x)$, donde g es una función iterativa. Para minimización, se define $g(x) = x - \alpha \nabla f(x)$, y la iteración es:

$$x_{k+1} = g(x_k).$$

La convergencia depende de que g sea una contracción.

Vínculo con ecuaciones diferenciales: Si $g(x) = x - \alpha \nabla f(x)$, el método de punto fijo puede relacionarse con la EDO:

$$\frac{dx}{dt} = -\nabla f(x).$$

Este es el mismo flujo gradiente del método de gradiente descendente.

4.4. Método de penalización

El **método de penalización** transforma un problema con restricciones $\min f(x)$ sujeto a $c_i(x) = 0$ en un problema sin restricciones:

$$\min f(x) + \mu \sum_{i=1}^{m} c_i(x)^2,$$

donde $\mu > 0$ es el parámetro de penalización.

Vínculo con ecuaciones diferenciales: La dinámica asociada puede modelarse como:

$$\frac{dx}{dt} = -\nabla f(x) - 2\mu \sum_{i=1}^{m} c_i(x) \nabla c_i(x),$$

que combina el gradiente de la función objetivo con el gradiente de las restricciones.

4.5. Método de Lagrange

El **método de Lagrange** introduce multiplicadores λ para problemas con restricciones $c_i(x) = 0$. La función Lagrangiana es:

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^{m} \lambda_i c_i(x).$$

Las condiciones de optimalidad son:

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0, \quad c_i(x^*) = 0.$$

Vínculo con ecuaciones diferenciales: La dinámica de los multiplicadores de Lagrange puede describirse mediante:

$$\frac{dx}{dt} = -\nabla_x \mathcal{L}(x, \lambda), \quad \frac{d\lambda}{dt} = c(x).$$

Esta ecuación diferencial parcial (EDP) describe la evolución de x y λ hacia un punto de equilibrio.

4.6. Métodos cuasi-Newton (BFGS)

El método **BFGS** aproxima la inversa de la Hessiana H_k mediante actualizaciones iterativas:

$$H_{k+1} = \left(I - \frac{y_k s_k^T}{y_k^T s_k}\right) H_k \left(I - \frac{s_k y_k^T}{y_k^T s_k}\right) + \frac{s_k s_k^T}{y_k^T s_k},$$

donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$. La iteración es:

$$x_{k+1} = x_k - \alpha_k H_k \nabla f(x_k).$$

Vínculo con ecuaciones diferenciales: Los métodos cuasi-Newton pueden interpretarse como aproximaciones de la dinámica de segundo orden:

$$\frac{d^2x}{dt^2} + \gamma \frac{dx}{dt} = -H^{-1} \nabla f(x),$$

donde H es la aproximación de la Hessiana.

Capítulo 5

Medida y análisis funcional

Este capítulo está dedicado a profundizar en los fundamentos matemáticos esenciales para el análisis avanzado: la **teoría de medida**, la **integral de Lebesgue** y los **espacios funcionales**. Estos conceptos son pilares en el estudio de la probabilidad, la ecuación diferencial parcial, el análisis funcional y la teoría de control. A través de un enfoque riguroso, se presentan las herramientas teóricas necesarias para abordar problemas complejos en matemática, sentando las bases para el desarrollo de métodos modernos en optimización, física matemática y ciencia de datos.

5.1. Medida

La noción de **medida** generaliza el concepto clásico de longitud, área y volumen a conjuntos abstractos, permitiendo cuantificar el "tamaño" de subconjuntos en espacios arbitrarios. Esta teoría es fundamental para definir integrales generalizadas, como la integral de Lebesgue, y para analizar funciones medibles. Se exploran las propiedades de los espacios de medida, la construcción de medidas a partir de premedidas, y la relación entre la medida y la topología. Además, se estudian los teoremas clásicos de convergencia, como el de la convergencia monótona y el de la convergencia dominada, que son esenciales en el análisis funcional y en la teoría de la probabilidad.

5.2. Medida y funciones

5.2.1. Funciones BV

Definición 10 (Variación acotada)**.** *Una función $f : [a, b] \to \mathbb{R}$ es de* ***variación acotada*** *si su variación total es finita:*

$$V_a^b(f) = \sup \left\{ \sum_{i=1}^{n} |f(x_i) - f(x_{i-1})| : a = x_0 < x_1 < \cdots < x_n = b \right\} < \infty.$$

El espacio $BV([a, b])$ es el conjunto de funciones de variación acotada en $[a, b]$.

Teorema 9 (Estructura de funciones BV)**.** *Toda función $f \in BV([a, b])$ puede escribirse como la diferencia de dos funciones crecientes. Además, f es derivable en casi todo punto y su derivada es integrable.*

5.2.2. Continuidad absoluta

Definición 11 (Continuidad absoluta)**.** *Una función $f : [a, b] \to \mathbb{R}$ es* ***absolutamente continua*** *si para todo $\varepsilon > 0$ existe $\delta > 0$ tal que para cualquier colección finita de intervalos disjuntos $(a_i, b_i) \subset [a, b]$ con $\sum_i (b_i - a_i) < \delta$, se tiene:*

$$\sum_i |f(b_i) - f(a_i)| < \varepsilon.$$

Teorema 10 (Caracterización de funciones absolutamente continuas)**.** *Sea $f : [a, b] \to \mathbb{R}$ una función. Las siguientes afirmaciones son equivalentes:*

1. *f es absolutamente continua.*

2. *f es la integral indefinida de su derivada: existe $g \in L^1([a, b])$ tal que*
$$f(x) = f(a) + \int_a^x g(t)\, dt \quad \forall x \in [a, b].$$

3. *f es continua, de variación acotada, y la medida de Lebesgue-Stieltjes asociada a f es absolutamente continua respecto a la medida de Lebesgue.*

Observación 1. *Las funciones absolutamente continuas son un subconjunto propio de las funciones continuas de variación acotada. Además, toda función absolutamente continua es derivable en casi todo punto y su derivada coincide con la función g del teorema anterior.*

Ejemplo 9. *La función $f(x) = x^2 \sin(1/x)$ para $x \neq 0$ y $f(0) = 0$ es absolutamente continua en $[0, 1]$, pero no es Lipschitz continua.*

Ejemplo 10. *La función de Cantor-Lebesgue es un ejemplo clásico de función en $BV([0, 1])$ pero no absolutamente continua.*

5.2.3. Teorema de aproximación de Lebesgue

Teorema 11 (Teorema de aproximación de Lebesgue)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función medible. Entonces, existe una sucesión de funciones continuas f_k tal que $f_k \to f$ casi en todo punto y en medida.*

Observación 2. *Este teorema es fundamental para aproximar funciones no continuas por funciones continuas en el contexto de la teoría de la medida, y está estrechamente relacionado con la diferenciabilidad en casi todo punto.*

5.2.4. Teorema de Lebesgue

Teorema 12 (Teorema de diferenciación de Lebesgue)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función localmente integrable. Entonces, para casi todo $x \in \mathbb{R}^n$, se tiene:*

$$\lim_{r \to 0^+} \frac{1}{|B(x, r)|} \int_{B(x,r)} f(y)\, dy = f(x),$$

donde $B(x, r)$ es la bola de centro x y radio r.

Teorema 13 (Teorema de Lebesgue para funciones de variación acotada)**.** *Sea $f : [a, b] \to \mathbb{R}$ una función de variación acotada. Entonces, f es derivable en casi todo punto de $[a, b]$, y su derivada f' es integrable en $[a, b]$.*

Observación 3. *El teorema de Lebesgue asegura que, aunque una función no sea continua, su promedio local converge a su valor en casi todo punto. Esto es clave para entender la diferenciabilidad en el contexto de la teoría de la medida.*

5.2.5. Teorema de Rademacher

Definición 12 (Función Lipschitz)**.** *Una función $f : \mathbb{R}^n \to \mathbb{R}^m$ es* ***Lipschitz*** *si existe $L \geq 0$ tal que*

$$|f(x) - f(y)| \leq L|x - y| \quad \forall x, y \in \mathbb{R}^n.$$

El menor L que satisface esta desigualdad se denomina ***constante de Lipschitz*** *de f.*

Teorema 14 (Teorema de Rademacher)**.** *Toda función Lipschitz $f : \mathbb{R}^n \to \mathbb{R}^m$ es derivable en casi todo punto de $\mathbb{R}^n$. Además, su diferencial $Df(x)$ es esencialmente acotada (i.e., $\|Df(x)\| \leq L$ c.t.p.).*

Demostración. La demostración clásica usa el teorema de diferenciación de Lebesgue y el hecho de que las funciones Lipschitz son de variación acotada en casi todo punto. □

Observación 4. *El teorema de Rademacher es fundamental en el análisis de funciones no diferenciables en el sentido clásico, pero con regularidad Lipschitz. Extiende el resultado de que las funciones de variación acotada son derivables en casi todo punto (Teorema de Lebesgue).*

Ejemplo 11. *La función $f(x) = |x|$ es Lipschitz en $\mathbb{R}$, pero no es derivable en $x = 0$. Sin embargo, es derivable en casi todo punto de $\mathbb{R}$ (excepto en $x = 0$).*

5.2.6. Resumen de Relaciones entre Propiedades

Propiedad	**Derivable en c.t.p.**	**Relación con L^1**
Continuidad absoluta	Sí	$f(x) = f(a) + \int_a^x g(t)\,dt$
Función Lipschitz	Sí (Rademacher)	$\|Df\|_\infty \leq L$
Variación acotada	Sí (Lebesgue)	$f' \in L^1$
Medible	No necesariamente	Aproximable por funciones continuas

5.3. Hahn–Banach

El **teorema de Hahn–Banach** es uno de los resultados más profundos y útiles del análisis funcional. Este teorema garantiza la existencia de extensiones lineales y continuas de funcionales definidos en subespacios de un espacio vectorial normado, preservando su norma. Sus consecuencias son vastas: permite demostrar la existencia de funcionales lineales continuos no triviales, la separación de conjuntos convexos disjuntos, y la unicidad de normas equivalentes. El teorema de Hahn–Banach es clave en la dualidad entre espacios de Banach y en el estudio de la convergencia en espacios de funciones.

5.4. Espacios de Hilbert

Los **espacios de Hilbert** son generalizaciones del espacio euclidiano a dimensiones infinitas, donde la noción de ortogonalidad y proyección juega un papel central. Estos espacios poseen una estructura geométrica rica, basada en el producto interno, y permiten desarrollar teorías de series de Fourier generalizadas, bases ortonormales y operadores compactos. Se analizan propiedades como la completitud, la descomposición ortogonal y la representación de funcionales lineales continuos mediante el teorema de representación de Riesz. Los espacios de Hilbert son fundamentales en mecánica cuántica, teoría de aproximación y procesamiento de señales.

5.5. Espacios de Lebesgue

Los **espacios de Lebesgue** L^p son espacios funcionales que generalizan el concepto de integrabilidad en el sentido de Lebesgue. Estos espacios, parametrizados por $p \in [1, \infty]$, consisten en clases de equivalencia de funciones medibles cuyas potencias p-ésimas son integrables. Se estudian sus propiedades topológicas, la densidad de funciones continuas, y los teoremas de densidad y aproximación. Además, se exploran las desigualdades fundamentales, como las de Hölder y Minkowski, y su

relación con la convergencia en medida y la continuidad de operadores lineales.

5.6. Derivada débil

La **derivada débil** extiende el concepto clásico de derivada a funciones que no son diferenciables en el sentido usual, pero que poseen una derivada generalizada en un sentido distribucional. Esta noción es esencial en la teoría de distribuciones y en el estudio de ecuaciones diferenciales parciales, donde muchas soluciones no son clásicas. Se definen los espacios de Sobolev y se analizan sus propiedades, incluyendo los teoremas de inmersión y traza, que permiten entender cómo las propiedades de regularidad de una función se transfieren a su frontera. La derivada débil es una herramienta poderosa para formular problemas variacionales y analizar su solubilidad.

5.7. Espacios de Sobolev

Los **espacios de Sobolev** son espacios funcionales que combinan propiedades de diferenciabilidad y integrabilidad, siendo fundamentales en el estudio de ecuaciones diferenciales parciales y en el análisis numérico. Estos espacios consisten en funciones cuyas derivadas débiles hasta cierto orden pertenecen a espacios de Lebesgue. Se analizan sus propiedades de completitud, densidad, y los teoremas de compactación, que son cruciales para demostrar la existencia de soluciones débiles. Los espacios de Sobolev también permiten formular problemas de minimización en cálculo de variaciones y en la teoría del potencial, proporcionando un marco riguroso para el análisis de regularidad y unicidad de soluciones.

5.8. Ejemplos

5.8.1. Generales

A continuación se dan ejemplos sencillos en una dimensión (dominio habitual $(-1, 1)$ o $\mathbb{R}$) que ilustran pertenencia o no a los espacios L^2 y

H^1.

- **Función continua que está en L^2 pero no en H^1:**

$$f(x) = |x|^\alpha, \qquad \alpha = \tfrac{1}{4}, \quad x \in (-1,1).$$

  Aquí $f \in L^2((-1,1))$ porque $\int_{-1}^{1} |x|^{2\alpha}\,dx < \infty$ (ya que $2\alpha > -1$), pero la derivada puntual es $f'(x) = \alpha\ \mathrm{sgn}(x)|x|^{\alpha-1}$ cuya norma L^2 diverge porque $2(\alpha-1) \leq -1$; por tanto no existe derivada débil en L^2 y $f \notin H^1((-1,1))$. Este ejemplo es continuo pero no pertenece a H^1.

- **Función discontinua que pertenece a L^2 pero no a H^1:**

$$\chi_{(0,1)}(x) = \begin{cases} 1, & x \in (0,1), \\ 0, & \text{en otro caso,} \end{cases}$$

  vista como función en $\mathbb{R}$. Tiene norma L^2 finita, pero presenta una discontinuidad por salto; su derivada en sentido de distribuciones contiene deltas de frontera (no representables por una función en L^2), luego $\chi_{(0,1)} \notin H^1(\mathbb{R})$.

- **Función o distribución que no está en L^2:**
  - La función singular $g(x) = |x|^{-\beta}$ en $(-1,1)$ con $\beta \geq \frac{1}{2}$ no pertenece a $L^2((-1,1))$ porque $\int_{-1}^{1} |x|^{-2\beta}\,dx = \infty$.
  - La delta de Dirac δ_0 (distribución) no es una función en L^2 (no es una función cuadrado-integrable).

Cada ejemplo indica la razón básica (comportamiento en el origen o saltos) por la que falla la integrabilidad cuadrática o la existencia de derivada débil en L^2.

5.8.2. Indicador

La función $1_{\{0,1\}}(x)$ representa la **indicador de** $\{0,1\}$, definida como:

$$1_{\{0,1\}}(x) = \begin{cases} 1 & \text{si } x \in \{0,1\}, \\ 0 & \text{en otro caso.} \end{cases}$$

Esta función es discontinua en $x = 0$ y $x = 1$, por lo que no pertenece a los espacios clásicos de Sobolev $H^s(\mathbb{R})$ para $s \geq 1/2$ en el sentido estándar. Sin embargo, su regularidad puede analizarse en el marco de los **espacios de Sobolev fraccionarios** $H^s(\mathbb{R})$, $s \in (0,1)$.

En particular, la indicatriz $1_{\{0,1\}}$ pertenece al espacio $H^{1/2-\varepsilon}(\mathbb{R})$ para todo $\varepsilon > 0$, pero **no** pertenece a $H^{1/2}(\mathbb{R})$. Este resultado se justifica mediante el cálculo de la norma de Sobolev fraccionaria:

$$\|1_{\{0,1\}}\|^2_{H^s(\mathbb{R})} = \int_{\mathbb{R}} |\xi|^{2s} |\widehat{1_{\{0,1\}}}(\xi)|^2 \, d\xi,$$

donde $\widehat{1_{\{0,1\}}}(\xi)$ es la transformada de Fourier de la indicatriz. Dado que la transformada de Fourier de $1_{\{0,1\}}$ decae como $|\xi|^{-1}$ en el infinito, la integral converge si y solo si $s < 1/2$. Por lo tanto, la regularidad fraccionaria de la indicatriz está limitada por $s = 1/2$. La **transformada de Fourier** de la indicatriz $1_{\{0,1\}}(x)$ es:

$$\widehat{1_{\{0,1\}}}(\xi) = e^{-i\xi} \frac{\sin(\xi)}{\xi},$$

que también puede escribirse como:

$$\widehat{1_{\{0,1\}}}(\xi) = e^{-i\xi} \frac{\sin(\xi)}{\xi}.$$

Esta función decae como $|\xi|^{-1}$ cuando $|\xi| \to \infty$.

5.9. Más espacios funcionales

5.9.1. Espacios de Sobolev $H^s(\mathbb{R})$

El espacio de Sobolev $H^s(\mathbb{R})$ para $s \in \mathbb{R}$ se define como:

$$H^s(\mathbb{R}) = \left\{ f \in \mathcal{S}'(\mathbb{R}) : \int_{\mathbb{R}} (1 + |\xi|^2)^s |\widehat{f}(\xi)|^2 \, d\xi < \infty \right\},$$

donde $\widehat{f}$ es la transformada de Fourier de f. La norma en $H^s(\mathbb{R})$ es:

$$\|f\|^2_{H^s(\mathbb{R})} = \int_{\mathbb{R}} (1 + |\xi|^2)^s |\widehat{f}(\xi)|^2 \, d\xi.$$

5.9.2. Espacios de Besov $\mathcal{B}^s_{p,q}(\mathbb{R})$

El espacio de Besov $\mathcal{B}^s_{p,q}(\mathbb{R})$ para $s \in \mathbb{R}$ y $p, q \in [1, \infty]$ se define mediante diferencias finitas o mediante la descomposición en frecuencias. Intuitivamente, mide la regularidad de f en términos de cómo sus diferencias finitas decaen. Para $0 < s < 1$ y $1 \leq p, q \leq \infty$, se tiene:

$$\mathcal{B}^s_{p,q}(\mathbb{R}) = \left\{ f \in L^p(\mathbb{R}) : \left(\int_0^\infty \left(t^{-s} \omega_p(f,t) \right)^q \frac{dt}{t} \right)^{1/q} < \infty \right\},$$

donde $\omega_p(f,t)$ es el módulo de continuidad en L^p.

5.9.3. Exponente de Hölder

El **exponente de Hölder** α de una función f en un punto x_0 es el supremo de todos $\alpha > 0$ tales que:

$$|f(x) - f(x_0)| \leq C|x - x_0|^\alpha \quad \text{para } x \text{ cerca de } x_0.$$

5.10. Fractales

5.10.1. Función de Weierstrass

La **función de Weierstrass** se define para $\lambda > 1$ y $0 < H < 1$ como:

$$W_H(x) = \sum_{n=0}^{\infty} \lambda^{-nH} \cos(2\pi \lambda^n x).$$

- **Propiedades:** Es continua pero nowhere differentiable.
- **Regularidad de Sobolev:** $W_H \in H^s(\mathbb{R})$ para todo $s < H$.
- **Regularidad de Besov:** $W_H \in \mathcal{B}^H_{p,q}(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = H$ en casi todo punto.
- **Referencia:** Mandelbrot [9].

5.10.2. Función de Takagi

La **función de Takagi** se define como:

$$T(x) = \sum_{n=0}^{\infty} \frac{1}{2^n} \mathrm{dist}(2^n x, \mathbb{Z}),$$

donde $\mathrm{dist}(x, \mathbb{Z})$ es la distancia de x al entero más cercano.

- **Propiedades:** Es continua, creciente, y nowhere differentiable.
- **Regularidad de Sobolev:** $T \in H^s(\mathbb{R})$ para todo $s < 1/2$.
- **Regularidad de Besov:** $T \in \mathcal{B}^{1/2}_{p,q}(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = 1/2$ en casi todo punto.
- **Referencia:** Takagi [12].

5.10.3. Movimiento browniano fraccionario

El **movimiento Browniano fraccionario** $B_H(t)$ con parámetro de Hurst $0 < H < 1$ es un proceso estocástico gaussiano con trayectorias fractales.

- **Propiedades:** Tiene trayectorias continuas pero nowhere diferenciables si $H \neq 1$.
- **Regularidad de Sobolev:** Casi todas las trayectorias satisfacen $B_H \in H^s(\mathbb{R})$ para todo $s < H$.
- **Regularidad de Besov:** Casi todas las trayectorias satisfacen $B_H \in \mathcal{B}^H_{p,q}(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = H$ en casi todo punto y trayectoria.
- **Referencia:** Samorodnitsky y Taqqu [11].

5.10.4. Conjunto de Cantor

El **conjunto de Cantor** C se construye eliminando el tercio central de cada intervalo.

- **Propiedades:** Es un fractal autosimilar con dimensión de Hausdorff $D = \frac{\log 2}{\log 3}$.
- **Función indicatriz:** La función $1_C(x)$ tiene regularidad de Besov $s < D$.
- **Regularidad de Sobolev:** $1_C \notin H^{1/2}(\mathbb{R})$.
- **Referencia:** Cantor [2].

5.10.5. Función de Cantor-Lebesgue

La **función de Cantor-Lebesgue** $f_C(x)$ es continua, creciente, y singular (constante en los intervalos del complemento de C).

- **Propiedades:** Es constante en los intervalos de $\mathbb{R} \setminus C$.
- **Regularidad de Sobolev:** $f_C \notin H^{1/2}(\mathbb{R})$.
- **Regularidad de Besov:** $f_C \in \mathcal{B}^s_{p,q}(\mathbb{R})$ para $s < D$.
- **Referencia:** Lebesgue [8].

5.11. Ecuaciones elípticas

Las ecuaciones elípticas son un tipo de ecuaciones en derivadas parciales de segundo orden cuyo símbolo principal es definido positivo (por ejemplo, la ecuación de Laplace $\Delta u = 0$ o la de Poisson $-\Delta u = f$), y modelan estados estacionarios y distribuciones espaciales equilibradas; en problemas de contorno bien planteados suelen garantizar existencia, unicidad y regularidad de soluciones suaves en dominios regulares, y poseen propiedades cualitativas importantes como el principio del máximo, estimaciones a priori y dependencia continua respecto de los datos, lo que las convierte en herramientas centrales en análisis y aplicaciones físicas e ingenieriles.

Capítulo 6
Dimensión infinita

El estudio de la **dimensión infinita** en el ámbito del análisis convexo y la optimización permite abordar problemas complejos que surgen en mecánica de sólidos, teoría de control, economía y aprendizaje automático. En este contexto, las funciones y conjuntos convexos se definen en espacios de Hilbert o de Banach, donde las herramientas del análisis funcional son esenciales para garantizar la existencia de soluciones y su caracterización. La optimización en dimensión infinita extiende los principios de la programación convexa clásica, permitiendo modelar fenómenos con restricciones no lineales y operadores diferenciales. Este enfoque es fundamental para desarrollar métodos numéricos robustos y teoremas de dualidad que subyacen en aplicaciones modernas como el control óptimo y la teoría de juegos.

Capítulo 7
Desigualdades variacionales

Las desigualdades variacionales son útiles para modelar numerosos problemas de la física o la ingeniería [3, 4, 7]. Sin embargo, rara vez se abordan en los cursos de posgrado de análisis numérico. El objetivo de esta breve nota es presentar el análisis numérico del problema del obstáculo, cuando se discretiza mediante elementos finitos. El problema del obstáculo es, de hecho, el prototipo ideal de una desigualdad variacional y, quizás, el más sencillo de ellos.

Denotamos por $H^s(\cdot)$, $s \in \mathbb{R}$, a los espacios de Sobolev. Para un subconjunto abierto D de $\mathbb{R}^n$, la norma usual de $H^s(D)$ se denota por $\|\cdot\|_{s,D}$. El espacio $H_0^1(D)$ es el subespacio de funciones en $H^1(D)$ con traza nula en ∂D. La letra C representa una constante genérica, independiente de los parámetros de discretización.

7.1. El obstáculo

7.1.1. Formulación fuerte

Este enfoque clásico del problema del obstáculo presenta la formulación en términos de ecuaciones diferenciales parciales y condiciones de contorno.

7.1.2. Desigualdad variacional

Las desigualdades variacionales proporcionan un marco general para estudiar problemas con restricciones, como el del obstáculo. Este planteamiento permite modelar fenómenos físicos donde las soluciones deben satisfacer condiciones de desigualdad en lugar de igualdades. La teoría de desigualdades variacionales es fundamental para entender la estructura matemática del problema.

7.1.3. Existencia y unicidad

El estudio de la existencia y unicidad de soluciones es crucial para garantizar la validez de los modelos matemáticos. En el caso del obstáculo, se demuestra que, bajo condiciones adecuadas, existe una solución única que satisface las restricciones físicas del problema. Este análisis sienta las bases para el desarrollo de métodos numéricos confiables.

7.1.4. Aproximación de Galerkin

La aproximación de Galerkin es un método numérico ampliamente utilizado para resolver problemas descritos por desigualdades variacionales. Este enfoque permite discretizar el problema y transformarlo en un sistema algebraico resoluble. Su simplicidad y eficacia lo convierten en una herramienta estándar en el análisis numérico.

7.1.5. Penalización

El método de penalización reemplaza las restricciones del problema original por términos en la función objetivo. Este enfoque simplifica la implementación numérica y permite aplicar técnicas estándar de resolución. Sin embargo, la elección del parámetro de penalización es clave para la estabilidad y precisión del método.

7.1.6. Newton semi-suave

El método de Newton semi-suave es una técnica avanzada para resolver problemas de desigualdades variacionales, combinando ideas de métodos de Newton y subgradientes. Este enfoque aprovecha la estructura diferenciable a trozos de las funciones involucradas, mejorando la convergencia en problemas no lineales. Su aplicación es especialmente relevante en contextos donde la solución puede presentar comportamientos complejos.

7.1.7. Implementación en scikit-fem

scikit-fem es una biblioteca de Python que facilita la implementación de métodos de elementos finitos para resolver problemas variacionales. Su integración con NumPy y SciPy permite desarrollar soluciones eficientes y modulares. Esta herramienta es ideal para prototipar y validar algoritmos numéricos en entornos académicos y de investigación. Veamos el listado siguiente, escrito por Lucas Curci.

```
"""Diferenciación automática.
Utiliza diferenciación automática para derivar el sistema tangente
para el método de Newton.
"""

from skfem import *
from skfem.autodiff import NonlinearForm
from skfem.autodiff.helpers import grad, dot
import numpy as np
import jax.numpy as jnp

m = MeshTri().refined(5)

@NonlinearForm(hessian=True)
def J(u, _):
    eps = 1e-2
    return (1/2 * dot(grad(u), grad(u)) - u
            + (1 / eps) * ((u - jnp.minimum(u.value, 0.01))**2))

basis = Basis(m, ElementTriP1())

D = m.boundary_nodes()
x = np.zeros(basis.N)

for itr in range(100):
    x_prev = x.copy()
    x += solve(*condense(*J.assemble(basis, x=x), D=D))
    res = np.linalg.norm(x - x_prev)
    if res < 1e-8:
        break
    if __name__ == "__main__":
        print(res)
```

```python

if __name__ == "__main__":
    from skfem.visuals.matplotlib import plot3, show
    plot3(m, x)
    show()
```

Listado 7.1: Diferenciación automática con scikit-fem

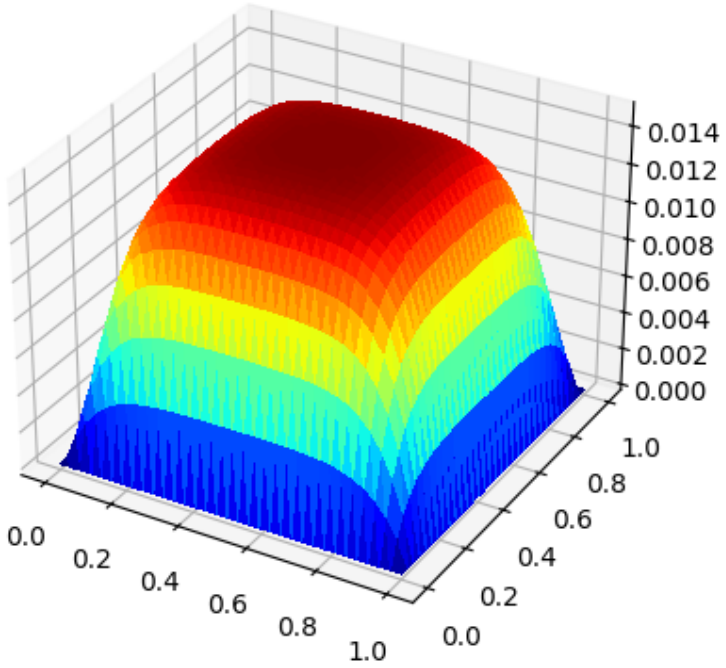

Figura 7.1: Solución del obstáculo penalizado con scikit-fem

7.1.8. Comentarios adicionales

- **Método de Nitsche o multiplicadores**: Estas técnicas alternativas permiten incorporar las restricciones del problema de manera explícita en la formulación débil, mejorando la estabilidad numérica en ciertos casos. El método de Nitsche, en particular, ofrece una forma elegante de manejar las condiciones de desigualdad.

- **Aplicaciones**: El problema del obstáculo tiene aplicaciones en mecánica de sólidos, fluidos, finanzas y otras áreas de la ciencia e ingeniería. Su versatilidad lo convierte en un modelo fundamental para estudiar fenómenos con restricciones geométricas o físicas.

Capítulo 8
Control óptimo

El control óptimo es una rama de las matemáticas aplicadas que se ocupa de determinar la mejor manera de influir sobre la evolución de un sistema dinámico con el fin de optimizar un cierto criterio. Este tipo de problemas aparece de forma natural en numerosos campos, como la ingeniería, la economía, la biología o la física, donde se busca tomar decisiones que conduzcan a un comportamiento deseado del sistema.

En el contexto de las ecuaciones diferenciales, un sistema dinámico se describe mediante una relación que vincula la evolución temporal del estado con ciertas variables de control. Estas variables representan las acciones que pueden ser ajustadas para modificar la trayectoria del sistema. El objetivo consiste entonces en seleccionar dichas variables de control de manera que se minimice o maximice una cantidad de interés, como puede ser un costo, una energía o un rendimiento.

Una característica fundamental de los problemas de control óptimo es la interacción entre la dinámica del sistema y el criterio de optimización. Esta interacción da lugar a una estructura matemática rica y compleja, en la que las soluciones deben satisfacer simultáneamente restricciones dinámicas y condiciones de optimalidad. A diferencia de los problemas de optimización estática, aquí las decisiones se distribuyen a lo largo del tiempo, lo que introduce una dimensión adicional de dificultad.

Entre los resultados más influyentes en este campo se encuentra el principio del máximo de Pontryaguin. Este principio proporciona una caracterización necesaria de las soluciones óptimas y constituye una herramienta central en el análisis teórico del control óptimo. Su importancia radica en que transforma un problema global de optimización en una condición local que debe cumplirse a lo largo de la trayectoria óptima.

De manera conceptual, el principio de Pontryaguin introduce variables auxiliares que permiten evaluar la sensibilidad del criterio de optimización frente a variaciones en el estado del sistema. Estas variables, junto

con el estado y el control, forman un conjunto ampliado cuya evolución está gobernada por un sistema acoplado. La condición de optimalidad se expresa entonces mediante un principio de tipo variacional que selecciona, en cada instante, los controles que resultan más favorables.

Este enfoque ha tenido un impacto profundo tanto en el desarrollo teórico como en las aplicaciones del control óptimo. Ha permitido el diseño de métodos numéricos, el análisis de propiedades cualitativas de las soluciones y la formulación de estrategias de control en problemas reales. Además, ha servido como base para desarrollos posteriores, como la programación dinámica y las formulaciones en términos de ecuaciones en derivadas parciales.

En resumen, el control óptimo proporciona un marco matemático poderoso para la toma de decisiones en sistemas dinámicos, y el principio de Pontryaguin constituye una de sus piedras angulares. Su estudio continúa siendo un área activa de investigación, motivada tanto por desafíos teóricos como por aplicaciones cada vez más complejas.

Capítulo 9
Conclusión y perspectivas

Para concluir nuestra breve introducción, damos unas sugerencias que permitirán al lector ir más allá en el tema y/o descubrir otros campos relacionados.

9.1. Optimización matemática

El análisis convexo es fundamental en la teoría de la optimización, especialmente en problemas de programación matemática. Las funciones convexas y los conjuntos convexos permiten modelar y resolver problemas de minimización o maximización con restricciones, garantizando la existencia de soluciones globales óptimas. Por ejemplo, en **programación convexa**, se minimiza una función convexa sobre un conjunto convexo, lo que asegura convergencia a soluciones globales.

$$\begin{aligned} &\text{Minimizar } f(x) \\ &\quad \text{Sujeto a } g_i(x) \leq 0, \quad i = 1, \ldots, m \\ &\qquad\qquad\quad h_j(x) = 0, \quad j = 1, \ldots, p, \end{aligned}$$

donde f es convexa y g_i, h_j son funciones convexas.

9.2. Control y sistemas dinámicos

En teoría de control, el análisis convexo se aplica para estabilizar sistemas dinámicos y diseñar controladores robustos. Los **conos tangentes** y las **funciones de Lyapunov convexas** son herramientas clave para analizar la estabilidad asintótica y diseñar estrategias de control óptimo.

9.3. Aprendizaje Automático

En aprendizaje automático, el análisis convexo es esencial en algoritmos como **Support Vector Machines (SVM)** y **regresión logística**. Las SVM, por ejemplo, buscan el hiperplano que maximice el margen entre clases, lo que se formula como un problema de optimización convexa. La convexidad garantiza que el algoritmo encuentre la solución globalmente óptima.

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{sujeto a} \quad y_i(w \cdot x_i + b) \geq 1 \quad \forall i.$$

9.4. Economía y finanzas

En economía, el análisis convexo se utiliza para modelar preferencias de agentes económicos, funciones de producción y problemas de equilibrio general. Por ejemplo, las **funciones de utilidad cuasi-convexas** permiten analizar decisiones bajo incertidumbre, mientras que la convexidad de las funciones de costo es clave en la teoría de la firma.

9.5. Teoría de juegos

En teoría de juegos, los conceptos de convexidad son centrales para analizar equilibrios de Nash en juegos no cooperativos. Las estrategias mixtas y las funciones de pago convexas permiten demostrar la existencia de equilibrios y estudiar su estabilidad.

9.6. Geometría y computación

En geometría computacional, el análisis convexo se aplica en algoritmos de **envueltas convexas** (como el algoritmo de Graham) y en problemas de localización de puntos. La convexidad permite diseñar algoritmos eficientes para encontrar soluciones aproximadas o exactas en conjuntos de datos de alta dimensionalidad.

9.7. Procesamiento de señales e imágenes

En procesamiento de imágenes, técnicas como la **reconstrucción convexa** y la **regularización total variación (TV)** se basan en la convexidad para minimizar artefactos y mejorar la calidad de la imagen. Estas técnicas son fundamentales en tomografía, resonancia magnética y reconstrucción 3D.

9.8. Teoría de la Información

En teoría de la información, las funciones convexas como la **entropía relativa** (o divergencia de Kullback-Leibler) son herramientas esenciales para analizar la capacidad de canales de comunicación y diseñar códigos eficientes.

Referencias bibliográficas

[1] S. Boyd and L. Vandenberghe, *Convex optimization*, Cambridge University Press, 2004.

[2] G. Cantor, *Über unendliche lineare punktmannigfaltigkeiten*, Math. Ann., 20 (1883), pp. 61–74.

[3] G. Duvaut and J.-L. Lions, *Inequalities in mechanics and physics*, Springer-Verlag, 1976.

[4] R. Glowinski, *Lectures on numerical methods for nonlinear variational problems*, Springer-Verlag, 1980.

[5] B. Grünbaum, *Convex polytopes*, Interscience Publishers, 1963.

[6] J.-B. Hiriart-Urruty and C. Lemaréchal, *Fundamentals of convex analysis*, Springer-Verlag, 2001.

[7] D. Kinderlehrer and G. Stampacchia, *An introduction to variational inequalities and their applications*, Academic Press, 1980.

[8] H. Lebesgue, *Leçons sur l'intégration et la recherche des fonctions primitives*, Gauthier-Villars, 1904.

[9] B. B. Mandelbrot, *The Fractal Geometry of Nature*, W. H. Freeman and Company, 1982.

[10] R. T. Rockafellar, *Convex analysis*, Princeton University Press, 1970.

[11] G. Samorodnitsky and M. S. Taqqu, *Stable non-gaussian random processes*, Chapman & Hall, 1994.

[12] T. Takagi, *A simple example of a continuous function without derivative*, Proc. Phys.-Math. Soc. Japan, 1 (1903), pp. 124–125.