

Análisis convexo

Franz Chouly

En Construcción (23 de agosto de 2026)

Tabla de contenido

Agradecimientos	9
1. Introducción	11
2. Descenso de gradiente	13
2.1. Aplicaciones	13
2.1.1. Aprendizaje automático	13
2.1.2. Optimización de forma	14
2.2. Gradiente a paso constante	14
2.2.1. Definición	15
2.2.2. Python	15
2.2.3. Análisis	16
2.3. Otros métodos de minimización	18
2.3.1. Gradiente a paso variable	18
2.3.2. Método del gradiente conjugado	18
2.3.3. Método BiCG	18
2.4. Para profundizar	19
3. Funciones convexas	21
3.1. Contexto	21
3.1.1. Definiciones	21
3.1.2. Algunos ejemplos	22
3.1.3. Existencia de sucesiones minimizantes	23
3.2. Existencia de mínimos globales	23
3.3. Conjuntos y funciones convexas	24
3.3.1. Obstáculo	25
3.4. Funciones convexas y mínimos	27
3.4.1. Mínimos globales	27
3.4.2. Caso fuertemente convexo	29
3.4.3. Caso estrictamente convexo	35
3.5. El caso convexo	37

3.6. Criterios de convexidad con diferencial	44
3.7. Criterios de optimalidad	44
4. Método de Newton	45
4.1. Idea del método	45
4.2. Mas sobre funciones convexas	46
4.2.1. Subdiferencial de funciones convexas	48
4.2.2. Caracterización de mínimos	50
4.3. Newton semi-suave	52
4.4. Restricciones	52
4.4.1. Penalización	52
4.4.2. Lagrangiano	52
4.4.3. Lagrangiano aumentado	52
5. Desigualdades variacionales	53
5.1. Ejemplos	53
5.1.1. Problema de Signorini (contacto unilateral sin fricción)	53
5.1.2. Problema de torsión (Saint-Venant)	54
5.1.3. Problema de Tresca (fricción)	54
5.1.4. Problema de Bingham (fluido visco-plástico)	55
5.1.5. Formulación con forma bilineal no simétrica	55
5.2. Teoría general	56
5.2.1. Teorema de Stampacchia	56
5.2.2. Teorema de Lions-Stampacchia	56
5.3. Galerkin y elementos finitos	56
5.3.1. Penalización	56
5.3.2. Newton semi-suave	57
5.3.3. Implementación en scikit-fem	57
5.3.4. Comentarios adicionales	58
6. Dualidad	59
6.1. Problema primal y problema dual	59
6.1.1. Definiciones	59

7. Perspectivas	61
7.1. Optimización matemática	61
7.2. Control y sistemas dinámicos	61
7.3. Aprendizaje automático	62
7.4. Economía y finanzas	62
7.5. Teoría de juegos	62
7.6. Geometría y computación	62
7.7. Procesamiento de señales e imágenes	63
7.8. Teoría de la información	63
 A. Más sobre conjuntos convexos	 65
A.1. Definición y propiedades	66
A.1.1. Para empezar	66
A.1.2. Interior y clausura de un conjunto convexo	67
A.2. Conos convexos	68
A.2.1. Definición	68
A.2.2. Ejemplos	69
A.2.3. Propiedades principales	70
A.3. Envoltura convexa	70
A.3.1. Caracterización	70
A.3.2. Técnicas para calcular la envoltura convexa . . .	71
A.3.3. Algoritmo de Graham Scan	72
A.3.4. Algoritmo QuickHull	75
A.3.5. Aplicaciones	77
A.4. Separación de convexos	77
A.5. Para profundizar	77
 B. Funciones convexas en dimensión finita	 79
B.1. Caso general	79
B.1.1. Definición, ejemplos y propiedades	79
B.1.2. Propiedades de continuidad	83
B.1.3. Subdiferencial de funciones convexas	85
B.1.4. Caracterización de mínimos	87
B.2. Existencia de mínimo	89
B.3. Caso diferenciable	89

C. Más métodos	91
C.1. Método de penalización	91
C.2. Método de Lagrange	91
C.3. Método de Lagrange aumentado	91
C.3.1. Definición	91
C.3.2. Algoritmo	92
C.3.3. Ejemplo	93
C.4. Métodos cuasi-Newton (BFGS)	93
D. Medida y análisis funcional	95
D.1. Medida	95
D.2. Medida y funciones	96
D.2.1. Funciones BV	96
D.2.2. Continuidad absoluta	96
D.2.3. Teorema de aproximación de Lebesgue	97
D.2.4. Teorema de Lebesgue	97
D.2.5. Teorema de Rademacher	98
D.2.6. Resumen de Relaciones entre Propiedades	98
D.3. Hahn–Banach	99
D.4. Espacios de Hilbert	99
D.5. Espacios de Lebesgue	99
D.6. Derivada débil	100
D.7. Espacios de Sobolev	100
D.8. Ejemplos	100
D.8.1. Generales	100
D.8.2. Indicador	101
D.9. Más espacios funcionales	102
D.9.1. Espacios de Sobolev $H^s(\mathbb{R})$	102
D.9.2. Espacios de Besov $\mathcal{B}_{p,q}^s(\mathbb{R})$	103
D.9.3. Exponente de Hölder	103
D.10. Fractales	103
D.10.1. Función de Weierstrass	103
D.10.2. Función de Takagi	104
D.10.3. Movimiento browniano fraccionario	104
D.10.4. Conjunto de Cantor	105
D.10.5. Función de Cantor-Lebesgue	105

D.11. Ecuaciones elípticas	105
E. Ejemplos para minimizar con descenso de gradiente	107
E.1. Ridge	107
E.1.1. Contexto	107
E.1.2. Funcional	107
E.1.3. Propiedades	108
E.1.4. Ejemplo	108
E.2. Energía potencial de un sistema de resortes	108
E.2.1. Contexto	108
E.2.2. Funcional	108
E.2.3. Propiedades	108
E.2.4. Ejemplo	109
E.3. Optimización de forma	109
E.3.1. Contexto	109
E.3.2. Funcional	109
E.3.3. Penalización	109
E.3.4. Ejemplo	109
E.4. Aprendizaje automático	110
E.4.1. Contexto	110
E.4.2. Funcional	110
E.4.3. Propiedades	110
E.4.4. Ejemplo	110
Referencias bibliográficas	111

Agradecimientos

Agradezco al CMAT. También por sus consejos: Dominique Attali, Juan Pablo Borthagaray, Lucas Curci, Françoise Dal'Bo, Jean-Baptiste Hiriart Urruty, Mauricio Velasco.

Capítulo 1

Introducción

El análisis convexo es una rama fundamental de las matemáticas que estudia funciones y conjuntos convexos, ofreciendo herramientas teóricas y prácticas para resolver problemas complejos en ciencia, ingeniería y economía. Este libro aborda desde los fundamentos matemáticos del análisis convexo hasta sus aplicaciones más avanzadas, incluyendo desigualdades variacionales, optimización convexa, aprendizaje automático e inteligencia artificial, geometría algorítmica y teoría de juegos.

Se presentan las definiciones y propiedades esenciales de conjuntos y funciones convexas, junto con conceptos clave como el subgradiente, la cáscara convexa y la dualidad. Estos fundamentos son la base para entender algoritmos de optimización y técnicas numéricas que se desarrollan en varios capítulos.

Para el desarrollo de este trabajo, nos apoyaremos fundamentalmente en las obras de G. Allaire [1], de S. Boyd and L. Vandenberghe [3], de J.-B. Hiriart-Urruty and C. Lemaréchal [10] y D. G. Luenberger [13]. A partir de ahora, utilizaremos la notación V para designar un espacio de Hilbert (espacio vectorial normado completo). Notaremos $(\cdot, \cdot)_V$ el producto interno de V y $\|\cdot\|_V$ la norma asociada. Cuando V sea de dimensión finita, y cuando se precisa, lo denotaremos por V_n , donde n indica la dimensión de V .

Capítulo 2

Descenso de gradiente

El descenso de gradiente es un algoritmo iterativo de optimización de primer orden utilizado para minimizar funciones. Su idea central es moverse en la dirección opuesta al gradiente de la función en el punto actual, lo que garantiza una disminución local del valor de la función. Este método es ampliamente aplicado en aprendizaje automático y optimización numérica debido a su simplicidad y eficacia. La elección del tamaño de paso, o tasa de aprendizaje, es crucial para la convergencia del algoritmo. Sin embargo, su rendimiento puede verse afectado por la elección de parámetros y la geometría de la función. Seguimos [1].

2.1. Aplicaciones

Antes de describir el algoritmo y hacer su análisis, presentemos ya algunas aplicaciones donde es relevante.

2.1.1. Aprendizaje automático

En aprendizaje automático, la regresión Ridge busca minimizar el error cuadrático entre las predicciones de un modelo lineal y los datos reales, añadiendo un término de regularización para evitar el sobreajuste.

Dada una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$, un vector de etiquetas $\mathbf{y} \in \mathbb{R}^n$, y un vector de pesos $\mathbf{w} \in \mathbb{R}^d$, la funcional a minimizar es:

$$\mathcal{J}(\mathbf{w}) := \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_V^2 + \varepsilon \|\mathbf{w}\|_V^2$$

donde $\varepsilon > 0$ es el parámetro de regularización, y

$$\|\mathbf{y}\|_V^2 := y_1^2 + \cdots + y_n^2, \quad \|\mathbf{w}\|_V^2 := w_1^2 + \cdots + w_d^2.$$

Aquí tenemos $V = V_d = \mathbb{R}^d$, con la norma Euclidiana.

2.1.2. Optimización de forma

Ahora presentamos un problema simplificado de optimización de forma. Se buscan las coordenadas de los vértices de un triángulo que maximice su área, sujetas a una restricción de perímetro fijo. Para un triángulo con vértices

$$\mathbf{p}_1 = (x_1, y_1), \quad \mathbf{p}_2 = (x_2, y_2), \quad \mathbf{p}_3 = (x_3, y_3),$$

y un perímetro $\mathcal{P}$ fijo:

- **Área** (a maximizar):

$$\mathcal{A}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) := \frac{1}{2} |(\mathbf{p}_2 - \mathbf{p}_1) \times (\mathbf{p}_3 - \mathbf{p}_1)|,$$

donde $\times$ es el producto vectorial en dos dimensiones.

- **Restricción:**

$$\mathcal{R}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = 0$$

con

$$\mathcal{R}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = \|\mathbf{p}_2 - \mathbf{p}_1\|_{\mathbb{R}^2} + \|\mathbf{p}_3 - \mathbf{p}_2\|_{\mathbb{R}^2} + \|\mathbf{p}_1 - \mathbf{p}_3\|_{\mathbb{R}^2} - \mathcal{P}.$$

Para transformar el problema restringido en uno no restringido, se usa, por ejemplo:

$$\mathcal{J}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = -\mathcal{A}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) + \frac{1}{\varepsilon} (\mathcal{R}(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3))^2$$

a minimizar en $V_6 = \mathbb{R}^6$, y donde $\varepsilon > 0$ es un parámetro de penalización.

2.2. Gradiente a paso constante

Sea $V = V_n = \mathbb{R}^n$ y

$$\mathcal{J} : V \rightarrow \mathbb{R}$$

una función $\mathcal{C}^1(V; \mathbb{R})$. Notamos $\nabla \mathcal{J}$ su gradiente:

$$\nabla \mathcal{J} : \mathbb{R}^n \rightarrow \mathbb{R}^n.$$

El objetivo es encontrar un mínimo de esta función.

2.2.1. Definición

El método de descenso de gradiente a paso constante se define como:

$$x_{k+1} = x_k - \alpha \nabla \mathcal{J}(x_k) \quad (2.1)$$

con $k \geq 0$, a partir de $x_0 \in V$ y donde:

- x_k es la posición actual en la iteración k ,
- α es el tamaño del paso (constante),
- $\nabla \mathcal{J}(x_k)$ es el gradiente de la función $\mathcal{J}$ evaluado en x_k .

2.2.2. Python

```
1 import numpy as np
2
3 def J(x):
4     return x*2 + 2*x + 1
5
6 def dJ(x):
7     return 2*x + 2
8
9 def gradient_descent(alpha, x0, max_iter=1000):
10     x = x0
11     for _ in range(max_iter):
12         grad = dJ(x)
13         x = x - alpha * grad
14     return x
15
16 # Ejemplo de uso
17
18 alpha = 0.1
19 x0 = 5.0
20 x_min = gradient_descent(alpha, x0)
21 print(f"Mínimo encontrado en x = {x_min:.4f}")
```

Listado 2.1: Gradiente a paso constante.

2.2.3. Análisis

Supongamos, para simplificar, que $\mathcal{J}$ cumple las siguientes condiciones:

1. Existe un único mínimo estricto global de $\mathcal{J}$.
2. $\mathcal{J}$ es de clase $\mathcal{C}^2(V; \mathbb{R})$ (continuamente diferenciable en V).
3. Existe una constante $c_{\mathcal{J}} > 0$ tal que, para todo $x, y \in V$:

$$(\nabla \mathcal{J}(x) - \nabla \mathcal{J}(y), x - y)_V \geq c_{\mathcal{J}} \|x - y\|_V^2. \quad (2.2)$$

De hecho, veremos luego que 2 y 3 implican 1. Entonces, tenemos lo siguiente:

Teorema 1. *Sea $\mathcal{J} : V \rightarrow \mathbb{R}$ una función de clase que cumple con las condiciones 1, 2 y 3 anteriores. Sea x^* el único mínimo estricto global de $\mathcal{J}$. Entonces, si $\alpha > 0$ es suficientemente pequeño, el método de gradiente descendente:*

$$x_{k+1} = x_k - \alpha \nabla \mathcal{J}(x_k),$$

converge hacia x^ .*

Demostración. Sea $x_0 \in V$ y $B_0 \subset V$ una bola cerrada y acotada que contiene x^* y x_0 , centrada en x^* . Supongamos $x_k \in B_0$. Ahora, consideremos la iteración del gradiente descendente:

$$x_{k+1} = x_k - \alpha \nabla \mathcal{J}(x_k).$$

Queremos analizar $\|x_{k+1} - x^*\|^2$. Desarrollamos:

$$\|x_{k+1} - x^*\|_V^2 = \|x_k - \alpha \nabla \mathcal{J}(x_k) - x^*\|_V^2$$

y luego

$$\|x_{k+1} - x^*\|_V^2 = \|x_k - x^*\|_V^2 - 2\alpha(x_k - x^*, \nabla \mathcal{J}(x_k))_V + \alpha^2 \|\nabla \mathcal{J}(x_k)\|_V^2.$$

Veamos primero:

$$(x_k - x^*, \nabla \mathcal{J}(x_k))_V = (x_k - x^*, \nabla \mathcal{J}(x_k) - \nabla \mathcal{J}(x^*))_V \geq c_{\mathcal{J}} \|x_{k+1} - x^*\|_V^2.$$

Hemos utilizado $\nabla \mathcal{J}(x^*) = 0$ y (2.2). Esto implica

$$-2\alpha(x_k - x^*, \nabla \mathcal{J}(x_k))_V \leq -2\alpha c_{\mathcal{J}} \|x_{k+1} - x^*\|_V^2.$$

Además, como $\mathcal{J}$ es de clase $\mathcal{C}^2(B; \mathbb{R}^d)$, en B_0 , acotada y cerrada, entonces $\nabla \mathcal{J}$ es Lipschitz en B_0 . Existe $L > 0$ tal que:

$$\|\nabla J(x_k)\|_V \leq L \|x_k - x^*\|_V.$$

Por lo tanto:

$$\alpha^2 \|\nabla J(x_k)\|_V^2 \leq \alpha^2 L^2 \|x_k - x^*\|_V^2.$$

Sustituyendo todo en la desigualdad:

$$\|x_{k+1} - x^*\|_V^2 \leq \|x_k - x^*\|_V^2 - 2\alpha c_{\mathcal{J}} \|x_k - x^*\|_V^2 + \alpha^2 L^2 \|x_k - x^*\|_V^2.$$

Simplificando:

$$\|x_{k+1} - x^*\|_V^2 \leq (1 - 2\alpha c_{\mathcal{J}} + \alpha^2 L^2) \|x_k - x^*\|_V^2.$$

Elegimos α tal que:

$$1 - 2\alpha c_{\mathcal{J}} + \alpha^2 L^2 < 1.$$

Esto se cumple si:

$$-2\alpha c_{\mathcal{J}} + \alpha^2 L^2 < 0 \quad \Rightarrow \quad 2\alpha c_{\mathcal{J}} > \alpha^2 L^2.$$

La desigualdad se satisface si:

$$\alpha < \frac{2c_{\mathcal{J}}}{L^2}.$$

Por lo tanto, para α suficientemente pequeño, existe $\rho \in (0, 1)$ tal que:

$$\|x_{k+1} - x^*\|_V^2 \leq \rho \|x_k - x^*\|_V^2.$$

Verificamos que x_{k+1} queda en B_0 . Esto implica que la secuencia $\{x_k\}$ converge linealmente hacia x^* . $\square$

2.3. Otros métodos de minimización

Mencionamos brevemente otros métodos de minimización que se basan únicamente en el cálculo del gradiente, como el *método del gradiente con paso variable* y el *método del gradiente conjugado*. Para más detalles, referirse a [1, 6].

2.3.1. Gradiente a paso variable

En el método de *descenso de gradiente a paso variable*, el tamaño del paso α_k puede cambiar en cada iteración. Una estrategia común es usar una *búsqueda de línea* (line search) para elegir α_k que minimice $\mathcal{J}(x_k - \alpha_k \nabla \mathcal{J}(x_k))$. La actualización se escribe como:

$$x_{k+1} = x_k - \alpha_k \nabla \mathcal{J}(x_k).$$

2.3.2. Método del gradiente conjugado

En el método del *gradiente conjugado*, se optimiza la minimización de funciones cuadráticas de la forma $\mathcal{J}(x) = \frac{1}{2}x^T A x - \mathbf{b}^T x + c$, donde A es una matriz simétrica y definida positiva. Este método acelera la convergencia del descenso de gradiente al utilizar direcciones conjugadas con respecto a A . La actualización se escribe como:

$$x_{k+1} = x_k + \alpha_k d_k,$$

donde d_k es la dirección conjugada y α_k se elige mediante una búsqueda de línea o fórmula analítica [6, Chapter 11].

2.3.3. Método BiCG

El método *BiCG* (Biconjugate Gradient) está adaptado para resolver sistemas lineales no simétricos de la forma $Ax = b$ [6, S. 11.7.8], donde A es una matriz cuadrada no necesariamente simétrica. Es una extensión del gradiente conjugado para matrices no simétricas. La actualización se basa en residuos biconjugados y se escribe como:

$$x_{k+1} = x_k + \alpha_k p_k,$$

donde p_k es la dirección de búsqueda y α_k se calcula para minimizar el error en un subespacio de Krylov.

2.4. Para profundizar

Para un análisis más detallado sobre los métodos de descenso de gradiente y sus variantes, se puede consultar [6, Capítulo 11] y [1, Capítulos 8–9].

Capítulo 3

Funciones convexas

Las funciones convexas juegan un papel fundamental en optimización, ya que garantizan que cualquier mínimo local es también un mínimo global. Una función $\mathcal{J} : V \rightarrow \mathbb{R}$ es convexa si el segmento de línea que une cualquier par de puntos en su gráfico siempre queda por encima del gráfico. Esta propiedad simplifica significativamente el análisis y la resolución de problemas de optimización. Además, las funciones convexas tienen derivadas monótonas, lo que facilita la aplicación de métodos numéricos. Su estudio es esencial para entender la eficiencia de algoritmos como el descenso de gradiente.

3.1. Contexto

Consideramos el problema de minimización de una función objetivo $\mathcal{J}$ sobre un conjunto $K \subseteq V$, donde V es un espacio de Hilbert. El objetivo es encontrar el **ínfimo** de J en K y, en caso de existir, un punto donde este ínfimo se alcance. El problema se formula como:

$$\inf_K \mathcal{J}. \quad (3.1)$$

3.1.1. Definiciones

Definición 1 (Ínfimo). *Dado un conjunto $K \subseteq V$ y una función $\mathcal{J} : K \rightarrow \mathbb{R}$, el ínfimo de J sobre K se define como:*

$$\inf_{v \in K} \mathcal{J}(v) = \inf\{\mathcal{J}(v) \mid v \in K\}.$$

Es el mayor de las cotas inferiores de $\mathcal{J}$ en K . No necesariamente existe un punto $v \in K$ tal que $J(v) = \inf_{v \in K} \mathcal{J}(v)$.

Definición 2 (Punto de mínimo local). *Un punto $u^* \in K$ es un mínimo local de $\mathcal{J}$ en K si existe $\delta > 0$ tal que:*

$$\mathcal{J}(u^*) \leq \mathcal{J}(v) \quad \forall v \in K \text{ con } \|v - u^*\| < \delta.$$

Definición 3 (Punto de mínimo global). *Un punto $u^* \in K$ es un mínimo global de $\mathcal{J}$ en K si:*

$$\mathcal{J}(u^*) \leq \mathcal{J}(v) \quad \forall v \in K.$$

Definición 4 (Sucesión minimizante). *Una sucesión $\{u_n\}_{n \in \mathbb{N}} \subseteq K$ se dice **minimizante** para $\mathcal{J}$ si:*

$$\lim_{n \rightarrow \infty} \mathcal{J}(u_n) = \inf_{u \in K} \mathcal{J}(u).$$

3.1.2. Algunos ejemplos

Ejemplo 1. *Consideremos $V = \mathbb{R}$, $K = \mathbb{R}$, y $\mathcal{J}(v) = v^2$.*

Entonces:

$$\inf_{v \in \mathbb{R}} \mathcal{J}(v) = 0,$$

y el mínimo global se alcanza en $u^ = 0$. La sucesión $u_n = 1/n$ es minimizante, ya que:*

$$\mathcal{J}(u_n) = \left(\frac{1}{n}\right)^2 \rightarrow 0 = \inf_{v \in \mathbb{R}} \mathcal{J}(v).$$

Ejemplo 2. *Sea $K = [0, +\infty)$ y $\mathcal{J}(v) = e^{-v}$.*

Entonces:

$$\inf_{v \in K} \mathcal{J}(v) = 0,$$

pero no existe $u^ \in K$ tal que $\mathcal{J}(u^*) = 0$. Sin embargo, la sucesión $u_n = n$ es minimizante, pues:*

$$\mathcal{J}(u_n) = e^{-n} \rightarrow 0.$$

3.1.3. Existencia de sucesiones minimizantes

La proposición siguiente se establece directamente a partir de la definición del ínfimo.

Proposición 1. *Para cualquier función $\mathcal{J} : K \rightarrow \mathbb{R}$, siempre existe una sucesión minimizante $\{u_n\}_{n \in \mathbb{N}} \subseteq K$ tal que:*

$$\lim_{n \rightarrow \infty} \mathcal{J}(u_n) = \inf_{v \in K} \mathcal{J}(v).$$

3.2. Existencia de mínimos globales

Retomamos este resultado general y simple de [1].

Teorema 2. *Sea V un espacio vectorial normado de dimensión finita, $K \subseteq V$ un conjunto cerrado y no vacío, y $\mathcal{J} : K \rightarrow \mathbb{R}$ una función continua sobre K . Supongamos además que:*

$$\text{Si } \{u_n\} \subseteq K \text{ es tal que } \|u_n\| \rightarrow +\infty, \text{ entonces } \mathcal{J}(u_n) \rightarrow +\infty. \quad (3.2)$$

Entonces, la función $\mathcal{J} : K \rightarrow \mathbb{R}$ admite al menos un punto de mínimo global en K .

Demostración. Es un baile en cinco pasos.

Paso 1. Existencia del ínfimo. Como $\mathcal{J}$ está acotada inferiormente (por continuidad y por la condición (3.2)), existe:

$$m = \inf_{v \in K} \mathcal{J}(v) \in \mathbb{R}.$$

Paso 2. Existencia de una sucesión minimizante. Por la Proposición anterior, para todo $n \in \mathbb{N}$, existe $u_n \in K$ tal que:

$$\lim_{n \rightarrow \infty} \mathcal{J}(u_n) = m.$$

Paso 3. Acotación de la sucesión minimizante. Supongamos que $\{u_n\}$ no estuviera acotada en V . Entonces, existiría una subsucesión $\{u_{n_k}\}$ tal que $\|u_{n_k}\|_V \rightarrow +\infty$. Por hipótesis (3.2), esto implicaría que:

$$\mathcal{J}(u_{n_k}) \rightarrow +\infty,$$

lo cual contradice que $\mathcal{J}(u_{n_k}) \rightarrow m$. Por lo tanto, $\{u_n\}$ está acotada en V .

Paso 4. Compacidad en dimensión finita. En un espacio de dimensión finita, toda sucesión acotada tiene una subsucesión convergente. Sea $\{u_{n_k}\}$ una subsucesión de $\{u_n\}$ tal que $u_{n_k} \rightarrow u^* \in V$. Como K es cerrado, $u^* \in K$.

Paso 5. Continuidad de $\mathcal{J}$. Por la continuidad de $\mathcal{J}$, se tiene: $\mathcal{J}(u^*) = \lim_{k \rightarrow \infty} \mathcal{J}(u_{n_k}) = m$. Por lo tanto, u^* es un punto de mínimo global de J en K . $\square$

El teorema anterior no se extiende en dimensión infinita [1]. Tampoco asegura unicidad. Esto motiva la introducción de los siguientes conceptos.

3.3. Conjuntos y funciones convexas

Definición 5. Un conjunto $K \subset V$ es convexo si para todo $v, w \in K$ y todo $\lambda \in [0, 1]$, se cumple:

$$\lambda v + (1 - \lambda)w \in K. \quad (3.3)$$

Definición 6. Una función $\mathcal{J} : V \rightarrow \mathbb{R}$ es convexa si para todo $v, w \in V$ y todo $\lambda \in [0, 1]$, se cumple:

$$\mathcal{J}(\lambda v + (1 - \lambda)w) \leq \lambda \mathcal{J}(v) + (1 - \lambda)\mathcal{J}(w). \quad (3.4)$$

Es convexa estricta, si, cuando $\lambda \in (0, 1)$, se cumple:

$$\mathcal{J}(\lambda v + (1 - \lambda)w) < \lambda \mathcal{J}(v) + (1 - \lambda)\mathcal{J}(w). \quad (3.5)$$

Definición 7. Una función $\mathcal{J} : V \rightarrow \mathbb{R}$ es convexa fuerte, si existe $c_{\mathcal{J}} > 0$ tal que para todo $v, w \in V$, se cumple:

$$\mathcal{J}\left(\frac{1}{2}v + \frac{1}{2}w\right) \leq \frac{1}{2}(\mathcal{J}(v) + \mathcal{J}(w)) - \frac{c_{\mathcal{J}}}{8}\|v - w\|_V^2. \quad (3.6)$$

Ejemplo 3. Sea $V = L^2([0, 1])$ el espacio de Hilbert de funciones cuadrado-integrables en $[0, 1]$. La función

$$\mathcal{J}(v) := \int_0^1 |v(x)|^2 dx$$

es convexa en V .

3.3.1. Obstáculo

Recordamos aquí la formulación del problema de obstáculo, descrito con mayor detalle en, por ejemplo, [9]. Sea $\Omega \subset \mathbb{R}^n$, con $n \geq 1$, un dominio abierto, acotado, poliedro, simplemente conexo y con frontera de Lipschitz. Sea κ un parámetro físico (por ejemplo, la rigidez de una membrana).

Sea $H_0^1(\Omega)$ el espacio de Sobolev usual [1]. Definimos la forma bilineal:

$$a : H_0^1(\Omega) \times H_0^1(\Omega) \rightarrow \mathbb{R}$$

dada por:

$$a(u, v) := \int_{\Omega} \kappa \nabla u(x) \cdot \nabla v(x) dx, \quad \forall u, v \in H_0^1(\Omega).$$

Asimismo, definimos la forma lineal:

$$L(v) := \int_{\Omega} f v dx, \quad \forall v \in H_0^1(\Omega),$$

donde $f \in L^2(\Omega)$ es un término fuente.

Consideramos una función de obstáculo dada $\Psi : \Omega \rightarrow \mathbb{R}$, que cumple $\Psi \in H^2(\Omega)$ y $\Psi \geq 0$ en $\partial\Omega$.

El problema de minimización asociado consiste en encontrar $u \in K$ tal que: $\min_{v \in K} \mathcal{J}(v)$, donde $\mathcal{J}$ es la funcional cuadrática definida como:

$$\mathcal{J}(v) := \frac{1}{2}a(v, v) - L(v),$$

y el conjunto convexo K se define como:

$$K := \{v \in H_0^1(\Omega) \mid v \geq \Psi \text{ c.p.p. en } \Omega\}.$$

Ahora sea la funcional (general) cuadrática: $\mathcal{J}(v) = \frac{1}{2}a(v, v) - L(v)$, donde a es una forma bilineal elíptica (es decir, existe $c_J > 0$ tal que $a(v, v) \geq c_J \|v\|_V^2$ para todo $v \in V (= H_0^1(\Omega))$).

Para demostrar que $\mathcal{J}$ es fuertemente convexa, verificamos la siguiente desigualdad para todo $u, v \in H_0^1(\Omega)$:

$$\mathcal{J}\left(\frac{u+v}{2}\right) + \frac{c_J}{8}\|u-v\|^2 \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v).$$

Desarrollo de $\mathcal{J}\left(\frac{u+v}{2}\right)^{**}$:

$$\mathcal{J}\left(\frac{u+v}{2}\right) = \frac{1}{2}a\left(\frac{u+v}{2}, \frac{u+v}{2}\right) - L\left(\frac{u+v}{2}\right).$$

Usando la bilinealidad y la simetría de a :

$$a\left(\frac{u+v}{2}, \frac{u+v}{2}\right) = \frac{1}{4}a(u+v, u+v) = \frac{1}{4}(a(u, u) + 2a(u, v) + a(v, v)).$$

Por lo tanto:

$$\mathcal{J}\left(\frac{u+v}{2}\right) = \frac{1}{8}(a(u, u) + 2a(u, v) + a(v, v)) - \frac{1}{2}L(u+v).$$

Combinación convexa de $\mathcal{J}(u)$ y $\mathcal{J}(v)$:

$$\frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) = \frac{1}{2}\left(\frac{1}{2}a(u, u) - L(u)\right) + \frac{1}{2}\left(\frac{1}{2}a(v, v) - L(v)\right)$$

y luego

$$\frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) = \frac{1}{4}(a(u, u) + a(v, v)) - \frac{1}{2}L(u+v).$$

Diferencia entre la combinación convexa y $\mathcal{J}\left(\frac{u+v}{2}\right)$:

$$\frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \mathcal{J}\left(\frac{u+v}{2}\right) = \frac{1}{8}(a(u, u) - 2a(u, v) + a(v, v))$$

y

$$\frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \mathcal{J}\left(\frac{u+v}{2}\right) = \frac{1}{8}a(u-v, u-v).$$

Por la elipticidad de a , sabemos que:

$$a(u-v, u-v) \geq c_J\|u-v\|_V^2.$$

Por lo tanto:

$$\frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \mathcal{J}\left(\frac{u+v}{2}\right) \geq \frac{c_J}{8}\|u-v\|^2.$$

Reordenando:

$$\mathcal{J}\left(\frac{u+v}{2}\right) \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \frac{c_J}{8}\|u-v\|^2.$$

La funcional $\mathcal{J}$ es fuertemente convexa con constante c_J , ya que cumple:

$$\mathcal{J}\left(\frac{u+v}{2}\right) + \frac{c_J}{8}\|u-v\|^2 \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v).$$

3.4. Funciones convexas y mínimos

Los siguientes resultados son adaptados de [1].

3.4.1. Mínimos globales

Teorema 3. *Si $\mathcal{J}$ es convexa, entonces todo mínimo local es un mínimo global. Además, el conjunto de mínimos de $\mathcal{J}$ es convexo.*

Demostración. Sea u^* un mínimo local de $\mathcal{J}$, es decir, existe $\delta > 0$ tal que:

$$\mathcal{J}(u^*) \leq \mathcal{J}(u) \quad \forall u \in K \text{ con } \|u - u^*\|_V < \delta.$$

Queremos demostrar que u^* es un mínimo global, es decir, que:

$$\mathcal{J}(u^*) \leq \mathcal{J}(u) \quad \forall u \in K.$$

Sea $u \in K$ arbitrario. Consideremos la función $f : [0, 1] \rightarrow \mathbb{R}$ definida por:

$$f(t) = \mathcal{J}((1-t)u^* + tu).$$

Como $\mathcal{J}$ es convexa, se tiene:

$$f(t) = \mathcal{J}((1-t)u^* + tu) \leq (1-t)\mathcal{J}(u^*) + t\mathcal{J}(u).$$

Supongamos, por contradicción, que existe $u \in K$ tal que $\mathcal{J}(u) < \mathcal{J}(u^*)$. Entonces, para todo $t \in (0, 1)$:

$$f(t) \leq (1-t)\mathcal{J}(u^*) + t\mathcal{J}(u) < (1-t)\mathcal{J}(u^*) + t\mathcal{J}(u^*) = \mathcal{J}(u^*).$$

Pero como u^* es un mínimo local, existe $\delta > 0$ tal que para todo t suficientemente pequeño (por ejemplo, $t < \delta/\|u - u^*\|_V$), se cumple:

$$f(t) \geq \mathcal{J}(u^*).$$

Esto es una contradicción, ya que $f(t) < \mathcal{J}(u^*)$ y $f(t) \geq \mathcal{J}(u^*)$ no pueden ser ciertos simultáneamente. Por lo tanto, $\mathcal{J}(u^*) \leq \mathcal{J}(u)$ para todo $u \in K$, y u^* es un mínimo global.

Para demostrar que el conjunto de mínimos es convexo, sean u_1, u_2 dos mínimos globales de $\mathcal{J}$ y $t \in [0, 1]$. Entonces:

$$\mathcal{J}(tu_1 + (1-t)u_2) \leq t\mathcal{J}(u_1) + (1-t)\mathcal{J}(u_2)$$

y

$$t\mathcal{J}(u_1) + (1-t)\mathcal{J}(u_2) = t \inf_{v \in K} \mathcal{J}(v) + (1-t) \inf_{v \in K} \mathcal{J}(v) = \inf_{v \in K} \mathcal{J}(v).$$

Como $\inf_{v \in K} \mathcal{J}(v)$ es el valor mínimo, se tiene:

$$\mathcal{J}(tu_1 + (1-t)u_2) = \inf_{v \in K} \mathcal{J}(v),$$

lo que implica que $tu_1 + (1-t)u_2$ es también un mínimo global. Por lo tanto, el conjunto de mínimos es convexo. $\square$

Teorema 4. *Si $\mathcal{J}$ es estrictamente convexa, entonces existe a lo sumo un mínimo global.*

Demostración. Supongamos, por contradicción, que existen dos mínimos globales distintos u_1 y u_2 tales que:

$$\mathcal{J}(u_1) = \mathcal{J}(u_2) = \inf_{v \in K} \mathcal{J}(v).$$

Como $\mathcal{J}$ es estrictamente convexa, para todo $t \in (0, 1)$ se cumple:

$$\mathcal{J}(tu_1 + (1-t)u_2) < t\mathcal{J}(u_1) + (1-t)\mathcal{J}(u_2)$$

y

$$t\mathcal{J}(u_1) + (1-t)\mathcal{J}(u_2) = t \inf_{v \in K} \mathcal{J}(v) + (1-t) \inf_{v \in K} \mathcal{J}(v) = \inf_{v \in K} \mathcal{J}(v).$$

Esto implica que:

$$\mathcal{J}(tu_1 + (1-t)u_2) < \inf_{v \in K} \mathcal{J}(v),$$

lo cual contradice la definición de ínfimo. Por lo tanto, no pueden existir dos mínimos globales distintos, y el mínimo global, si existe, es único. $\square$

3.4.2. Caso fuertemente convexo

Tenemos lo siguiente.

Teorema 5. *Sea K un conjunto no vacío, cerrado y convexo en un espacio de Hilbert V y sea $\mathcal{J}$ una función continua y fuertemente convexa en V . Entonces $\mathcal{J}$ admite un único minimizador global u en K . Además, para todo $v \in K$, se cumple:*

$$\|v - u\|_V^2 \leq \frac{4}{c_J} (\mathcal{J}(v) - \mathcal{J}(u)),$$

y toda subsucesión minimizante de $\mathcal{J}$ converge hacia u .

Demostración. Paso 1: Existencia de una sucesión minimizante y acotación. Dado que $\mathcal{J}$ está acotada inferiormente, por la Proposición 3, existe $I = \inf_{v \in K} \mathcal{J}(v) > -\infty$. Sea $\{u_n\}$ una sucesión minimizante para $\mathcal{J}$ en K (existe por definición del ínfimo y dado que K es no vacío). Por definición de sucesión minimizante, se tiene

$$\lim_{n \rightarrow \infty} \mathcal{J}(u_n) = I.$$

Paso 2: Uso de la fuerte convexidad. Aplicamos la propiedad de fuerte convexidad de $\mathcal{J}$ con constante $c_J > 0$. Para $n, m \in \mathbb{N}$ arbitrarios, se cumple:

$$\mathcal{J}\left(\frac{u_n + u_m}{2}\right) \leq \frac{1}{2}\mathcal{J}(u_n) + \frac{1}{2}\mathcal{J}(u_m) - \frac{c_J}{8}\|u_n - u_m\|^2.$$

Restando I a ambos lados y usando que $\mathcal{J}\left(\frac{u_n+u_m}{2}\right) \geq I$ (pues I es el ínfimo), obtenemos:

$$\frac{c_J}{8}\|u_n - u_m\|^2 \leq \frac{1}{2}\mathcal{J}(u_n) + \frac{1}{2}\mathcal{J}(u_m) - I.$$

Como $\mathcal{J}(u_n) \rightarrow I$ y $\mathcal{J}(u_m) \rightarrow I$, el lado derecho tiende a cero cuando $n, m \rightarrow \infty$. Por lo tanto, $\{u_n\}$ es una sucesión de Cauchy en K .

Paso 3: Convergencia y minimizador global. Dado que K es cerrado y V es completo, $\{u_n\}$ converge a un elemento $u \in K$. Por la continuidad de $\mathcal{J}$:

$$\mathcal{J}(u) = \lim_{n \rightarrow \infty} \mathcal{J}(u_n) = I.$$

Así, u es un minimizador global de $\mathcal{J}$ en K .

Paso 4: Unicidad del minimizador. Supongamos que existe otro minimizador $\tilde{u} \in K$. Aplicando la fuerte convexidad:

$$I = \mathcal{J}(u) \leq \mathcal{J}\left(\frac{u + \tilde{u}}{2}\right) \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(\tilde{u}) - \frac{c_J}{8}\|u - \tilde{u}\|^2.$$

Como $\mathcal{J}(u) = \mathcal{J}(\tilde{u}) = I$, esto implica:

$$0 \leq -\frac{c_J}{8}\|u - \tilde{u}\|^2.$$

Dado que $c_J > 0$, se deduce que $\|u - \tilde{u}\|^2 = 0$, es decir, $u = \tilde{u}$. Por lo tanto, el minimizador es único.

Paso 5: Desigualdad para el minimizador. Sea $v \in K$. Como K es convexo, $(u + v)/2 \in K$. Aplicando la fuerte convexidad:

$$\mathcal{J}\left(\frac{u + v}{2}\right) \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \frac{c_J}{8}\|u - v\|^2.$$

Dado que u es minimizador, $\mathcal{J}\left(\frac{u+v}{2}\right) \geq \mathcal{J}(u)$. Sustituyendo:

$$\mathcal{J}(u) \leq \frac{1}{2}\mathcal{J}(u) + \frac{1}{2}\mathcal{J}(v) - \frac{c_J}{8}\|u - v\|^2.$$

Simplificando:

$$\frac{c_J}{8}\|u - v\|^2 \leq \frac{1}{2}(\mathcal{J}(v) - \mathcal{J}(u)).$$

Multiplicando por 4:

$$\|u - v\|^2 \leq \frac{4}{c_J} (\mathcal{J}(v) - \mathcal{J}(u)),$$

lo que concluye la demostración. $\square$

Aquí el enunciado del Teorema de Hahn-Banach (versión geométrica: separación de un convexo cerrado por un hiperplano) en un espacio de Hilbert, junto con una prueba simplificada que utiliza el teorema de proyección en un convexo cerrado.

Teorema 6 (Teorema de Hahn-Banach (Separación)). *Sea V un espacio de Hilbert y $K \subset V$ un conjunto no vacío, cerrado y convexo. Si*

$$v_0 \in V \setminus K,$$

entonces existe un hiperplano cerrado que separa estrictamente v_0 de K . Es decir, existen $z \in V$ y $\beta \in \mathbb{R}$ tales que:

$$(z, v_0)_V < \beta < (z, w)_V, \quad \forall w \in K.$$

Demostración. Es una valse en tres pasos.

Paso 1: Proyección sobre el convexo cerrado. Dado que K es cerrado y convexo, por el teorema de proyección en un convexo cerrado, existe un único $w_0 \in K$ tal que, para todo $w \in K$:

$$(v_0 - w_0, w - w_0)_V \leq 0.$$

Este w_0 es la proyección ortogonal de v_0 sobre K .

Paso 2: Construcción del hiperplano separador. Definimos

$$m := \frac{w_0 + v_0}{2}, \quad z := w_0 - m = \frac{w_0 - v_0}{2}.$$

Como $v_0 \notin K$, z es no nulo. Ahora, consideramos el hiperplano:

$$\mathcal{H} := \{v \in V \mid (z, v)_V = \beta\},$$

donde $\beta = (z, m)_V$.

Paso 3: Separación estricta. Primero tenemos

$$(z, m - v_0)_V = \frac{1}{4}(w_0 - v_0, w_0 - v_0) > 0$$

y luego

$$(z, v_0) < (z, m)_V = \beta.$$

También *****

$$(z, w)_V = \frac{1}{2}(w_0 - v_0, w)_V = \frac{1}{2}((w_0 - v_0, w - w_0)_V + (w_0 - v_0, w_0)_V).$$

y, como para todo $w \in K$:

$$(v_0 - w_0, w - w_0)_V \leq 0,$$

entonces

$$(z, w)_V \geq \frac{1}{2}(w_0 - v_0, w_0)_V.$$

Acotamos

$$(z, w)_V - \beta \geq \frac{1}{2}(w_0 - v_0, w_0)_V - (z, m)_V = \frac{1}{2}(w_0 - v_0, w_0)_V - \frac{1}{4}(w_0 - v_0, w_0 + v_0)_V.$$

y

$$(z, w)_V - \beta \geq \frac{1}{2}(w_0 - v_0, w_0)_V - (z, m)_V = \frac{1}{2}(w_0 - v_0, w_0)_V - \frac{1}{4}(w_0 - v_0, w_0 + v_0)_V.$$

$$(z, w)_V - \beta \geq (w_0 - v_0, \frac{1}{2}w_0 - \frac{1}{4}w_0 - \frac{1}{4}v_0)_V > 0.$$

□

—
—

Proposición 2 (Proposición (9.2.5, Allaire)). *Si $\mathcal{J}$ es convexa y continua sobre un conjunto K cerrado, convexo y no vacío, entonces existen $\delta \in \mathbb{R}$ y $L \in V'$ tales que para todo $v \in K$:*

$$\mathcal{J}(v) \geq L(v) + \delta.$$

Demostración. Como $\mathcal{J}$ es convexa y continua, su epigrafo:

$$\text{epi}(\mathcal{J}) = \{(v, \mu) \in V \times \mathbb{R} \mid \mathcal{J}(v) \leq \mu\}$$

es un conjunto convexo y cerrado en $V \times \mathbb{R}$. Además, como K es no vacío, existe al menos un punto $(v_0, \mathcal{J}(v_0)) \in \text{epi}(\mathcal{J})$. Consideremos el conjunto:

$$C = \left\{ (v, \mu) \in V \times \mathbb{R} \mid \mu < \inf_{v \in K} \mathcal{J}(v) \right\}.$$

Este conjunto es convexo y abierto, y no interseca con $\text{epi}(\mathcal{J})$. Por el *teorema de separación de Hahn-Banach*, existen un funcional lineal $F \in (V \times \mathbb{R})'$ y $\alpha \in \mathbb{R}$ tales que:

$$F(v, \mu) \leq \alpha \quad \forall (v, \mu) \in \text{epi}(\mathcal{J}),$$

$$F(v, \mu) > \alpha \quad \forall (v, \mu) \in C.$$

Podemos descomponer F como $F(v, \mu) = L(v) + \beta\mu$, donde $L \in V'$ y $\beta \in \mathbb{R}$. De las desigualdades anteriores, se deduce que $\beta > 0$ (de lo contrario, no se cumpliría la segunda desigualdad para $\mu \rightarrow -\infty$). Sin pérdida de generalidad, podemos normalizar F para que $\beta = 1$. Entonces:

$$L(v) + \mu \leq \alpha \quad \forall (v, \mu) \in \text{epi}(\mathcal{J}).$$

En particular, para todo $v \in V$ y $\mu = \mathcal{J}(v)$, se tiene:

$$L(v) + \mathcal{J}(v) \leq \alpha.$$

Reordenando, obtenemos:

$$\mathcal{J}(v) \geq -L(v) + \alpha.$$

Definiendo $\delta = -\alpha$ y reemplazando L por $-L$, se obtiene:

$$\mathcal{J}(v) \geq L(v) + \delta.$$

□

Proposición 3. *Además, si $\mathcal{J}$ es fuertemente convexa, entonces existen $\gamma > 0$ y $\delta \in \mathbb{R}$ tales que para todo $v \in V$:*

$$\mathcal{J}(v) \geq \gamma \|v\|^2 + \delta.$$

Demostración. Como $\mathcal{J}$ es fuertemente convexa, existe $\gamma > 0$ tal que la función $\mathcal{J}(v) - \frac{\gamma}{2}\|v\|^2$ es convexa. Aplicando la proposición anterior a esta función, existen $\delta' \in \mathbb{R}$ y $L \in V'$ tales que:

$$\mathcal{J}(v) - \frac{\gamma}{2}\|v\|^2 \geq L(v) + \delta'.$$

Reordenando, obtenemos:

$$\mathcal{J}(v) \geq \frac{\gamma}{2}\|v\|^2 + L(v) + \delta'.$$

Como $\frac{\gamma}{2}\|v\|^2 + L(v) \geq \frac{\gamma}{4}\|v\|^2 - \frac{1}{\gamma}\|L\|^2$ (por la desigualdad de Young), podemos ajustar γ y δ para obtener:

$$\mathcal{J}(v) \geq \gamma\|v\|^2 + \delta,$$

donde $\delta = \delta' - \frac{1}{\gamma}\|L\|^2$.

□

3.4.3. Caso estrictamente convexo

1. ****Función cuadrática degenerada**** Consideremos la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por:

$$f(x, y) = x^2 + y^4.$$

- ****Estrictamente convexa****: Su matriz hessiana es

$$H_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 12y^2 \end{pmatrix},$$

que es positiva definida para todo $(x, y) \neq (0, 0)$ (pues $12y^2 > 0$ si $y \neq 0$ y $2 > 0$). Además, f cumple la desigualdad de convexidad estricta:

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y), \quad \forall \lambda \in (0, 1), x \neq y.$$

- ****No fuertemente convexa****: No existe $\alpha > 0$ tal que $f(x, y) - \frac{\alpha}{2} \|(x, y)\|^2$ sea convexa. En particular, la segunda derivada en la dirección y tiende a 0 cuando $y \rightarrow 0$, lo que impide la existencia de una constante global $\alpha > 0$ que acote inferiormente el hessiano.

2. ****Función exponencial**** Consideremos la función $g : \mathbb{R} \rightarrow \mathbb{R}$ definida por:

$$g(x) = e^x.$$

- ****Estrictamente convexa****: Su segunda derivada es $g''(x) = e^x > 0$ para todo $x \in \mathbb{R}$, lo que garantiza convexidad estricta. - ****No fuertemente convexa****: No existe $\alpha > 0$ tal que $g''(x) \geq \alpha$ para todo $x \in \mathbb{R}$, ya que $g''(x) = e^x \rightarrow 0$ cuando $x \rightarrow -\infty$.

1. ****Funcional asociado al p -Laplaciano con $1 < p < 2$ **** Sea $\Omega \subset \mathbb{R}^n$ un dominio acotado y consideremos el funcional $J : W_0^{1,p}(\Omega) \rightarrow \mathbb{R}$ definido por:

$$J(u) = \frac{1}{p} \int_{\Omega} |\nabla u|^p dx.$$

- ****Estrictamente convexo****: El operador p -Laplaciano $-\Delta_p u = -\operatorname{div}(|\nabla u|^{p-2} \nabla u)$ es estrictamente monótono para $1 < p < \infty$, lo que implica que J es estrictamente convexo. - ****No fuertemente convexo****: Para $1 < p < 2$,

el funcional J **no es fuertemente convexo** en $W_0^{1,p}(\Omega)$. Esto se debe a que la derivada de $|\nabla u|^p$ no está acotada inferiormente por una constante positiva uniforme en todo el espacio. En particular, la "fuerte convexidad" falla porque la segunda derivada del término $|\nabla u|^p$ no es uniformemente elíptica.

2. **Funcional de energía asociado a una EDP elíptica no lineal**
Consideremos el funcional $E : H_0^1(\Omega) \rightarrow \mathbb{R}$ definido por:

$$E(u) = \int_{\Omega} \left(\sqrt{1 + |\nabla u|^2} - 1 \right) dx - \int_{\Omega} f u dx,$$

donde $f \in L^2(\Omega)$. - **Estrictamente convexo** : El integrando $\sqrt{1 + |\nabla u|^2}$ es estrictamente convexo en ∇u , ya que su hessiana (con respecto a ∇u) es positiva definida. Esto garantiza que E es estrictamente convexo. - **No fuertemente convexo** : La segunda derivada del término $\sqrt{1 + |\nabla u|^2}$ es:

$$\frac{\partial^2}{\partial(\nabla u)^2} \sqrt{1 + |\nabla u|^2} = \frac{I}{1 + |\nabla u|^2} - \frac{\nabla u \otimes \nabla u}{(1 + |\nabla u|^2)^{3/2}},$$

que no está acotada inferiormente por una constante positiva uniforme (por ejemplo, cuando $|\nabla u| \rightarrow \infty$, la norma de esta matriz tiende a 0). Por lo tanto, E no es fuertemente convexo.

3.5. El caso convexo

1. Ejemplos de funciones convexas pero no estrictamente convexas (relativos a EDP elípticas)

**Ejemplo 1: Funcional asociado al operador p -Laplaciano con $p = 1$ ** Consideremos el funcional $J : BV(\Omega) \rightarrow \mathbb{R}$ definido por:

$$J(u) = \int_{\Omega} |\nabla u| \, dx,$$

donde $BV(\Omega)$ es el espacio de funciones de variación acotada. - **Convexo**^{*}: El funcional J es convexo porque $|\nabla u|$ es una norma (y las normas son convexas). - **No estrictamente convexo**^{*}: No cumple la desigualdad estricta de convexidad. Por ejemplo, si u y v son funciones con $\nabla u = -\nabla v$, entonces:

$$J\left(\frac{u+v}{2}\right) = \int_{\Omega} \left| \nabla \left(\frac{u+v}{2} \right) \right| \, dx = \int_{\Omega} \left| \frac{\nabla u + \nabla v}{2} \right| \, dx = \int_{\Omega} \left| \frac{\nabla u - \nabla u}{2} \right| \, dx = 0,$$

mientras que:

$$\frac{1}{2}J(u) + \frac{1}{2}J(v) = \int_{\Omega} |\nabla u| \, dx > 0.$$

Por lo tanto, $J\left(\frac{u+v}{2}\right) = \frac{1}{2}J(u) + \frac{1}{2}J(v)$ (no hay desigualdad estricta).

— **Ejemplo 2: Funcional de energía con término lineal** Consideremos el funcional $E : H_0^1(\Omega) \rightarrow \mathbb{R}$ definido por:

$$E(u) = \int_{\Omega} |\Delta u| \, dx - \int_{\Omega} f u \, dx,$$

donde $f \in L^2(\Omega)$. - **Convexo**^{*}: El término $\int_{\Omega} |\Delta u| \, dx$ es convexo (porque es una norma), y el término lineal $-\int_{\Omega} f u \, dx$ es convexo (y cóncavo a la vez). - **No estrictamente convexo**^{*}: El término $\int_{\Omega} |\Delta u| \, dx$ no es estrictamente convexo, ya que su derivada segunda es nula en casi todo punto (no hay fuerte convexidad).

—
—
—
—

****2. Definición: Convergencia débil en un espacio de Hilbert****

Sea V un espacio de Hilbert. Una secuencia $\{u_n\} \subset V$ ****converge débilmente**** a $u \in V$ si:

$$\lim_{n \rightarrow \infty} \langle u_n, v \rangle_V = \langle u, v \rangle_V, \quad \forall v \in V.$$

Se denota $u_n \rightharpoonup u$.

—
—
—

****3. Proposición: Convergencia débil en Hilbert separable****

Proposición 4. *Sea V un espacio de Hilbert ****separable****. Entonces, una secuencia $\{u_n\} \subset V$ converge débilmente a $u \in V$ si y solo si:*

$$\lim_{n \rightarrow \infty} \langle u_n, e_i \rangle_V = \langle u, e_i \rangle_V, \quad \forall i \in \mathbb{N},$$

donde $\{e_i\}_{i \in \mathbb{N}}$ es una ****base hilbertiana**** (base ortonormal completa) de V .

— ****Demostración:****

- ****Implicación directa ($\Rightarrow$):**** Si $u_n \rightharpoonup u$, entonces por definición de convergencia débil:

$$\lim_{n \rightarrow \infty} \langle u_n, v \rangle_V = \langle u, v \rangle_V, \quad \forall v \in V.$$

En particular, esto vale para $v = e_i$ (pues $e_i \in V$).

- ****Implicación inversa ($\Leftarrow$):**** Supongamos que $\lim_{n \rightarrow \infty} \langle u_n, e_i \rangle_V = \langle u, e_i \rangle_V$ para todo $i \in \mathbb{N}$. Sea $v \in V$. Como $\{e_i\}$ es una base hilbertiana, podemos escribir:

$$v = \sum_{i=1}^{\infty} \langle v, e_i \rangle_V e_i,$$

con convergencia en la norma de V . Entonces:

$$\langle u_n, v \rangle_V = \left\langle u_n, \sum_{i=1}^{\infty} \langle v, e_i \rangle_V e_i \right\rangle_V = \sum_{i=1}^{\infty} \langle v, e_i \rangle_V \langle u_n, e_i \rangle_V.$$

Por hipótesis, $\langle u_n, e_i \rangle_V \rightarrow \langle u, e_i \rangle_V$ para cada i . Además, como $\{u_n\}$ es acotada (pues converge débilmente), por el ****Teorema de Lebesgue dominado****, podemos intercambiar el límite y la suma:

$$\lim_{n \rightarrow \infty} \langle u_n, v \rangle_V = \sum_{i=1}^{\infty} \langle v, e_i \rangle_V \langle u, e_i \rangle_V = \langle u, v \rangle_V.$$

Por lo tanto, $u_n \rightharpoonup u$.

—
—
—
—

****Ejemplo:**** En ℓ^2 , la secuencia $u_n = (1, 0, 0, \dots)$ (con 1 en la posición n y 0 en las demás) satisface: - $u_n \rightharpoonup 0$ (pues $\langle u_n, v \rangle = v_n \rightarrow 0$ para todo $v \in \ell^2$). - $\|u_n\| = 1$ para todo n , por lo que ****no converge fuertemente**** a 0.

Bressan: ejemplo con sen al cuadrado y un medio. —

****5. Lema:** De toda secuencia acotada se puede extraer una subsucesión que converge débilmente******

Lema 1. Sea V un espacio de Hilbert y $\{u_n\} \subset V$ una secuencia ****acotada**** (es decir, $\|u_n\| \leq M$ para todo n y algún $M > 0$). Entonces existe una subsucesión $\{u_{n_k}\}$ que converge débilmente a algún $u \in V$.

— ****Demostración:****

- ****Base hilbertiana:**** Como V es separable, existe una base hilbertiana $\{e_i\}_{i \in \mathbb{N}}$. - ****Acotación de las componentes:**** Para cada $i \in \mathbb{N}$, la secuencia $\{\langle u_n, e_i \rangle\}$ está acotada en $\mathbb{R}$ (pues $|\langle u_n, e_i \rangle| \leq \|u_n\| \|e_i\| \leq M$). - ****Subsucesión diagonal:**** Por el ****Teorema de Bolzano-Weierstrass****, para cada i , existe una subsucesión $\{u_n^{(i)}\}$ tal que $\{\langle u_n^{(i)}, e_i \rangle\}$ converge. Usando un argumento de ****subsucesión diagonal****, podemos construir una subsucesión $\{u_{n_k}\}$ tal que:

$$\lim_{k \rightarrow \infty} \langle u_{n_k}, e_i \rangle \text{ existe para todo } i \in \mathbb{N}.$$

- ****Convergencia débil:**** Por la ****Proposición 3****, esto implica que $\{u_{n_k}\}$ converge débilmente a algún $u \in V$.

—

—
—
6. Lema: Un convexo cerrado K es exactamente la intersección de los semiplanos cerrados que lo contienen

Lema 2. Sea V un espacio de Hilbert y $K \subset V$ un conjunto **cerrado y convexo**. Entonces:

$$K = \bigcap_{\substack{H \supset K \\ H \text{ semiplano cerrado}}} H.$$

— **Demostración (por contradicción usando Hahn-Banach):**
- **Inclusión trivial:** Claramente, $K \subset \bigcap_{H \text{ semiplano cerrado}, H \supset K} H$, ya que todo semiplano cerrado que contiene a K incluye a K . - **Inclusión inversa:** Supongamos que existe $x \in \bigcap_{H \text{ semiplano cerrado}, H \supset K} H$ pero $x \notin K$. Como K es cerrado y convexo, por el **Teorema de Hahn-Banach** (versión geométrica), existe un hiperplano cerrado que separa estrictamente x de K . Es decir, existen $a \in V$ y $\beta \in \mathbb{R}$ tales que:

$$\langle y, a \rangle \leq \beta < \langle x, a \rangle, \quad \forall y \in K.$$

Esto implica que el semiplano cerrado $H = \{y \in V \mid \langle y, a \rangle \leq \beta\}$ contiene a K pero **no contiene a x **, lo que contradice la hipótesis de que x está en la intersección de todos los semiplanos cerrados que contienen a K . Por lo tanto, $x \in K$.

—
—
—
7. Lema: Un convexo cerrado K es cerrado para la convergencia débil

Lema 3. Sea V un espacio de Hilbert y $K \subset V$ un conjunto **cerrado y convexo**. Entonces K es **cerrado para la convergencia débil**, es decir: Si $\{u_n\} \subset K$ y $u_n \rightharpoonup u$, entonces $u \in K$.

— **Demostración:**

- Por el ****Lema 6****, K es la intersección de todos los semiplanos cerrados que lo contienen. Sea $H = \{y \in V \mid \langle y, a \rangle \leq \beta\}$ uno de estos semiplanos. Como $u_n \in K \subset H$ para todo n , se tiene:

$$\langle u_n, a \rangle \leq \beta.$$

Tomando límite cuando $n \rightarrow \infty$ (por la convergencia débil):

$$\langle u, a \rangle \leq \beta.$$

Por lo tanto, $u \in H$ para todo semiplano cerrado H que contiene a K . Por el ****Lema 6****, esto implica que $u \in K$.

—
—
— —

****8. Lema:** Si J es convexa y semi-continua inferiormente (s.c.i.) sobre K , entonces J es s.c.i. para la convergencia débil**

Lema 4. Sea V un espacio de Hilbert, $K \subset V$ un conjunto ****cerrado y convexo****, y $J : K \rightarrow \mathbb{R}$ una función ****convexa y semi-continua inferiormente (s.c.i.)**** para la convergencia fuerte. Entonces J es también ****s.c.i. para la convergencia débil****.

— ****Demostración:****

- Sea $\{u_n\} \subset K$ una secuencia que converge débilmente a $u \in K$ (por el ****Lema 7****, $u \in K$). - Como J es convexa y s.c.i. para la convergencia fuerte, por el ****Teorema de Mazur****, existe una combinación convexa de los u_n que converge ****fuertemente**** a u . Es decir, para cada $k \in \mathbb{N}$, existen $\lambda_i^{(k)} \geq 0$ con $\sum_{i=1}^{N_k} \lambda_i^{(k)} = 1$ tales que:

$$v_k = \sum_{i=1}^{N_k} \lambda_i^{(k)} u_i \quad \text{y} \quad v_k \rightarrow u \text{ fuertemente.}$$

- Por la convexidad de J :

$$J(v_k) \leq \sum_{i=1}^{N_k} \lambda_i^{(k)} J(u_i).$$

- Tomando límite inferior cuando $k \rightarrow \infty$ y usando que J es s.c.i. para la convergencia fuerte:

$$J(u) \leq \liminf_{k \rightarrow \infty} J(v_k) \leq \liminf_{k \rightarrow \infty} \sum_{i=1}^{N_k} \lambda_i^{(k)} J(u_i).$$

Como $\{u_n\}$ converge débilmente a u , y J es convexa, se puede mostrar que:

$$J(u) \leq \liminf_{n \rightarrow \infty} J(u_n).$$

Por lo tanto, J es s.c.i. para la convergencia débil.

—

— — —

— ****9. Existencia de un mínimo: Caso convexo, J continua, coerciva y convexa sobre K^{**}**

Teorema 7. Sea V un espacio de Hilbert, $K \subset V$ un conjunto ****cerrado, convexo y no vacío****, y $J : K \rightarrow \mathbb{R}$ una función ****continua, coerciva**** (es decir, $\lim_{\|u\| \rightarrow \infty} J(u) = +\infty$) y ****convexa****. Entonces J admite un ****mínimo global**** en K .

— ****Prueba (pasos detallados):****

1. ****Existencia de una secuencia minimizante:**** Sea $I = \inf_{u \in K} J(u)$. Por definición del ínfimo, existe una secuencia $\{u_n\} \subset K$ tal que:

$$J(u_n) \rightarrow I.$$

2. ****La secuencia minimizante es acotada (por contradicción):**** Supongamos que $\{u_n\}$ no es acotada. Entonces existe una subsucesión $\{u_{n_k}\}$ tal que $\|u_{n_k}\| \rightarrow \infty$. Como J es coerciva:

$$J(u_{n_k}) \rightarrow +\infty,$$

lo que contradice que $J(u_{n_k}) \rightarrow I$. Por lo tanto, $\{u_n\}$ es acotada.

3. ****Existencia de una subsucesión que converge débilmente:**** Por el ****Lema 5****, existe una subsucesión $\{u_{n_k}\}$ que converge débilmente a algún $u \in V$. Además, por el ****Lema 7****, como K es cerrado y convexo, $u \in K$.

4. **$J(u)$ es el mínimo:** Por el **Lema 8**, J es s.c.i. para la convergencia débil. Por lo tanto:

$$J(u) \leq \liminf_{k \rightarrow \infty} J(u_{n_k}) = I.$$

Como I es el ínfimo, se tiene $J(u) \geq I$. Por lo tanto, $J(u) = I$, y u es un **minimizador global** de J en K .

3.6. Criterios de convexidad con diferencial

Aquí los criterios con derivada de $\mathcal{J}$ y derivada segunda.

3.7. Criterios de optimalidad

Sea $K \subset V$ un conjunto convexo y cerrado, y $\mathcal{J} : V \rightarrow \mathbb{R}$ una función convexa y diferenciable. Un punto $u \in K$ es mínimo de $\mathcal{J}$ en K si y solo si:

$$\langle \mathcal{J}'(u), v - u \rangle \geq 0, \quad \forall v \in K.$$

Esta es la **desigualdad variacional de Euler-Lagrange**.

Capítulo 4

Método de Newton

El método de Newton es un algoritmo de optimización de segundo orden que utiliza información de la segunda derivada para acelerar la convergencia. A diferencia del descenso de gradiente, este método aproxima la función objetivo localmente por una función cuadrática y encuentra su mínimo en una sola iteración. Aunque requiere el cálculo de la matriz hessiana, su convergencia es típicamente más rápida, especialmente cerca del óptimo. Es ampliamente utilizado en problemas donde la precisión y la velocidad son críticas. Sin embargo, su implementación puede ser costosa en términos computacionales.

4.1. Idea del método

Seguimos los libros de Suli y Allaire. El *método de Newton* utiliza aproximaciones cuadráticas locales para acelerar la convergencia. La iteración se define como:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k),$$

donde $\nabla^2 f(x_k)$ es la matriz Hessiana de f en x_k . Este método converge cuadráticamente cerca de mínimos locales (Teorema de Kantorovich). El método de Newton puede verse como una aproximación de la dinámica de segundo orden:

$$\frac{d^2 x}{dt^2} + \gamma \frac{dx}{dt} = -\nabla f(x),$$

donde γ es un parámetro de amortiguamiento. Esta ecuación modela el movimiento de una partícula en un paisaje de energía potencial f .

4.2. Mas sobre funciones convexas

Definición 8 (Función convexa en dimensión finita). *Una función*

$$f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$$

es **convexa** si su **dominio extendido** $\text{dom}(f) = \{x \in \mathbb{R}^n \mid f(x) < +\infty\}$ es un conjunto convexo y, para todo $x, y \in \text{dom}(f)$ y todo $\lambda \in [0, 1]$, se cumple:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

El **dominio extendido** $\text{dom}(f)$ incluye todos los puntos donde f no toma el valor $+\infty$. Este concepto es crucial porque:

- Permite manejar funciones definidas solo en subconjuntos específicos de $\mathbb{R}^n$ (por ejemplo, restricciones en optimización).
- Garantiza que la desigualdad de convexidad se aplique **solo** a pares de puntos donde f está bien definida.


Ejemplos ilustrativos

Ejemplo 4 (Función valor absoluto: $f(x) = |x|$). *Tiene las características siguientes.*

- **Dominio extendido:** $\text{dom}(f) = \mathbb{R}$.
- **Convexidad:** *Cumple la desigualdad de convexidad (por desigualdad triangular):*


$$|\lambda x + (1 - \lambda)y| \leq \lambda|x| + (1 - \lambda)|y|.$$

- **Visualización:**



Ejemplo 5 (Función parte positiva: $f(x) = \max(x, 0)$). Tiene las características siguientes.

- **Dominio extendido:** $\text{dom}(f) = \mathbb{R}$.
- **Convexidad:** se verifica directamente con la definición.
- **Visualización:**



Ejemplo 6 (Función indicatriz de un conjunto convexo C). Se define así:

$$f(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

- **Dominio extendido:** $\text{dom}(f) = C$, que es convexo por definición.
- **Convexidad:** La desigualdad se cumple trivialmente (ambos lados son $+\infty$ o 0).

Ejemplo 7 (Función norma euclidiana). **Función norma euclidiana:** Se define por $f(x) = \|x\|_2$.

- **Dominio extendido:** $\text{dom}(f) = \mathbb{R}^n$.
- **Convexidad:** Desigualdad triangular:

$$\|\lambda x + (1 - \lambda)y\|_2 \leq \lambda \|x\|_2 + (1 - \lambda)\|y\|_2.$$

Las funciones convexas propias son un caso especialmente importante en optimización y análisis convexo, ya que combinan la convexidad con condiciones naturales sobre su dominio y valores. A continuación, presentamos su definición formal.

Definición 9 (Función convexa propia). *Una función $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ se denomina **convexa propia** si cumple las siguientes condiciones:*

1. **Convexidad:** *f es convexa en el sentido usual:*

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad \forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1].$$

2. **Condición de no trivialidad:** *$f(x) < +\infty$ para al menos un $x \in \mathbb{R}^n$ (es decir, $\text{dom}(f) \neq \emptyset$).*

4.2.1. Subdiferencial de funciones convexas

La noción de subdiferencial generaliza el concepto de gradiente a funciones convexas que no son necesariamente diferenciables. Esta herramienta es fundamental en optimización convexa, ya que permite caracterizar óptimos incluso en presencia de no diferenciabilidad.

Definición 10 (Subgradiente). *Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ una función convexa. Un vector $g \in \mathbb{R}^n$ es un **subgradiente** de f en x si*

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in \mathbb{R}^n.$$

*El conjunto de todos los subgradientes de f en x se denota $\partial f(x)$ y se llama **subdiferencial** de f en x .*

Intuitivamente, un subgradiente define un hiperplano de soporte al epígrafo de la función en el punto considerado. Cuando la función es diferenciable, el subdiferencial se reduce a un singleton que contiene el gradiente clásico.

A continuación, resumimos algunas propiedades fundamentales del subdiferencial en dimensión finita.

Propiedades clave. Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ convexa y $x \in \text{dom}(f)$. Entonces:

- El conjunto $\partial f(x)$ es convexo y cerrado.
- Si f es diferenciable en x , entonces

$$\partial f(x) = \{\nabla f(x)\}.$$

- La condición de optimalidad de primer orden se escribe:

$$0 \in \partial f(x) \iff x \text{ es un minimizador global de } f.$$

- La aplicación $x \mapsto \partial f(x)$ es monótona en el sentido de operadores:

$$(g_1 - g_2)^T(x_1 - x_2) \geq 0 \quad \text{para todo } g_i \in \partial f(x_i).$$

Para ilustrar esta noción, presentamos ahora algunos ejemplos clásicos de cálculo de subdiferenciales.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$ con $x \in \mathbb{R}$. Entonces:

$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{-1\} & \text{si } x < 0, \\ [-1, 1] & \text{si } x = 0. \end{cases}$$

- **Parte positiva.** Sea $f(x) = \max(0, x)$. Entonces:

$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{0\} & \text{si } x < 0, \\ [0, 1] & \text{si } x = 0. \end{cases}$$

- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ un conjunto convexo cerrado y

$$\iota_C(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

Entonces, para $x \in C$, el subdiferencial está dado por el cono normal:

$$\partial \iota_C(x) = N_C(x) = \{g \in \mathbb{R}^n \mid g^T(y - x) \leq 0, \forall y \in C\}.$$

Estos ejemplos muestran cómo el subdiferencial captura la falta de diferenciabilidad mediante conjuntos de pendientes admisibles, lo cual resulta esencial en el análisis y la resolución de problemas de optimización convexa no suave.

4.2.2. Caracterización de mínimos

Una de las principales ventajas del subdiferencial es que permite formular condiciones de optimalidad de primer orden sin requerir diferenciabilidad. En el contexto de funciones convexas, esta caracterización es particularmente simple y poderosa. El siguiente resultado establece una condición necesaria y suficiente de optimalidad global.

Teorema 8 (Caracterización de mínimos). *Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ una función convexa. Un punto $x^* \in \text{dom}(f)$ es un mínimo global de f si y solo si*

$$0 \in \partial f(x^*).$$

Este resultado generaliza la condición clásica $\nabla f(x^*) = 0$ del caso diferenciable. En efecto, cuando f es diferenciable en x^* , se tiene $\partial f(x^*) = \{\nabla f(x^*)\}$, y la condición anterior se reduce a la conocida anulación del gradiente.

Idea de la demostración. La demostración se basa directamente en la definición de subgradiente.

- (*Suficiencia*) Si $0 \in \partial f(x^*)$, entonces por definición:

$$f(y) \geq f(x^*) \quad \forall y \in \mathbb{R}^n,$$

lo que implica que x^* es un mínimo global.

- (*Necesidad*) Si x^* es un mínimo global, entonces

$$f(y) \geq f(x^*) \quad \forall y,$$

lo que corresponde exactamente a la desigualdad de subgradiente con $g = 0$.

Para una demostración más detallada y en un marco más general (espacios vectoriales normados), se puede consultar textos clásicos de optimización convexa como [10].

Interpretación geométrica. La condición $0 \in \partial f(x^*)$ significa que existe un hiperplano de soporte horizontal al epígrafo de f en x^* . Intuitivamente, esto indica que no existe ninguna dirección de descenso, lo que caracteriza un mínimo global en el caso convexo.

A continuación, ilustramos esta caracterización con ejemplos clásicos.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$. Entonces:

$$\partial f(0) = [-1, 1].$$

Como $0 \in [-1, 1]$, se concluye que $x^* = 0$ es un mínimo global. En cambio, si $x \neq 0$, entonces $\partial f(x)$ no contiene al cero, lo que confirma que no son minimizadores.

- **Parte positiva.** Sea $f(x) = \max(0, x)$. Se tiene:

$$\partial f(0) = [0, 1].$$

Dado que $0 \in \partial f(0)$, el punto $x^* = 0$ es un mínimo global (de hecho, $f(x) \geq 0$ para todo x).

- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ convexo cerrado y $f = \iota_C$. Entonces:

$$\partial f(x) = N_C(x).$$

La condición de optimalidad se escribe:

$$0 \in N_C(x^*),$$

lo cual equivale a decir que

$$0^T(y - x^*) \leq 0 \quad \forall y \in C,$$

condición que es siempre verdadera. Esto refleja el hecho de que todo punto de C es minimizador de ι_C .

Comentario. Este criterio es fundamental en optimización convexa y sirve como base para numerosos algoritmos (métodos de subgradiente, métodos proximales, etc.). Su simplicidad contrasta con su gran generalidad, ya que sigue siendo válido incluso en ausencia de diferenciabilidad.

4.3. Newton semi-suave

Aquí describimos el algoritmo de Newton semi-suave.

4.4. Restricciones

Para problemas con restricciones, podemos aplicar además las siguientes técnicas.

4.4.1. Penalización

Ver [7].

4.4.2. Lagrangiano

Ver [7] y [1].

4.4.3. Lagrangiano aumentado

Ver [7] y trabajos recientes de Erik Burman.

Capítulo 5

Desigualdades variacionales

Las desigualdades variacionales son útiles para modelar numerosos problemas de la física o la ingeniería [5, 7, 11]. Sin embargo, rara vez se abordan en los cursos de posgrado de análisis numérico. El objetivo es presentar el análisis numérico del problema del obstáculo, cuando se discretiza mediante elementos finitos. El problema del obstáculo es, de hecho, el prototipo ideal de una desigualdad variacional y, quizás, el más sencillo de ellos.

Denotamos por $H^s(\cdot)$, $s \in \mathbb{R}$, a los espacios de Sobolev. Para un subconjunto abierto D de $\mathbb{R}^n$, la norma usual de $H^s(D)$ se denota por $\|\cdot\|_{s,D}$. El espacio $H_0^1(D)$ es el subespacio de funciones en $H^1(D)$ con traza nula en ∂D . La letra C representa una constante genérica, independiente de los parámetros de discretización.

5.1. Ejemplos

Seguimos [7]. Las desigualdades variacionales proporcionan un marco general para estudiar problemas con restricciones, como el del obstáculo. Este planteamiento permite modelar fenómenos físicos donde las soluciones deben satisfacer condiciones de desigualdad en lugar de igualdades. La teoría de desigualdades variacionales es fundamental para entender la estructura matemática del problema.

5.1.1. Problema de Signorini (contacto unilateral sin fricción)

Sea $\Omega \subseteq \mathbb{R}^d$ un dominio acotado con frontera $\Gamma = \Gamma_D \cup \Gamma_C \cup \Gamma_N$ (donde Γ_D es la parte de la frontera con desplazamiento prescrito, Γ_C es la zona de contacto potencial y Γ_N es la parte con carga aplicada). El

problema de Signorini consiste en encontrar $u \in K$, donde:

$$K = \{v \in H^1(\Omega) : v = 0 \text{ en } \Gamma_D, v \geq 0 \text{ en } \Gamma_C\},$$

tal que:

$$a(u, v - u) + j(v) - j(u) \geq \langle f, v - u \rangle \quad \forall v \in K.$$

Aquí:

- $a(u, v) = \int_{\Omega} \sigma_{ij}(u) \varepsilon_{ij}(v) dx$ es la forma bilineal simétrica asociada al tensor de deformaciones ε y tensiones σ .
- $j(v) = 0$ (en este caso, sin fricción).
- $\langle f, v \rangle = \int_{\Omega} f v dx + \int_{\Gamma_N} g v ds$ es el funcional lineal de cargas.
- $\sigma_{ij}(u)$ son las componentes del tensor de tensiones, y $\varepsilon_{ij}(v)$ las del tensor de deformaciones.

5.1.2. Problema de torsión (Saint-Venant)

Sea $\Omega \subseteq \mathbb{R}^2$ una sección transversal de una barra. El problema de torsión consiste en encontrar $\phi \in H_0^1(\Omega)$ tal que:

$$a(\phi, v) = \langle f, v \rangle \quad \forall v \in H_0^1(\Omega),$$

donde:

- $a(\phi, v) = \int_{\Omega} \nabla \phi \cdot \nabla v dx$ (forma bilineal simétrica).
- $\langle f, v \rangle = \int_{\Omega} G \theta v dx$, con G el módulo de corte, θ el ángulo de torsión por unidad de longitud, y $f = 2G\theta$ (constante).
- El convexo K es relacionado a $|\nabla u| \leq c$.

5.1.3. Problema de Tresca (fricción)

Sea Ω un dominio con frontera $\Gamma = \Gamma_D \cup \Gamma_C \cup \Gamma_N$. El problema de Tresca con fricción en Γ_C consiste en encontrar $u \in K$ tal que:

$$a(u, v - u) + j(v) - j(u) \geq \langle f, v - u \rangle \quad \forall v \in K,$$

donde:

- $K = \{v \in H^1(\Omega) : v = 0 \text{ en } \Gamma_D\}$.
- $j(v) = \int_{\Gamma_C} g|v_t| ds$, con g el coeficiente de fricción y v_t la componente tangencial de v en Γ_C .
- $a(u, v)$ es la forma bilineal simétrica asociada al problema elástico.

5.1.4. Problema de Bingham (fluido visco-plástico)

El fluido de Bingham se modela mediante la siguiente desigualdad variacional: Encontrar $u \in K$ tal que:

$$a(u, v - u) + j(v) - j(u) \geq \langle f, v - u \rangle \quad \forall v \in K,$$

donde:

- $K = \{v \in H_0^1(\Omega)^d : \operatorname{div} v = 0\}$ (campo de velocidades incompresible).
- $a(u, v) = \int_{\Omega} 2\mu \varepsilon_{ij}(u) \varepsilon_{ij}(v) dx$, con μ la viscosidad plástica.
- $j(v) = \int_{\Omega} \tau_0 \sqrt{2} |\varepsilon(v)| dx$, con τ_0 el límite de fluencia.
- $\langle f, v \rangle = \int_{\Omega} f \cdot v dx$.

5.1.5. Formulación con forma bilineal no simétrica

Consideremos un problema variacional con una forma bilineal no simétrica. Por ejemplo, sea $\Omega \subseteq \mathbb{R}^d$ y el problema: Encontrar $u \in H_0^1(\Omega)$ tal que:

$$a(u, v) = \langle f, v \rangle \quad \forall v \in H_0^1(\Omega),$$

donde la forma bilineal $a(u, v)$ se define como:

$$a(u, v) = \int_{\Omega} \nabla u \cdot \nabla v dx + \int_{\Omega} \mathbf{b} \cdot \nabla u v dx,$$

con $\mathbf{b} \in L^\infty(\Omega)^d$ un campo vectorial dado. Aquí, el término $\int_{\Omega} \mathbf{b} \cdot \nabla u v dx$ introduce la asimetría en la forma bilineal.

5.2. Teoría general

Veamos ahora resultados sobre desigualdades de tipo I y de tipo II. El estudio de la existencia y unicidad de soluciones es crucial para garantizar la validez de los modelos matemáticos. En el caso del obstáculo, se demuestra que, bajo condiciones adecuadas, existe una solución única que satisface las restricciones físicas del problema. Este análisis sienta las bases para el desarrollo de métodos numéricos confiables.

5.2.1. Teorema de Stampacchia

Aquí detallamos el Teorema de Stampacchia, para tipo I.

5.2.2. Teorema de Lions-Stampacchia

Aquí detallamos del Teorema de Lions-Stampacchia, para tipo II.

5.3. Galerkin y elementos finitos

Aproximaciones de tipo elementos finitos. Convergencia y estimaciones a priori, ver [7].

La aproximación de Galerkin es un método numérico ampliamente utilizado para resolver problemas descritos por desigualdades variacionales. Este enfoque permite discretizar el problema y transformarlo en un sistema algebraico resoluble. Su simplicidad y eficacia lo convierten en una herramienta estándar en el análisis numérico.

5.3.1. Penalización

El método de penalización reemplaza las restricciones del problema original por términos en la función objetivo. Este enfoque simplifica la implementación numérica y permite aplicar técnicas estándar de resolución. Sin embargo, la elección del parámetro de penalización es clave para la estabilidad y precisión del método.

5.3.2. Newton semi-suave

El método de Newton semi-suave es una técnica avanzada para resolver problemas de desigualdades variacionales, combinando ideas de métodos de Newton y subgradientes. Este enfoque aprovecha la estructura diferenciable a trozos de las funciones involucradas, mejorando la convergencia en problemas no lineales. Su aplicación es especialmente relevante en contextos donde la solución puede presentar comportamientos complejos.

5.3.3. Implementación en scikit-fem

scikit-fem es una biblioteca de Python que facilita la implementación de métodos de elementos finitos para resolver problemas variacionales. Su integración con NumPy y SciPy permite desarrollar soluciones eficientes y modulares. Esta herramienta es ideal para prototipar y validar algoritmos numéricos en entornos académicos y de investigación. Veamos el listado siguiente, escrito por Lucas Curci.

```
1  """Diferenciación automática.
2  Utiliza diferenciación automática para derivar el sistema
   tangente
3  para el método de Newton.
4  """
5
6  from skfem import *
7  from skfem.autodiff import NonlinearForm
8  from skfem.autodiff.helpers import grad, dot
9  import numpy as np
10 import jax.numpy as jnp
11
12 m = MeshTri().refined(5)
13
14 @NonlinearForm(hessian=True)
15 def J(u, _):
16     eps = 1e-2
17     return (1/2 * dot(grad(u), grad(u)) - u
18             + (1 / eps) * ((u - jnp.minimum(u.value, 0.01)
19                             )**2))
19
20 basis = Basis(m, ElementTriP1())
```

```
21 D = m.boundary_nodes()
22 x = np.zeros(basis.N)
23
24
25 for itr in range(100):
26     x_prev = x.copy()
27     x += solve(*condense(*J.assemble(basis, x=x), D=D))
28     res = np.linalg.norm(x - x_prev)
29     if res < 1e-8:
30         break
31     if __name__ == "__main__":
32         print(res)
33
34 if __name__ == "__main__":
35     from skfem.visuals.matplotlib import plot3, show
36     plot3(m, x)
37     show()
```

Listado 5.1: Diferenciación automática con scikit-fem.

5.3.4. Comentarios adicionales

- **Método de Nitsche o multiplicadores:** Estas técnicas alternativas permiten incorporar las restricciones del problema de manera explícita en la formulación débil, mejorando la estabilidad numérica en ciertos casos. El método de Nitsche, en particular, ofrece una forma elegante de manejar las condiciones de desigualdad.
- **Aplicaciones:** El problema del obstáculo tiene aplicaciones en mecánica de sólidos, fluidos, finanzas y otras áreas de la ciencia e ingeniería. Su versatilidad lo convierte en un modelo fundamental para estudiar fenómenos con restricciones geométricas o físicas.

Capítulo 6

Dualidad

La dualidad en optimización es un concepto fundamental que establece una relación entre un problema de optimización primal y su problema dual asociado. El problema dual proporciona una cota inferior para el valor óptimo del problema primal, lo que permite analizar la solidez de las soluciones encontradas. Las condiciones de optimalidad de Karush-Kuhn-Tucker (KKT) conectan las soluciones primales y duales. Este enfoque es especialmente útil en problemas con restricciones complejas, donde el análisis directo puede ser difícil. La dualidad también tiene interpretaciones geométricas profundas. Seguimos [1] (véase también [3] y [13]).

6.1. Problema primal y problema dual

6.1.1. Definiciones

Definición 11. Sean V y Q dos espacios de Hilbert sobre el cuerpo $\mathbb{K}$ (donde $\mathbb{K} = \mathbb{R}$ o $\mathbb{C}$), y sea $\mathcal{L}: U \times P \subseteq V \times Q \rightarrow \mathbb{K}$ un Lagrangiano definido sobre un subconjunto $U \times P$ de $V \times Q$.

Un punto silla de $\mathcal{L}$ es un par $(v^*, q^*) \in U \times P$ tal que:

$$\mathcal{L}(v^*, q) \leq \mathcal{L}(v^*, q^*) \leq \mathcal{L}(v, q^*) \quad \forall (v, q) \in U \times P.$$

Es decir, v^* minimiza $\mathcal{L}(\cdot, q^*)$ en U y q^* maximiza $\mathcal{L}(v^*, \cdot)$ en P .

Definición 12. Dado el Lagrangiano $\mathcal{L}$, definimos las funciones primal y dual como:

$$P(v) = \sup_{q \in P} \mathcal{L}(v, q) \quad (\text{función primal}),$$

$$D(q) = \inf_{v \in U} \mathcal{L}(v, q) \quad (\text{función dual}).$$

—

Definición 13. *Los problemas primal y dual asociados a $\mathcal{L}$ son:*

$$\textit{Problema primal:} \quad \inf_{v \in U} P(v) = \inf_{v \in U} \sup_{q \in P} \mathcal{L}(v, q),$$

$$\textit{Problema dual:} \quad \sup_{q \in P} D(q) = \sup_{q \in P} \inf_{v \in U} \mathcal{L}(v, q).$$

Capítulo 7

Perspectivas

Para concluir nuestra breve introducción, damos unas sugerencias que permitirán al lector ir más allá en el tema y/o descubrir otros campos relacionados. Se puede referir también a [2].

7.1. Optimización matemática

El análisis convexo es fundamental en la teoría de la optimización, especialmente en problemas de programación matemática. Las funciones convexas y los conjuntos convexos permiten modelar y resolver problemas de minimización o maximización con restricciones, garantizando la existencia de soluciones globales óptimas. Por ejemplo, en **programación convexa**, se minimiza una función convexa sobre un conjunto convexo, lo que asegura convergencia a soluciones globales.

$$\begin{aligned} &\text{Minimizar } f(x) \\ &\text{Sujeto a } g_i(x) \leq 0, \quad i = 1, \dots, m \\ &\quad \quad h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned}$$

donde f es convexa y g_i, h_j son funciones convexas.

7.2. Control y sistemas dinámicos

En teoría de control, el análisis convexo se aplica para estabilizar sistemas dinámicos y diseñar controladores robustos. Los **conos tangentes** y las **funciones de Lyapunov convexas** son herramientas clave para analizar la estabilidad asintótica y diseñar estrategias de control óptimo.

7.3. Aprendizaje automático

En aprendizaje automático, el análisis convexo es esencial en algoritmos como **Support Vector Machines (SVM)** y **regresión logística**. Las SVM, por ejemplo, buscan el hiperplano que maximice el margen entre clases, lo que se formula como un problema de optimización convexa. La convexidad garantiza que el algoritmo encuentre la solución globalmente óptima.

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{sueto a} \quad y_i(w \cdot x_i + b) \geq 1 \quad \forall i.$$

7.4. Economía y finanzas

En economía, el análisis convexo se utiliza para modelar preferencias de agentes económicos, funciones de producción y problemas de equilibrio general. Por ejemplo, las **funciones de utilidad cuasi-convexas** permiten analizar decisiones bajo incertidumbre, mientras que la convexidad de las funciones de costo es clave en la teoría de la firma.

7.5. Teoría de juegos

En teoría de juegos, los conceptos de convexidad son centrales para analizar equilibrios de Nash en juegos no cooperativos. Las estrategias mixtas y las funciones de pago convexas permiten demostrar la existencia de equilibrios y estudiar su estabilidad.

7.6. Geometría y computación

En geometría computacional, el análisis convexo se aplica en algoritmos de **envueltas convexas** (como el algoritmo de Graham) y en problemas de localización de puntos. La convexidad permite diseñar algoritmos eficientes para encontrar soluciones aproximadas o exactas en conjuntos de datos de alta dimensionalidad.

7.7. Procesamiento de señales e imágenes

En procesamiento de imágenes, técnicas como la **reconstrucción convexa** y la **regularización total variación (TV)** se basan en la convexidad para minimizar artefactos y mejorar la calidad de la imagen. Estas técnicas son fundamentales en tomografía, resonancia magnética y reconstrucción 3D.

7.8. Teoría de la información

En teoría de la información, las funciones convexas como la **entropía relativa** (o divergencia de Kullback-Leibler) son herramientas esenciales para analizar la capacidad de canales de comunicación y diseñar códigos eficientes.

Apéndice A

Más sobre conjuntos convexos

Los conjuntos convexos son fundamentales en geometría computacional, optimización y aprendizaje automático. Su estudio permite resolver problemas complejos mediante estructuras bien definidas y propiedades robustas. La importancia de estos conjuntos radica en su capacidad para modelar fenómenos reales de manera eficiente, desde la planificación de rutas hasta la clasificación de datos. Además, su definición intuitiva —un conjunto donde el segmento entre dos puntos cualesquiera siempre está contenido— facilita su aplicación en algoritmos y teoremas. En la práctica, los conjuntos convexos aparecen en problemas de minimización, donde garantizan la existencia de soluciones óptimas. Su utilidad se extiende también a la robótica, el procesamiento de imágenes y la inteligencia artificial, donde sirven como herramientas clave para el análisis y la toma de decisiones.

La cáscara convexa, (*convex hull*), es una de las aplicaciones más relevantes de estos conjuntos. Se trata del conjunto convexo más pequeño que contiene a un grupo dado de puntos, actuando como un envoltorio geométrico que preserva la estructura esencial del conjunto original. Este concepto es crucial en geometría computacional, donde permite resolver problemas como la detección de colisiones o la reconstrucción de superficies en tres dimensiones. En el aprendizaje automático, la cáscara convexa se utiliza para definir regiones de decisión en algoritmos de clasificación, como las máquinas de vectores de soporte. Su cálculo eficiente es posible gracias a algoritmos como el de Graham o QuickHull, que optimizan el proceso reduciendo la complejidad computacional. Además, su visualización intuitiva ayuda a comprender mejor la distribución de datos en espacios multidimensionales. Este capítulo explora tanto la teoría como las aplicaciones prácticas de los conjuntos convexos y la cáscara convexa. A través de ejemplos concretos y algoritmos, se busca proporcionar al lector una buena comprensión de estos conceptos.

A.1. Definición y propiedades

Los conjuntos convexos son uno de los conceptos más poderosos en matemáticas, con aplicaciones que abarcan desde la optimización hasta el aprendizaje automático. Un conjunto es convexo si, intuitivamente, no presenta huecos ni entrantes: cualquier segmento de recta que una dos puntos del conjunto permanece completamente dentro de él. Esta propiedad, aparentemente simple, tiene implicaciones profundas en teoría y práctica, permitiendo resolver problemas de minimización, clasificación y modelado con garantías de eficiencia y robustez.

A.1.1. Para empezar

En el marco de la geometría y el análisis funcional, los conjuntos convexos emergen como objetos fundamentales, definidos por la propiedad intrínseca de contener, junto con cualquier par de sus puntos, el segmento de recta que los une.

Definición 14 (Conjunto convexo). *Un conjunto $C \subseteq \mathbb{R}^n$ es **convexo** si, para todo $x, y \in C$ y todo $\lambda \in [0, 1]$, se cumple que:*

$$\lambda x + (1 - \lambda)y \in C.$$

En otras palabras, el conjunto contiene todos los puntos del segmento de recta que une x e y .

Ejemplo 8. Ejemplos clásicos de conjuntos convexos:

- *Un **segmento de recta** en $\mathbb{R}^n$: $[a, b] = \{\lambda a + (1 - \lambda)b \mid \lambda \in [0, 1]\}$.*
- *Un **disco** (o bola cerrada) en $\mathbb{R}^2$: $\{(x, y) \mid x^2 + y^2 \leq r^2\}$.*
- *Un **hiperplano** en $\mathbb{R}^n$: $\{x \mid a^T x = b\}$, donde $a \in \mathbb{R}^n$ y $b \in \mathbb{R}$.*
- *El **espacio vectorial** $\mathbb{R}^n$ en sí mismo.*

Teorema 9 (Intersección de conjuntos convexos). *Sea $\{C_i\}_{i \in I}$ una familia de conjuntos convexos en $\mathbb{R}^n$. Entonces, su intersección $\bigcap_{i \in I} C_i$ también es un conjunto convexo.*

Demostración. Sea $x, y \in \bigcap_{i \in I} C_i$ y $\lambda \in [0, 1]$. Por definición de intersección, $x, y \in C_i$ para todo $i \in I$. Como cada C_i es convexo,

$$\lambda x + (1 - \lambda)y \in C_i$$

para todo $i \in I$. Por lo tanto, $\lambda x + (1 - \lambda)y \in \bigcap_{i \in I} C_i$, lo que prueba que la intersección es convexa. $\square$

Definición 15 (Combinación convexa). Una **combinación convexa** de puntos $x_1, x_2, \dots, x_k \in \mathbb{R}^n$ es una expresión de la forma:

$$\sum_{i=1}^k \lambda_i x_i, \quad \text{donde} \quad \lambda_i \geq 0 \quad y \quad \sum_{i=1}^k \lambda_i = 1.$$

A.1.2. Interior y clausura de un conjunto convexo

Ahora exploramos propiedades esenciales de los conjuntos convexos: primero, su comportamiento respecto al interior y la clausura.

Proposición 5. Sea $C \subseteq \mathbb{R}^n$ un conjunto convexo. Entonces, su interior $\overset{\circ}{C}$ y su clausura $\overline{C}$ son también conjuntos convexos.

Demostración. Veamos ambos casos.

Sean $C \subseteq \mathbb{R}^n$ un conjunto convexo y $\overset{\circ}{C}$ su interior. Queremos demostrar que $\overset{\circ}{C}$ es convexo, es decir, que para todo $x, y \in \overset{\circ}{C}$ y todo $\lambda \in [0, 1]$, el punto $z = \lambda x + (1 - \lambda)y$ pertenece a $\overset{\circ}{C}$.

1. **Premisas:** Sean $x, y \in \overset{\circ}{C}$. Por definición de punto interior, existen bolas abiertas $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, donde $r_x, r_y > 0$. Sea $\lambda \in [0, 1]$. Definimos $z = \lambda x + (1 - \lambda)y$.
2. **Construcción de la bola centrada en z :** Sea $r = \min(r_x, r_y) > 0$. Consideremos la bola abierta $B(z, r)$. Para todo $w \in B(z, r)$, escribimos $w = z + v$, donde $\|v\| < r$.
3. **Expresión de w como combinación convexa:** Observamos que:

$$w = z + v = \lambda x + (1 - \lambda)y + v.$$

Podemos descomponer v como:

$$v = \lambda v + (1 - \lambda)v,$$

donde $\|v\| < r \leq r_x$ y $\|v\| < r \leq r_y$. Esto es posible porque $r = \min(r_x, r_y)$.

4. **Verificación de que $w \in C$:** Como $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, entonces:

$$x + v \in B(x, r_x) \subseteq C \quad \text{y} \quad y + v \in B(y, r_y) \subseteq C.$$

Por convexidad de C , la combinación convexa:

$$\lambda(x + v) + (1 - \lambda)(y + v) = z + v = w$$

también está en C .

Dado que para todo $w \in B(z, r)$ se tiene $w \in C$, entonces $B(z, r) \subseteq C$. Esto implica que $z \in \overset{\circ}{C}$. Como z es un punto arbitrario en el segmento $[x, y]$, se concluye que $[x, y] \subseteq \overset{\circ}{C}$.

Por lo tanto, $\overset{\circ}{C}$ es un conjunto convexo.

Caso de la clausura $\overline{C}$: Sean $x, y \in \overline{C}$ y $\lambda \in [0, 1]$. Existen sucesiones $\{x_k\}$ e $\{y_k\}$ en C tales que $x_k \rightarrow x$ e $y_k \rightarrow y$. Definimos $z_k = \lambda x_k + (1 - \lambda)y_k$. Como C es convexo, $z_k \in C$ para todo k . Además, $z_k \rightarrow \lambda x + (1 - \lambda)y = z$, por lo que $z \in \overline{C}$. $\square$

A.2. Conos convexos

A.2.1. Definición

Un **cono** en un espacio vectorial real V es un subconjunto $K \subseteq V$ que satisface:

- Si $x \in K$ y $\lambda \geq 0$, entonces $\lambda x \in K$.
- Si $x, y \in K$, entonces $x + y \in K$.

Un cono K es **convexo** si es convexo como conjunto, es decir, si para todo $x, y \in K$ y $\lambda \in [0, 1]$, se cumple:

$$\lambda x + (1 - \lambda)y \in K.$$

En particular, todo cono convexo es cerrado bajo combinaciones lineales no negativas de sus elementos.

Sea V un espacio vectorial real. Un subconjunto $K \subseteq V$ es un **cono convexo** si:

1. K es un cono: $\lambda x \in K$ para todo $x \in K$ y $\lambda \geq 0$.
2. K es convexo: $\lambda x + (1 - \lambda)y \in K$ para todo $x, y \in K$ y $\lambda \in [0, 1]$.

A.2.2. Ejemplos

1. **Cono positivo en $\mathbb{R}^n$:**

$$\mathbb{R}_+^n = \{x \in \mathbb{R}^n \mid x_i \geq 0 \text{ para todo } i = 1, \dots, n\}.$$

Es un cono convexo, ya que la suma de vectores no negativos es no negativo y el producto por escalares no negativos preserva la no negatividad.

2. **Cono de Lorentz** (o cono de segundo orden):

$$L^n = \{(x_0, x_1, \dots, x_n) \in \mathbb{R}^{n+1} \mid x_0 \geq \sqrt{x_1^2 + \dots + x_n^2}\}.$$

Este cono es convexo y juega un papel importante en optimización convexa.

3. **Cono de matrices semidefinidas positivas:**

$$\mathbb{S}_+^n = \{X \in \mathbb{R}^{n \times n} \mid X = X^\top \text{ y } x^\top X x \geq 0 \text{ para todo } x \in \mathbb{R}^n\}.$$

Es un cono convexo en el espacio de matrices simétricas.

A.2.3. Propiedades principales

Sea $K \subseteq V$ un cono convexo. Entonces:

1. K es cerrado bajo combinaciones lineales no negativas:

$$\sum_{i=1}^m \lambda_i x_i \in K \quad \text{para todo } x_i \in K, \lambda_i \geq 0, m \in \mathbb{N}.$$

2. El **dual** de K , definido como

$$K^* = \{y \in V^* \mid \langle y, x \rangle \geq 0 \text{ para todo } x \in K\},$$

también es un cono convexo.

3. Si K es cerrado (en la topología apropiada), entonces $(K^*)^* = K$.
 - La propiedad de ser cerrado bajo combinaciones lineales no negativas es equivalente a la convexidad del cono.
 - El dual K^* permite caracterizar desigualdades lineales y es fundamental en programación convexa.

A.3. Envoltura convexa

La **envoltura convexa** de un conjunto $S \subseteq \mathbb{R}^n$ es un concepto fundamental en análisis convexo y optimización. Permite caracterizar los conjuntos convexos minimales que contienen a S , y entender sus propiedades geométricas y analíticas.

A.3.1. Caracterización

Una definición posible de la envoltura (o cáscara) convexa es la siguiente.

Definición 16 (Caracterización de la envoltura convexa). *Sea $S \subseteq \mathbb{R}^n$. Entonces,*

$$\text{conv}(S) = \left\{ \sum_{i=1}^k \lambda_i x_i \mid x_i \in S, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1, k \in \mathbb{N} \right\},$$

es un conjunto convexo que contiene a S , y es el más pequeño en el sentido de la inclusión.

El teorema siguiente ilustra que existen dos caracterizaciones equivalentes de $\text{conv}(S)$: una por combinación convexa, y otra por intersección de conjuntos convexos que contienen a S (véase [3], [10], [15] por la demostración).

Teorema 10 (Equivalencia por intersección). *Además, la envoltura convexa de S satisface la siguiente caracterización:*

$$\text{conv}(S) = \bigcap \{C \subseteq \mathbb{R}^n \mid \text{conv}(C) = C \text{ y } S \subseteq C\}.$$

El resultado siguiente, conocido como la *propiedad de los vértices*, también es un teorema (véase [8]).

Teorema 11 (Propiedad de los vértices en dimensión 2). *En dimensión 2, si S es un conjunto finito de puntos en $\mathbb{R}^2$, entonces $\text{conv}(S)$ es un polígono convexo cuyos vértices son un subconjunto de S .*

La figura A.1 ilustra la envoltura convexa de un conjunto de puntos en $\mathbb{R}^2$. En ella, los vértices del pentágono convexo están marcados con cuadrados negros, los puntos interiores con rombos rojos, y los puntos originales del conjunto S con círculos negros.

A.3.2. Técnicas para calcular la envoltura convexa

A lo largo de los años, se han desarrollado numerosos métodos para calcular la envoltura convexa de un conjunto de puntos en el plano o en espacios de mayor dimensión. Las técnicas más antiguas, como el **método de fuerza bruta**, consisten en comparar todos los subconjuntos posibles de puntos, lo que resulta en una complejidad computacional extremadamente alta, del orden de $O(n^4)$ en dos dimensiones. Una mejora significativa llegó con el algoritmo de **envuelto de regalo (Jarvis March, 1973)** que construye la envoltura convexa recorriendo los puntos en orden angular, alcanzando una complejidad de $O(nh)$, donde n es el número total de puntos y h el número de puntos en la envoltura. Con el avance de la computación y la necesidad de mayor eficiencia, surgieron




Figura A.1: Visualización de la envoltura convexa de un conjunto de puntos en $\mathbb{R}^2$.

algoritmos más sofisticados, como el **scan de Graham (1972)**, que ordena los puntos por ángulo polar y construye la envoltura en $O(n \log n)$, y el **QuickHull**, que emplea una estrategia de "divide y vencerás" con una complejidad promedio similar. Entre las técnicas modernas destacan algoritmos híbridos como el de **Chan** que combina ideas de Graham y QuickHull para lograr una complejidad de $O(n \log h)$, o el **Andrew's monotone chain** una variante optimizada del scan de Graham para conjuntos de puntos ordenados. Además, en contextos específicos o dimensiones superiores, se recurre a métodos basados en programación lineal o técnicas estocásticas.

A.3.3. Algoritmo de Graham Scan

El **algoritmo de Graham Scan** es un método eficiente para calcular la **envoltura convexa** de un conjunto finito de puntos en el plano. Su complejidad es de $O(n \log n)$, donde n es el número de puntos en el conjunto S .

Idea general

El objetivo es encontrar el polígono convexo más pequeño que contiene todos los puntos de $S \subseteq \mathbb{R}^2$. La idea central es:

- **Ordenar los puntos** por su ángulo polar respecto a un **punto base** (generalmente el de menor coordenada y).
- **Construir la envoltura** recorriendo los puntos ordenados y eliminando aquellos que no contribuyen a la convexidad.

Etapas del algoritmo

1. Selección del punto base p_0 :

- Elegir el punto con la **coordenada y mínima** (y x mínima en caso de empate).
- Este punto **siempre pertenece** a la envoltura convexa.

2. Ordenamiento por ángulo polar:

- Calcular el ángulo que forma cada punto p_i con el punto base p_0 usando la función `atan2`.
- Ordenar los puntos en **orden creciente de ángulo polar** respecto a p_0 .
- Si dos puntos tienen el mismo ángulo, conservar el más lejano.

3. Construcción de la envoltura con una pila:

- Inicializar una pila con los primeros tres puntos ordenados (p_0, p_1, p_2).
- Para cada punto p_i (desde p_3 hasta p_{n-1}):
 - a) Mientras el ángulo formado por los últimos tres puntos en la pila sea **mayor a 180°** (es decir, hay un "doblez hacia adentro"), eliminar el punto del medio de la pila.
 - b) Empujar p_i en la pila.
- Para verificar la convexidad entre tres puntos consecutivos A, B, C en la pila, calcular el **producto cruzado**:

$$\text{Producto cruzado} = (B_x - A_x)(C_y - B_y) - (B_y - A_y)(C_x - B_x)$$

- Si el producto cruzado es **negativo**, el ángulo en B es mayor a 180° (no convexo).

- Si es **cero**, los puntos son colineales.
- Si es **positivo**, el ángulo es menor a 180° (convexo).

¿Qué representa n en la complejidad?

- n es el **número total de puntos** en el conjunto S .
- La complejidad del algoritmo es $O(n \log n)$, debido principalmente al **ordenamiento por ángulo polar**.
- La construcción de la pila es $O(n)$, ya que cada punto se empuja y se saca como máximo una vez.

Ejemplo paso a paso

Consideremos el conjunto de puntos

$$S = \{(0, 0), (1, 1), (2, 0), (1, -1), (0, 5, 0, 5)\}.$$

1. Punto base: $p_0 = (0, 0)$.
2. Ordenar por ángulo polar: $(2, 0), (1, -1), (0, 5, 0, 5), (1, 1)$.
3. Construcción de la pila:
 - Empujar $(0, 0), (2, 0), (1, -1)$.
 - Para $(0, 5, 0, 5)$: Verificar convexidad entre $(0, 0), (2, 0), (1, -1)$. Eliminar $(2, 0)$.
 - Empujar $(0, 5, 0, 5)$.
 - Para $(1, 1)$: Verificar convexidad entre $(0, 0), (0, 5, 0, 5), (1, -1)$. Empujar $(1, 1)$.
4. Envoltura convexa final: $[(0, 0), (0, 5, 0, 5), (1, 1), (1, -1)]$.

A.3.4. Algoritmo QuickHull

El **algoritmo QuickHull** es un método eficiente para calcular la envoltura convexa de un conjunto de puntos en el plano, basado en una estrategia de **divide y vencerás**. Su nombre proviene de su similitud con el algoritmo de ordenamiento **Quicksort**, ya que también utiliza una partición recursiva del conjunto de puntos para construir la envoltura convexa.

Idea general

La idea central del QuickHull es:

- Identificar los puntos que forman los vértices de la envoltura convexa mediante la búsqueda de los puntos más alejados de los segmentos que unen pares de puntos.
- Dividir recursivamente el conjunto de puntos en subconjuntos más pequeños, cada uno asociado a un segmento de la envoltura parcial, y repetir el proceso hasta que no queden puntos externos.

Etapas del algoritmo

1. Inicialización:

- Encontrar los puntos con las **coordenadas x mínima y máxima** en el conjunto S . Estos puntos **siempre pertenecen** a la envoltura convexa.
- Estos dos puntos definen el **segmento inicial** de la envoltura convexa.

2. División recursiva:

- Para cada segmento de la envoltura parcial (inicialmente, el segmento entre los puntos $x_{\min}$ y $x_{\max}$), encontrar el punto p más alejado del segmento.
- Este punto p es un nuevo vértice de la envoltura convexa.
- Dividir el conjunto de puntos en dos subconjuntos:

- Los puntos que están a la **izquierda** del triángulo formado por el segmento y p .
- Los puntos que están a la **derecha** del mismo triángulo.
- Repetir el proceso recursivamente para cada subconjunto.

3. Construcción final:

- Combinar los resultados de las divisiones recursivas para formar la envoltura convexa completa.

Complejidad

- En el **caso promedio**, la complejidad del QuickHull es $O(n \log n)$, similar al scan de Graham.
- En el **peor caso** (por ejemplo, cuando los puntos están en un círculo), la complejidad puede degradarse a $O(n^2)$.
- Sin embargo, en la práctica, suele ser más rápido que otros algoritmos debido a su naturaleza recursiva y su capacidad para descartar grandes conjuntos de puntos en cada iteración.

Ejemplo

Consideremos el conjunto de puntos

$$S = \{(0, 0), (1, 1), (2, 0), (1, -1), (0, 5), (0, 5)\}.$$

1. Puntos iniciales: $x_{\min} = (0, 0)$ y $x_{\max} = (2, 0)$.
2. El punto más alejado del segmento $(0, 0) - (2, 0)$ es $(1, 1)$.
3. Dividir S en dos subconjuntos:
 - Izquierda: $\{(0, 0), (0, 5), (0, 5), (1, 1)\}$.
 - Derecha: $\{(2, 0), (1, -1), (0, 5), (0, 5)\}$.
4. Repetir el proceso para cada subconjunto hasta obtener la envoltura convexa final:

$$[(0, 0), (1, 1), (2, 0), (1, -1)].$$

Ventajas y limitaciones

- **Ventajas:** Rápido en la práctica, fácil de implementar, y eficiente para conjuntos de puntos dispersos.
- **Limitaciones:** En el peor caso, puede ser lento ($O(n^2)$), y su rendimiento depende de la distribución de los puntos.

A.3.5. Aplicaciones

La **envoltura convexa** (o cáscara convexa) es esencial en:

- **Geometría computacional:** Para problemas de colisión, localización de puntos y clustering.
- **Visión por computadora:** En reconstrucción 3D y reconocimiento de formas.
- **Robótica:** Para planificación de caminos y evitación de obstáculos.
- **Aprendizaje automático:** En clustering (por ejemplo, el algoritmo DBSCAN).

A.4. Separación de convexos

En el contexto de la separación de conjuntos convexos, el resultado fundamental establece que, si dos conjuntos convexos son disjuntos, siempre existe un hiperplano que los separa. Este hiperplano actúa como una barrera en el espacio que permite distinguir claramente entre los elementos de un conjunto y los del otro, sin solapamientos.

A.5. Para profundizar

Recomendamos al lector interesado en profundizar en el tema consultar las siguientes obras: [3], [8], [10], [15].

Apéndice B

Funciones convexas en dimensión finita

Este capítulo aborda el análisis de funciones convexas en dimensión finita, un concepto central en optimización, economía matemática y aprendizaje automático. Se estudian dos contextos principales: el caso general (no necesariamente continuo) y el caso continuo. Para cada contexto, se presentan definiciones, propiedades fundamentales, caracterizaciones de mínimos locales y globales, y herramientas como el subgradiente y la Hessiana.

B.1. Caso general

Antes de abordar las propiedades específicas de las funciones convexas continuas, comenzaremos analizando el caso más general: funciones convexas que, aunque definidas sobre conjuntos convexas, no necesariamente cumplen con la propiedad de continuidad.

B.1.1. Definición, ejemplos y propiedades

“La convexidad es el lenguaje natural de la optimización y el análisis de funciones en espacios vectoriales.”

Adaptado de *Convex Analysis*
(Rockafellar, 1970)

Las funciones convexas son un pilar fundamental en el análisis matemático, la optimización y la inteligencia artificial. Su definición, aunque

aparentemente simple, encierra profundas implicaciones geométricas y algebraicas, especialmente en espacios de dimensión finita. A continuación, exploramos esta noción desde sus bases hasta ejemplos concretos, destacando el papel del dominio extendido y su relación con la convexidad de conjuntos.

Definición 17 (Función convexa en dimensión finita). *Una función*

$$f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$$

*es **convexa** si su **dominio extendido** $\text{dom}(f) = \{x \in \mathbb{R}^n \mid f(x) < +\infty\}$ es un conjunto convexo y, para todo $x, y \in \text{dom}(f)$ y todo $\lambda \in [0, 1]$, se cumple:*

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

El **dominio extendido** $\text{dom}(f)$ incluye todos los puntos donde f no toma el valor $+\infty$. Este concepto es crucial porque:

- Permite manejar funciones definidas solo en subconjuntos específicos de $\mathbb{R}^n$ (por ejemplo, restricciones en optimización).
- Garantiza que la desigualdad de convexidad se aplique **solo** a pares de puntos donde f está bien definida.


Ejemplos ilustrativos

Ejemplo 9 (Función valor absoluto: $f(x) = |x|$). *Tiene las características siguientes.*

- **Dominio extendido:** $\text{dom}(f) = \mathbb{R}$.
- **Convexidad:** *Cumple la desigualdad de convexidad (por desigualdad triangular):*


$$|\lambda x + (1 - \lambda)y| \leq \lambda|x| + (1 - \lambda)|y|.$$

- **Visualización:**



Ejemplo 10 (Función parte positiva: $f(x) = \max(x, 0)$). Tiene las características siguientes.

- **Dominio extendido:** $\text{dom}(f) = \mathbb{R}$.
- **Converidad:** se verifica directamente con la definición.
- **Visualización:**



Ejemplo 11 (Función indicatriz de un conjunto convexo C). Se define así:

$$f(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

- **Dominio extendido:** $\text{dom}(f) = C$, que es convexo por definición.
- **Converidad:** La desigualdad se cumple trivialmente (ambos lados son $+\infty$ o 0).

Ejemplo 12 (Función norma euclidiana). **Función norma euclidiana:** Se define por $f(x) = \|x\|_2$.

■ **Dominio extendido:** $\text{dom}(f) = \mathbb{R}^n$.

■ **Convexidad:** Desigualdad triangular:

$$\|\lambda x + (1 - \lambda)y\|_2 \leq \lambda\|x\|_2 + (1 - \lambda)\|y\|_2.$$

Las funciones convexas propias son un caso especialmente importante en optimización y análisis convexo, ya que combinan la convexidad con condiciones naturales sobre su dominio y valores. A continuación, presentamos su definición formal.

Definición 18 (Función convexa propia). *Una función $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ se denomina **convexa propia** si cumple las siguientes condiciones:*

1. **Convexidad:** f es convexa en el sentido usual:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad \forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1].$$

2. **Condición de no trivialidad:** $f(x) < +\infty$ para al menos un $x \in \mathbb{R}^n$ (es decir, $\text{dom}(f) \neq \emptyset$).

El epígrafe de una función es, en términos sencillos, el 'volumen' o la región en el espacio que se forma por todos los puntos que están por encima de la gráfica de la función.

Definición 19 (Epígrafe de una función). *El **epígrafe** de f se define como:*

$$\text{epi}(f) = \{(x, \alpha) \in \mathbb{R}^n \times \mathbb{R} \mid f(x) \leq \alpha\}.$$

Propiedades clave de funciones convexas

- **Cierre bajo sumas ponderadas:** Si f y g son convexas, entonces $\alpha f + \beta g$ también lo es para $\alpha, \beta \geq 0$.
- **Subniveles convexas:** El conjunto $\{x \mid f(x) \leq \alpha\}$ es convexo para todo $\alpha \in \mathbb{R}$.
- **Relación con la convexidad de conjuntos:** Una función es convexa si y solo si su **epígrafe** (conjunto de puntos por encima de su gráfica) es un conjunto convexo en $\mathbb{R}^{n+1}$.

Transición a propiedades avanzadas

La convexidad no solo simplifica el análisis de funciones, sino que también garantiza la existencia de mínimos globales en problemas de optimización. En lo siguiente, exploraremos cómo estas propiedades se aplican en algoritmos de optimización y aprendizaje automático, donde la convexidad es una condición suficiente para la eficiencia computacional.

B.1.2. Propiedades de continuidad

Las funciones convexas en dimensión finita poseen propiedades de continuidad que las distinguen de otras clases de funciones y son fundamentales en optimización y análisis convexo. A continuación, se presentan los resultados teóricos principales, sus demostraciones y ejemplos ilustrativos.

Teorema 12 (Continuidad en el interior del dominio). *Sea*

$$f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$$

*una función convexa propia. Entonces, f es **localmente lipschitziana** y por lo tanto **continua** en el interior de su dominio extendido $\text{int}(\text{dom}(f))$.*

Demostración. La prueba puede consultarse en [3, Sección 2.1.2]. □

Teorema 13 (Continuidad global en $\mathbb{R}^n$). *Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa y $\text{dom}(f) = \mathbb{R}^n$, entonces f es **globalmente continua** en $\mathbb{R}^n$.*

Demostración. Véase [15, Teorema 10.1]. □

Ejemplos, contraejemplos y casos límite

Ejemplo 13 (Función convexa discontinua en la frontera). *Consideremos la función indicatriz de un conjunto convexo C :*

$$f(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

- f es convexa propia si C es no vacío y convexo.

- f es discontinua en todo punto $x \in \partial C$ (frontera de C), ya que $\lim_{y \rightarrow x, y \notin C} f(y) = +\infty$.
- Este ejemplo muestra que la continuidad solo se garantiza en el interior de $\text{dom}(f)$.

Ejemplo 14 (Función convexa definida en $\mathbb{R}^n$). La función $f(x) = \|x\|_2^2$ es convexa y definida en $\mathbb{R}^n$. Por el Teorema 13, f es continua en todo $\mathbb{R}^n$.

Ejemplo 15 (No convexidad de la función de Heaviside). Consideramos la función de Heaviside, definida como:

$$H(x) = \begin{cases} 0 & \text{si } x < 0, \\ c & \text{si } x = 0, \\ 1 & \text{si } x > 0. \end{cases} \quad \text{donde } c \in \{0, 1\},$$

Demostramos que H no es convexa, independientemente del valor de c .

Caso 1 : $H(0) = 0$ Tomemos $x_1 = -1$, $x_2 = 2$, y $\lambda = 0,5$:

$$H(0,5 \cdot (-1) + 0,5 \cdot 2) = H(0,5) = 1,$$

y

$$0,5 \cdot H(-1) + 0,5 \cdot H(2) = 0,5 \cdot 0 + 0,5 \cdot 1 = 0,5.$$

Aquí, $1 \not\leq 0,5$: la desigualdad de convexidad no se cumple. Por lo tanto, H no es convexa incluso si $H(0) = 0$.

Caso 2 : $H(0) = 1$ Tomemos: - $x_1 = -1$ (donde $H(-1) = 0$), - $x_2 = 1$ (donde $H(1) = 1$), - $\lambda = 0,5$. Calculamos:

$$H(\lambda x_1 + (1 - \lambda)x_2) = H(0) = 1,$$

y

$$0,5 \cdot H(-1) + 0,5 \cdot H(1) = 0,5 \cdot 0 + 0,5 \cdot 1 = 0,5.$$

La desigualdad de convexidad exige:

$$1 \leq 0,5,$$

lo cual es falso. Por lo tanto, H no es convexa si $H(0) = 1$. Independientemente del valor de $H(0)$ (0 o 1), la función de Heaviside no satisface la desigualdad de convexidad para ciertos puntos. Por lo tanto, nunca es convexa.

Implicaciones en optimización

- **Existencia de mínimos:** Si f es convexa propia y $C \subset \mathbb{R}^n$ es un conjunto convexo cerrado no vacío, entonces f alcanza su mínimo sobre C si $C \cap \text{dom}(f) \neq \emptyset$ [15].
- **Estabilidad numérica:** La continuidad de f en el interior de su dominio garantiza la convergencia de algoritmos como el de gradiente descendente.
- **Subgradientes:** En puntos donde f no es diferenciable (por ejemplo, $f(x) = |x|$ en $x = 0$), la convexidad permite definir subgradientes, que son herramientas clave en optimización.

B.1.3. Subdiferencial de funciones convexas

La noción de subdiferencial generaliza el concepto de gradiente a funciones convexas que no son necesariamente diferenciables. Esta herramienta es fundamental en optimización convexa, ya que permite caracterizar óptimos incluso en presencia de no diferenciabilidad.

Definición 20 (Subgradiente). *Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ una función convexa. Un vector $g \in \mathbb{R}^n$ es un **subgradiente** de f en x si*

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in \mathbb{R}^n.$$

*El conjunto de todos los subgradientes de f en x se denota $\partial f(x)$ y se llama **subdiferencial** de f en x .*

Intuitivamente, un subgradiente define un hiperplano de soporte al epígrafo de la función en el punto considerado. Cuando la función es diferenciable, el subdiferencial se reduce a un singleton que contiene el gradiente clásico.

A continuación, resumimos algunas propiedades fundamentales del subdiferencial en dimensión finita.

Propiedades clave. Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ convexa y $x \in \text{dom}(f)$. Entonces:

- El conjunto $\partial f(x)$ es convexo y cerrado.
- Si f es diferenciable en x , entonces

$$\partial f(x) = \{\nabla f(x)\}.$$

- La condición de optimalidad de primer orden se escribe:

$$0 \in \partial f(x) \iff x \text{ es un minimizador global de } f.$$

- La aplicación $x \mapsto \partial f(x)$ es monótona en el sentido de operadores:

$$(g_1 - g_2)^T(x_1 - x_2) \geq 0 \quad \text{para todo } g_i \in \partial f(x_i).$$

Para ilustrar esta noción, presentamos ahora algunos ejemplos clásicos de cálculo de subdiferenciales.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$ con $x \in \mathbb{R}$. Entonces:

$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{-1\} & \text{si } x < 0, \\ [-1, 1] & \text{si } x = 0. \end{cases}$$

- **Parte positiva.** Sea $f(x) = \max(0, x)$. Entonces:

$$\partial f(x) = \begin{cases} \{1\} & \text{si } x > 0, \\ \{0\} & \text{si } x < 0, \\ [0, 1] & \text{si } x = 0. \end{cases}$$

- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ un conjunto convexo cerrado y

$$\iota_C(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

Entonces, para $x \in C$, el subdiferencial está dado por el cono normal:

$$\partial \iota_C(x) = N_C(x) = \{g \in \mathbb{R}^n \mid g^T(y - x) \leq 0, \forall y \in C\}.$$

Estos ejemplos muestran cómo el subdiferencial captura la falta de diferenciabilidad mediante conjuntos de pendientes admisibles, lo cual resulta esencial en el análisis y la resolución de problemas de optimización convexa no suave.

B.1.4. Caracterización de mínimos

Una de las principales ventajas del subdiferencial es que permite formular condiciones de optimalidad de primer orden sin requerir diferenciabilidad. En el contexto de funciones convexas, esta caracterización es particularmente simple y poderosa. El siguiente resultado establece una condición necesaria y suficiente de optimalidad global.

Teorema 14 (Caracterización de mínimos). *Sea $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ una función convexa. Un punto $x^* \in \text{dom}(f)$ es un mínimo global de f si y solo si*

$$0 \in \partial f(x^*).$$

Este resultado generaliza la condición clásica $\nabla f(x^*) = 0$ del caso diferenciable. En efecto, cuando f es diferenciable en x^* , se tiene $\partial f(x^*) = \{\nabla f(x^*)\}$, y la condición anterior se reduce a la conocida anulación del gradiente.

Idea de la demostración. La demostración se basa directamente en la definición de subgradiente.

- (*Suficiencia*) Si $0 \in \partial f(x^*)$, entonces por definición:

$$f(y) \geq f(x^*) \quad \forall y \in \mathbb{R}^n,$$

lo que implica que x^* es un mínimo global.

- (*Necesidad*) Si x^* es un mínimo global, entonces

$$f(y) \geq f(x^*) \quad \forall y,$$

lo que corresponde exactamente a la desigualdad de subgradiente con $g = 0$.

Para una demostración más detallada y en un marco más general (espacios vectoriales normados), se puede consultar textos clásicos de optimización convexa como [10].

Interpretación geométrica. La condición $0 \in \partial f(x^*)$ significa que existe un hiperplano de soporte horizontal al epígrafo de f en x^* . Intuitivamente, esto indica que no existe ninguna dirección de descenso, lo que caracteriza un mínimo global en el caso convexo.

A continuación, ilustramos esta caracterización con ejemplos clásicos.

Ejemplos.

- **Valor absoluto.** Sea $f(x) = |x|$. Entonces:

$$\partial f(0) = [-1, 1].$$

Como $0 \in [-1, 1]$, se concluye que $x^* = 0$ es un mínimo global. En cambio, si $x \neq 0$, entonces $\partial f(x)$ no contiene al cero, lo que confirma que no son minimizadores.

- **Parte positiva.** Sea $f(x) = \max(0, x)$. Se tiene:

$$\partial f(0) = [0, 1].$$

Dado que $0 \in \partial f(0)$, el punto $x^* = 0$ es un mínimo global (de hecho, $f(x) \geq 0$ para todo x).

- **Función indicatriz.** Sea $C \subset \mathbb{R}^n$ convexo cerrado y $f = \iota_C$. Entonces:

$$\partial f(x) = N_C(x).$$

La condición de optimalidad se escribe:

$$0 \in N_C(x^*),$$

lo cual equivale a decir que

$$0^T(y - x^*) \leq 0 \quad \forall y \in C,$$

condición que es siempre verdadera. Esto refleja el hecho de que todo punto de C es minimizador de ι_C .

Comentario. Este criterio es fundamental en optimización convexa y sirve como base para numerosos algoritmos (métodos de subgradiente, métodos proximales, etc.). Su simplicidad contrasta con su gran generalidad, ya que sigue siendo válido incluso en ausencia de diferenciabilidad.

B.2. Existencia de mínimo

Consideremos una función $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa, propia (es decir, $f(x) < +\infty$ para al menos un $x \in \mathbb{R}^n$) y semicontinua inferiormente. Si el dominio efectivo de f , definido como $\text{dom}(f) = \{x \in \mathbb{R}^n : f(x) < +\infty\}$, es no vacío, cerrado y acotado, entonces f alcanza su mínimo global en $\mathbb{R}^n$.

Teorema 15. *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ una función convexa, propia y semicontinua inferiormente. Si $\text{dom}(f)$ es no vacío, cerrado y acotado, entonces existe $x^* \in \text{dom}(f)$ tal que*

$$f(x^*) = \inf_{x \in \mathbb{R}^n} f(x).$$

Consideremos la función $f(x) = x^2$, definida en $\mathbb{R}$. Esta función es convexa, propia y semicontinua inferiormente. Su dominio efectivo es $\mathbb{R}$, que no es acotado. Sin embargo, si restringimos el dominio a un intervalo cerrado y acotado, por ejemplo, $[-1, 1]$, entonces f alcanza su mínimo en $x = 0$.

B.3. Caso diferenciable

Definición 21 (Función convexa diferenciable). *Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa y diferenciable en x , entonces*

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) \quad \forall y \in \mathbb{R}^n.$$

Además, $\nabla f(x)$ es el único subgradiente de f en x .

Definición 22 (Función convexa dos veces diferenciable). *Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa y dos veces diferenciable, entonces su matriz Hessiana $\nabla^2 f(x)$ es **semidefinida positiva** para todo $x \in \mathbb{R}^n$. Recíprocamente, si $\nabla^2 f(x)$ es semidefinida positiva para todo x , entonces f es convexa.*

Teorema 16 (Caracterización de mínimos con gradiente). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global de f si y solo si*

$$\nabla f(x^*) = 0.$$

Teorema 17 (Caracterización de mínimos con Hessiana). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y dos veces diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global estricto de f si y solo si*

$$\nabla f(x^*) = 0 \quad \text{y} \quad \nabla^2 f(x^*) \text{ es definida positiva.}$$

Apéndice C

Más métodos

C.1. Método de penalización

El **método de penalización** transforma un problema con restricciones $\min f(x)$ sujeto a $c_i(x) = 0$ en un problema sin restricciones:

$$\min f(x) + \mu \sum_{i=1}^m c_i(x)^2,$$

donde $\mu > 0$ es el parámetro de penalización.

C.2. Método de Lagrange

El **método de Lagrange** introduce multiplicadores λ para problemas con restricciones $c_i(x) = 0$. La función Lagrangiana es:

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i c_i(x).$$

Las condiciones de optimalidad son:

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0, \quad c_i(x^*) = 0.$$

C.3. Método de Lagrange aumentado

C.3.1. Definición

El método de Lagrange aumentado, también conocido como método de los multiplicadores de Lagrange con penalización, es una técnica

utilizada para resolver problemas de optimización con restricciones. Este método es una generalización del método clásico de los multiplicadores de Lagrange, incorporando una función de penalización que permite manejar restricciones de igualdad de manera más flexible.

Problema general: Dado un problema de optimización no lineal con restricciones de igualdad:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeto a} \quad & h_i(x) = 0, \quad i = 1, \dots, m, \end{aligned}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo y $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son las funciones de restricción, el método de Lagrange aumentado introduce una función de penalización cuadrática en las restricciones, transformando el problema en uno sin restricciones de la siguiente manera:

$$\mathcal{L}_\mu(x, \lambda) = f(x) + \lambda^T h(x) + \frac{\mu}{2} \|h(x)\|^2,$$

donde $\lambda \in \mathbb{R}^m$ son los multiplicadores de Lagrange asociados a las restricciones, y $\mu > 0$ es un parámetro de penalización.

C.3.2. Algoritmo

El algoritmo básico del método de Lagrange aumentado (Uzawa) es el siguiente:

1. Inicializar λ_0 y $\mu > 0$.
2. Resolver el problema sin restricciones:

$$x_{k+1} = \arg \min_x \mathcal{L}_\mu(x, \lambda_k).$$

3. Actualizar los multiplicadores:

$$\lambda_{k+1} = \lambda_k + \mu h(x_{k+1}).$$

4. Verificar convergencia. Si no se cumple, repetir desde el paso 2.

C.3.3. Ejemplo

Consideremos el siguiente problema de optimización con restricción de igualdad:

$$\begin{aligned} \min_{x,y} \quad & x^2 + y^2 \\ \text{sujeto a} \quad & x + y = 1. \end{aligned}$$

Aplicando el método de Lagrange aumentado, definimos la función de Lagrange aumentada:

$$\mathcal{L}_\mu(x, y, \lambda) = x^2 + y^2 + \lambda(x + y - 1) + \frac{\mu}{2}(x + y - 1)^2.$$

Para resolver el problema, minimizamos $\mathcal{L}_\mu$ respecto a x e y , y luego actualizamos λ iterativamente hasta alcanzar la convergencia. Por ejemplo, si tomamos $\mu = 1$ y $\lambda_0 = 0$, el punto óptimo se alcanza en $(x, y) = (0,5, 0,5)$.

C.4. Métodos cuasi-Newton (BFGS)

El método **BFGS** aproxima la inversa de la Hessiana H_k mediante actualizaciones iterativas:

$$H_{k+1} = \left(I - \frac{y_k s_k^T}{y_k^T s_k} \right) H_k \left(I - \frac{s_k y_k^T}{y_k^T s_k} \right) + \frac{s_k s_k^T}{y_k^T s_k},$$

donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$. La iteración es:

$$x_{k+1} = x_k - \alpha_k H_k \nabla f(x_k).$$

Apéndice D

Medida y análisis funcional

Este capítulo está dedicado a profundizar en los fundamentos matemáticos esenciales para el análisis avanzado: la **teoría de medida**, la **integral de Lebesgue** y los **espacios funcionales**. Estos conceptos son pilares en el estudio de la probabilidad, la ecuación diferencial parcial, el análisis funcional y la teoría de control. A través de un enfoque riguroso, se presentan las herramientas teóricas necesarias para abordar problemas complejos en matemática, sentando las bases para el desarrollo de métodos modernos en optimización, física matemática y ciencia de datos.

D.1. Medida

La noción de **medida** generaliza el concepto clásico de longitud, área y volumen a conjuntos abstractos, permitiendo cuantificar el "tamaño" de subconjuntos en espacios arbitrarios. Esta teoría es fundamental para definir integrales generalizadas, como la integral de Lebesgue, y para analizar funciones medibles. Se exploran las propiedades de los espacios de medida, la construcción de medidas a partir de premedidas, y la relación entre la medida y la topología. Además, se estudian los teoremas clásicos de convergencia, como el de la convergencia monótona y el de la convergencia dominada, que son esenciales en el análisis funcional y en la teoría de la probabilidad.

D.2. Medida y funciones

D.2.1. Funciones BV

Definición 23 (Variación acotada). *Una función $f : [a, b] \rightarrow \mathbb{R}$ es de **variación acotada** si su variación total es finita:*

$$V_a^b(f) = \sup \left\{ \sum_{i=1}^n |f(x_i) - f(x_{i-1})| : a = x_0 < x_1 < \cdots < x_n = b \right\} < \infty.$$

El espacio $BV([a, b])$ es el conjunto de funciones de variación acotada en $[a, b]$.

Teorema 18 (Estructura de funciones BV). *Toda función $f \in BV([a, b])$ puede escribirse como la diferencia de dos funciones crecientes. Además, f es derivable en casi todo punto y su derivada es integrable.*

D.2.2. Continuidad absoluta

Definición 24 (Continuidad absoluta). *Una función $f : [a, b] \rightarrow \mathbb{R}$ es **absolutamente continua** si para todo $\varepsilon > 0$ existe $\delta > 0$ tal que para cualquier colección finita de intervalos disjuntos $(a_i, b_i) \subset [a, b]$ con $\sum_i (b_i - a_i) < \delta$, se tiene:*

$$\sum_i |f(b_i) - f(a_i)| < \varepsilon.$$

Teorema 19 (Caracterización de funciones absolutamente continuas). *Sea $f : [a, b] \rightarrow \mathbb{R}$ una función. Las siguientes afirmaciones son equivalentes:*

1. f es absolutamente continua.
2. f es la integral indefinida de su derivada: existe $g \in L^1([a, b])$ tal que

$$f(x) = f(a) + \int_a^x g(t) dt \quad \forall x \in [a, b].$$

3. f es continua, de variación acotada, y la medida de Lebesgue-Stieltjes asociada a f es absolutamente continua respecto a la medida de Lebesgue.

Observación 1. Las funciones absolutamente continuas son un subconjunto propio de las funciones continuas de variación acotada. Además, toda función absolutamente continua es derivable en casi todo punto y su derivada coincide con la función g del teorema anterior.

Ejemplo 16. La función $f(x) = x^2 \sin(1/x)$ para $x \neq 0$ y $f(0) = 0$ es absolutamente continua en $[0, 1]$, pero no es Lipschitz continua.

Ejemplo 17. La función de Cantor-Lebesgue es un ejemplo clásico de función en $BV([0, 1])$ pero no absolutamente continua.

D.2.3. Teorema de aproximación de Lebesgue

Teorema 20 (Teorema de aproximación de Lebesgue). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función medible. Entonces, existe una sucesión de funciones continuas f_k tal que $f_k \rightarrow f$ casi en todo punto y en medida.

Observación 2. Este teorema es fundamental para aproximar funciones no continuas por funciones continuas en el contexto de la teoría de la medida, y está estrechamente relacionado con la diferenciabilidad en casi todo punto.

D.2.4. Teorema de Lebesgue

Teorema 21 (Teorema de diferenciación de Lebesgue). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función localmente integrable. Entonces, para casi todo $x \in \mathbb{R}^n$, se tiene:

$$\lim_{r \rightarrow 0^+} \frac{1}{|B(x, r)|} \int_{B(x, r)} f(y) dy = f(x),$$

donde $B(x, r)$ es la bola de centro x y radio r .

Teorema 22 (Teorema de Lebesgue para funciones de variación acotada). Sea $f : [a, b] \rightarrow \mathbb{R}$ una función de variación acotada. Entonces, f es derivable en casi todo punto de $[a, b]$, y su derivada f' es integrable en $[a, b]$.

Observación 3. *El teorema de Lebesgue asegura que, aunque una función no sea continua, su promedio local converge a su valor en casi todo punto. Esto es clave para entender la diferenciabilidad en el contexto de la teoría de la medida.*

D.2.5. Teorema de Rademacher

Definición 25 (Función Lipschitz). *Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es **Lipschitz** si existe $L \geq 0$ tal que*

$$|f(x) - f(y)| \leq L|x - y| \quad \forall x, y \in \mathbb{R}^n.$$

*El menor L que satisface esta desigualdad se denomina **constante de Lipschitz** de f .*

Teorema 23 (Teorema de Rademacher). *Toda función Lipschitz $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es derivable en casi todo punto de $\mathbb{R}^n$. Además, su diferencial $Df(x)$ es esencialmente acotada (i.e., $\|Df(x)\| \leq L$ c.t.p.).*

Demostración. La demostración clásica usa el teorema de diferenciación de Lebesgue y el hecho de que las funciones Lipschitz son de variación acotada en casi todo punto. $\square$

Observación 4. *El teorema de Rademacher es fundamental en el análisis de funciones no diferenciables en el sentido clásico, pero con regularidad Lipschitz. Extiende el resultado de que las funciones de variación acotada son derivables en casi todo punto (Teorema de Lebesgue).*

Ejemplo 18. *La función $f(x) = |x|$ es Lipschitz en $\mathbb{R}$, pero no es derivable en $x = 0$. Sin embargo, es derivable en casi todo punto de $\mathbb{R}$ (excepto en $x = 0$).*

D.2.6. Resumen de Relaciones entre Propiedades

Propiedad	Derivable en c.t.p.	Relación con L^1
Continuidad absoluta	Sí	$f(x) = f(a) + \int_a^x g(t) dt$
Función Lipschitz	Sí (Rademacher)	$\ Df\ _\infty \leq L$
Variación acotada	Sí (Lebesgue)	$f' \in L^1$
Medible	No necesariamente	Aproximable por funciones continuas

D.3. Hahn–Banach

El **teorema de Hahn–Banach** es uno de los resultados más profundos y útiles del análisis funcional. Este teorema garantiza la existencia de extensiones lineales y continuas de funcionales definidos en subespacios de un espacio vectorial normado, preservando su norma. Sus consecuencias son vastas: permite demostrar la existencia de funcionales lineales continuos no triviales, la separación de conjuntos convexos disjuntos, y la unicidad de normas equivalentes. El teorema de Hahn–Banach es clave en la dualidad entre espacios de Banach y en el estudio de la convergencia en espacios de funciones.

D.4. Espacios de Hilbert

Los **espacios de Hilbert** son generalizaciones del espacio euclidiano a dimensiones infinitas, donde la noción de ortogonalidad y proyección juega un papel central. Estos espacios poseen una estructura geométrica rica, basada en el producto interno, y permiten desarrollar teorías de series de Fourier generalizadas, bases ortonormales y operadores compactos. Se analizan propiedades como la completitud, la descomposición ortogonal y la representación de funcionales lineales continuos mediante el teorema de representación de Riesz. Los espacios de Hilbert son fundamentales en mecánica cuántica, teoría de aproximación y procesamiento de señales.

D.5. Espacios de Lebesgue

Los **espacios de Lebesgue** L^p son espacios funcionales que generalizan el concepto de integrabilidad en el sentido de Lebesgue. Estos espacios, parametrizados por $p \in [1, \infty]$, consisten en clases de equivalencia de funciones medibles cuyas potencias p -ésimas son integrables. Se estudian sus propiedades topológicas, la densidad de funciones continuas, y los teoremas de densidad y aproximación. Además, se exploran las desigualdades fundamentales, como las de Hölder y Minkowski, y su

relación con la convergencia en medida y la continuidad de operadores lineales.

D.6. Derivada débil

La **derivada débil** extiende el concepto clásico de derivada a funciones que no son diferenciables en el sentido usual, pero que poseen una derivada generalizada en un sentido distribucional. Esta noción es esencial en la teoría de distribuciones y en el estudio de ecuaciones diferenciales parciales, donde muchas soluciones no son clásicas. Se definen los espacios de Sobolev y se analizan sus propiedades, incluyendo los teoremas de inmersión y traza, que permiten entender cómo las propiedades de regularidad de una función se transfieren a su frontera. La derivada débil es una herramienta poderosa para formular problemas variacionales y analizar su solubilidad.

D.7. Espacios de Sobolev

Los **espacios de Sobolev** son espacios funcionales que combinan propiedades de diferenciabilidad y integrabilidad, siendo fundamentales en el estudio de ecuaciones diferenciales parciales y en el análisis numérico. Estos espacios consisten en funciones cuyas derivadas débiles hasta cierto orden pertenecen a espacios de Lebesgue. Se analizan sus propiedades de completitud, densidad, y los teoremas de compactación, que son cruciales para demostrar la existencia de soluciones débiles. Los espacios de Sobolev también permiten formular problemas de minimización en cálculo de variaciones y en la teoría del potencial, proporcionando un marco riguroso para el análisis de regularidad y unicidad de soluciones.

D.8. Ejemplos

D.8.1. Generales

A continuación se dan ejemplos sencillos en una dimensión (dominio habitual $(-1, 1)$ o $\mathbb{R}$) que ilustran pertenencia o no a los espacios L^2 y

H^1 .

- **Función continua que está en L^2 pero no en H^1 :**

$$f(x) = |x|^\alpha, \quad \alpha = \frac{1}{4}, \quad x \in (-1, 1).$$

Aquí $f \in L^2((-1, 1))$ porque $\int_{-1}^1 |x|^{2\alpha} dx < \infty$ (ya que $2\alpha > -1$), pero la derivada puntual es $f'(x) = \alpha \operatorname{sgn}(x)|x|^{\alpha-1}$ cuya norma L^2 diverge porque $2(\alpha-1) \leq -1$; por tanto no existe derivada débil en L^2 y $f \notin H^1((-1, 1))$. Este ejemplo es continuo pero no pertenece a H^1 .

- **Función discontinua que pertenece a L^2 pero no a H^1 :**

$$\chi_{(0,1)}(x) = \begin{cases} 1, & x \in (0, 1), \\ 0, & \text{en otro caso,} \end{cases}$$

vista como función en $\mathbb{R}$. Tiene norma L^2 finita, pero presenta una discontinuidad por salto; su derivada en sentido de distribuciones contiene deltas de frontera (no representables por una función en L^2), luego $\chi_{(0,1)} \notin H^1(\mathbb{R})$.

- **Función o distribución que no está en L^2 :**

- La función singular $g(x) = |x|^{-\beta}$ en $(-1, 1)$ con $\beta \geq \frac{1}{2}$ no pertenece a $L^2((-1, 1))$ porque $\int_{-1}^1 |x|^{-2\beta} dx = \infty$.
- La delta de Dirac δ_0 (distribución) no es una función en L^2 (no es una función cuadrado-integrable).

Cada ejemplo indica la razón básica (comportamiento en el origen o saltos) por la que falla la integrabilidad cuadrática o la existencia de derivada débil en L^2 .

D.8.2. Indicador

La función $1_{\{0,1\}}(x)$ representa la **indicador de $\{0, 1\}$** , definida como:

$$1_{\{0,1\}}(x) = \begin{cases} 1 & \text{si } x \in \{0, 1\}, \\ 0 & \text{en otro caso.} \end{cases}$$

Esta función es discontinua en $x = 0$ y $x = 1$, por lo que no pertenece a los espacios clásicos de Sobolev $H^s(\mathbb{R})$ para $s \geq 1/2$ en el sentido estándar. Sin embargo, su regularidad puede analizarse en el marco de los **espacios de Sobolev fraccionarios** $H^s(\mathbb{R})$, $s \in (0, 1)$.

En particular, la indicatriz $1_{\{0,1\}}$ pertenece al espacio $H^{1/2-\varepsilon}(\mathbb{R})$ para todo $\varepsilon > 0$, pero **no** pertenece a $H^{1/2}(\mathbb{R})$. Este resultado se justifica mediante el cálculo de la norma de Sobolev fraccionaria:

$$\|1_{\{0,1\}}\|_{H^s(\mathbb{R})}^2 = \int_{\mathbb{R}} |\xi|^{2s} |\widehat{1_{\{0,1\}}}(\xi)|^2 d\xi,$$

donde $\widehat{1_{\{0,1\}}}(\xi)$ es la transformada de Fourier de la indicatriz. Dado que la transformada de Fourier de $1_{\{0,1\}}$ decae como $|\xi|^{-1}$ en el infinito, la integral converge si y solo si $s < 1/2$. Por lo tanto, la regularidad fraccionaria de la indicatriz está limitada por $s = 1/2$. La **transformada de Fourier** de la indicatriz $1_{\{0,1\}}(x)$ es:

$$\widehat{1_{\{0,1\}}}(\xi) = e^{-i\xi} \frac{\sin(\xi)}{\xi},$$

que también puede escribirse como:

$$\widehat{1_{\{0,1\}}}(\xi) = e^{-i\xi} \frac{\sin(\xi)}{\xi}.$$

Esta función decae como $|\xi|^{-1}$ cuando $|\xi| \rightarrow \infty$.

D.9. Más espacios funcionales

D.9.1. Espacios de Sobolev $H^s(\mathbb{R})$

El espacio de Sobolev $H^s(\mathbb{R})$ para $s \in \mathbb{R}$ se define como:

$$H^s(\mathbb{R}) = \left\{ f \in \mathcal{S}'(\mathbb{R}) : \int_{\mathbb{R}} (1 + |\xi|^2)^s |\widehat{f}(\xi)|^2 d\xi < \infty \right\},$$

donde $\widehat{f}$ es la transformada de Fourier de f . La norma en $H^s(\mathbb{R})$ es:

$$\|f\|_{H^s(\mathbb{R})}^2 = \int_{\mathbb{R}} (1 + |\xi|^2)^s |\widehat{f}(\xi)|^2 d\xi.$$

D.9.2. Espacios de Besov $\mathcal{B}_{p,q}^s(\mathbb{R})$

El espacio de Besov $\mathcal{B}_{p,q}^s(\mathbb{R})$ para $s \in \mathbb{R}$ y $p, q \in [1, \infty]$ se define mediante diferencias finitas o mediante la descomposición en frecuencias. Intuitivamente, mide la regularidad de f en términos de cómo sus diferencias finitas decaen. Para $0 < s < 1$ y $1 \leq p, q \leq \infty$, se tiene:

$$\mathcal{B}_{p,q}^s(\mathbb{R}) = \left\{ f \in L^p(\mathbb{R}) : \left(\int_0^\infty (t^{-s} \omega_p(f, t))^q \frac{dt}{t} \right)^{1/q} < \infty \right\},$$

donde $\omega_p(f, t)$ es el módulo de continuidad en L^p .

D.9.3. Exponente de Hölder

El **exponente de Hölder** α de una función f en un punto x_0 es el supremo de todos $\alpha > 0$ tales que:

$$|f(x) - f(x_0)| \leq C|x - x_0|^\alpha \quad \text{para } x \text{ cerca de } x_0.$$

D.10. Fractales

D.10.1. Función de Weierstrass

La **función de Weierstrass** se define para $\lambda > 1$ y $0 < H < 1$ como:

$$W_H(x) = \sum_{n=0}^{\infty} \lambda^{-nH} \cos(2\pi \lambda^n x).$$

- **Propiedades:** Es continua pero nowhere differentiable.
- **Regularidad de Sobolev:** $W_H \in H^s(\mathbb{R})$ para todo $s < H$.
- **Regularidad de Besov:** $W_H \in \mathcal{B}_{p,q}^H(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = H$ en casi todo punto.
- **Referencia:** Mandelbrot [14].

D.10.2. Función de Takagi

La **función de Takagi** se define como:

$$T(x) = \sum_{n=0}^{\infty} \frac{1}{2^n} \text{dist}(2^n x, \mathbb{Z}),$$

donde $\text{dist}(x, \mathbb{Z})$ es la distancia de x al entero más cercano.

- **Propiedades:** Es continua, creciente, y nowhere differentiable.
- **Regularidad de Sobolev:** $T \in H^s(\mathbb{R})$ para todo $s < 1/2$.
- **Regularidad de Besov:** $T \in \mathcal{B}_{p,q}^{1/2}(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = 1/2$ en casi todo punto.
- **Referencia:** Takagi [17].

D.10.3. Movimiento browniano fraccionario

El **movimiento Browniano fraccionario** $B_H(t)$ con parámetro de Hurst $0 < H < 1$ es un proceso estocástico gaussiano con trayectorias fractales.

- **Propiedades:** Tiene trayectorias continuas pero nowhere diferenciables si $H \neq 1$.
- **Regularidad de Sobolev:** Casi todas las trayectorias satisfacen $B_H \in H^s(\mathbb{R})$ para todo $s < H$.
- **Regularidad de Besov:** Casi todas las trayectorias satisfacen $B_H \in \mathcal{B}_{p,q}^H(\mathbb{R})$ para todo $p, q \geq 1$.
- **Exponente de Hölder:** $\alpha = H$ en casi todo punto y trayectoria.
- **Referencia:** Samorodnitsky y Taqqu [16].

D.10.4. Conjunto de Cantor

El **conjunto de Cantor** C se construye eliminando el tercio central de cada intervalo.

- **Propiedades:** Es un fractal autosimilar con dimensión de Hausdorff $D = \frac{\log 2}{\log 3}$.
- **Función indicatriz:** La función $1_C(x)$ tiene regularidad de Besov $s < D$.
- **Regularidad de Sobolev:** $1_C \notin H^{1/2}(\mathbb{R})$.
- **Referencia:** Cantor [4].

D.10.5. Función de Cantor-Lebesgue

La **función de Cantor-Lebesgue** $f_C(x)$ es continua, creciente, y singular (constante en los intervalos del complemento de C).

- **Propiedades:** Es constante en los intervalos de $\mathbb{R} \setminus C$.
- **Regularidad de Sobolev:** $f_C \notin H^{1/2}(\mathbb{R})$.
- **Regularidad de Besov:** $f_C \in \mathcal{B}_{p,q}^s(\mathbb{R})$ para $s < D$.
- **Referencia:** Lebesgue [12].

D.11. Ecuaciones elípticas

Las ecuaciones elípticas son un tipo de ecuaciones en derivadas parciales de segundo orden cuyo símbolo principal es definido positivo (por ejemplo, la ecuación de Laplace $\Delta u = 0$ o la de Poisson $-\Delta u = f$), y modelan estados estacionarios y distribuciones espaciales equilibradas; en problemas de contorno bien planteados suelen garantizar existencia, unicidad y regularidad de soluciones suaves en dominios regulares, y poseen propiedades cualitativas importantes como el principio del máximo, estimaciones a priori y dependencia continua respecto de los datos, lo que las convierte en herramientas centrales en análisis y aplicaciones físicas e ingenieriles.

Apéndice E

Ejemplos para minimizar con descenso de gradiente

Este presenta cuatro ejemplos **concretos y precisos** de funcionales diferenciables que pueden minimizarse utilizando el método de **descenso de gradiente**. Los ejemplos abarcan:

- Una función fuertemente convexa (regresión Ridge).
- Un problema físico (energía potencial de un sistema de resortes).
- Un problema de optimización de forma (área de un polígono bajo restricción de perímetro).
- Un ejemplo de aprendizaje automático (regresión logística).

Todos los ejemplos están formulados con un número reducido de variables (entre 2 y 10) para facilitar su comprensión y implementación.

E.1. Ridge

E.1.1. Contexto

En aprendizaje automático, la regresión Ridge busca minimizar el error cuadrático entre las predicciones de un modelo lineal y los datos reales, añadiendo un término de regularización L2 para evitar el sobreajuste.

E.1.2. Funcional

Dada una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$, un vector de etiquetas $\mathbf{y} \in \mathbb{R}^n$, y un vector de pesos $\mathbf{w} \in \mathbb{R}^d$, la funcional a minimizar es: $J(\mathbf{w}) = \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$ donde $\lambda > 0$ es el parámetro de regularización.

E.1.3. Propiedades

- **Fuertemente convexa** si $\lambda > 0$.
- Diferenciable, con gradiente: $\nabla J(\mathbf{w}) = \frac{1}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) + 2\lambda\mathbf{w}$.

E.1.4. Ejemplo

Para $d = 2$ (dos variables w_1, w_2) y $n = 3$ muestras:

$$\mathbf{X} = \begin{bmatrix} 1 & 23 & 45 & 6 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 3711 \end{bmatrix}, \quad \lambda = 0,1.$$

La funcional se escribe como:

$$J(w_1, w_2) = \frac{1}{6} ((w_1 + 2w_2 - 3)^2 + (3w_1 + 4w_2 - 7)^2 + (5w_1 + 6w_2 - 11)^2) + 0,1(w_1^2 + w_2^2).$$

E.2. Energía potencial de un sistema de resortes

E.2.1. Contexto

Minimización de la energía potencial elástica de un sistema de masas conectadas por resortes en 1D. Este es un problema clásico en física de medios continuos.

E.2.2. Funcional

Consideremos N masas conectadas por resortes. Sea x_i la posición de la masa i (con x_0 y x_{N+1} fijas). La energía potencial total es: $E(\mathbf{x}) = \sum_{i=1}^N \frac{k}{2} (x_i - x_{i-1} - L_i)^2$ donde k es la constante elástica, L_i es la longitud en reposo del resorte i , y $\mathbf{x} = [x_1, \dots, x_N]$.

E.2.3. Propiedades

- **Convexa** (suma de cuadrados).
- Diferenciable, con gradiente: $\frac{\partial E}{\partial x_i} = k(2x_i - x_{i-1} - x_{i+1} - L_i + L_{i+1})$ (con x_0 y x_{N+1} fijas).

E.2.4. Ejemplo

Para $N = 2$ masas (2 variables x_1, x_2): $k = 1$, $L_1 = L_2 = 1$, $x_0 = 0$, $x_3 = 2$ La funcional se escribe como: $E(x_1, x_2) = \frac{1}{2}(x_1 - 1)^2 + \frac{1}{2}(x_2 - x_1 - 1)^2 + \frac{1}{2}(2 - x_2 - 1)^2$.

E.3. Optimización de forma

E.3.1. Contexto

Encontrar las coordenadas de los vértices de un triángulo que minimice su área, sujetas a una restricción de perímetro fijo. Este es un problema simplificado de optimización de forma.

E.3.2. Funcional

Para un triángulo con vértices $\mathbf{p}_1 = (x_1, y_1)$, $\mathbf{p}_2 = (x_2, y_2)$, $\mathbf{p}_3 = (x_3, y_3)$, y un perímetro P fijo:

- **Área** (a minimizar): $A(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = \frac{1}{2}(\mathbf{p}_2 - \mathbf{p}_1) \times (\mathbf{p}_3 - \mathbf{p}_1)$ (producto vectorial en 2D).
- **Restricción:** $\mathbf{p}_2 - \mathbf{p}_1 + \mathbf{p}_3 - \mathbf{p}_2 + \mathbf{p}_1 - \mathbf{p}_3 = P$.

E.3.3. Penalización

Para transformar el problema restringido en uno no restringido, se usa:

$$J(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = A(\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) + \mu (\mathbf{p}_2 - \mathbf{p}_1 + \mathbf{p}_3 - \mathbf{p}_2 + \mathbf{p}_1 - \mathbf{p}_3 - P)^2$$

donde μ es un parámetro de penalización.

E.3.4. Ejemplo

Para $P = 6$, y fijando $\mathbf{p}_1 = (0, 0)$, $\mathbf{p}_2 = (a, 0)$, $\mathbf{p}_3 = (b, c)$:

- **Área:** $A(a, b, c) = \frac{1}{2}|a \cdot c|$.
- **Restricción:** $a + \sqrt{(b - a)^2 + c^2} + \sqrt{b^2 + c^2} = 6$.

E.4. Aprendizaje automático

E.4.1. Contexto

Clasificar puntos en 2D en dos clases (0 o 1) aprendiendo los parámetros de un modelo logístico.

E.4.2. Funcional

Dada una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times 2}$, un vector de etiquetas $\mathbf{y} \in \{0, 1\}^n$, y parámetros $\mathbf{w} = (w_1, w_2)$, b (pesos y sesgo), la log-verosimilitud negativa (a minimizar) es:

$$J(\mathbf{w}, b) = - \sum_{i=1}^n [y_i \log(\sigma(\mathbf{w}^T \mathbf{x}_i + b)) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^T \mathbf{x}_i + b))]$$

donde $\sigma(z) = \frac{1}{1+e^{-z}}$ es la función sigmoide.

E.4.3. Propiedades

- **Convexa** (la log-verosimilitud negativa es convexa para regresión logística).
- Diferenciable, con gradiente:

$$\nabla_{w_j} J = - \sum_{i=1}^n (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i + b)) x_{ij}, \quad \nabla_b J = - \sum_{i=1}^n (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i + b)).$$

E.4.4. Ejemplo

Para $n = 3$ muestras:

$$\mathbf{X} = \begin{bmatrix} 1 & 22 & 13 & 3 \end{bmatrix}, \quad \mathbf{y} = [101].$$

La funcional se escribe como:

$$J(w_1, w_2, b) = - [\log(\sigma(w_1 + 2w_2 + b)) + \log(1 - \sigma(2w_1 + w_2 + b)) + \log(\sigma(3w_1 + 3w_2 + b))].$$

Referencias bibliográficas

- [1] G. ALLAIRE, *Numerical analysis and optimization*, Oxford University Press, 2007.
- [2] D. P. BERTSEKAS, *Constrained optimization and Lagrange multiplier methods*. Computer Science and Applied Mathematics. New York - London etc.: Academic Press. A Subsidiary of Harcourt Brace Jovanovich, Publishers. XIII, 395 p. \$ 65.00 (1982)., 1982.
- [3] S. BOYD AND L. VANDENBERGHE, *Convex optimization*, Cambridge University Press, 2004.
- [4] G. CANTOR, *Über unendliche lineare punktmannigfaltigkeiten*, Math. Ann., 20 (1883), pp. 61–74.
- [5] G. DUVAUT AND J.-L. LIONS, *Inequalities in mechanics and physics*, Springer-Verlag, 1976.
- [6] W. GANDER, M. J. GANDER, AND F. KWOK, *Scientific computing. An introduction using Maple and MATLAB*, vol. 11 of Texts Comput. Sci. Eng., Cham: Springer, 2014.
- [7] R. GLOWINSKI, *Lectures on numerical methods for nonlinear variational problems*, Springer-Verlag, 1980.
- [8] B. GRÜNBAUM, *Convex polytopes*, Interscience Publishers, 1963.
- [9] T. GUSTAFSSON, *Adaptive finite elements for obstacle problems*, Advances in Applied Mechanics (AAMS), 58 (2024), pp. 205–243. Chapter 5, <https://doi.org/10.1016/bs.aams.2024.03.004>.
- [10] J.-B. HIRIART-URRUTY AND C. LEMARÉCHAL, *Fundamentals of convex analysis*, Springer-Verlag, 2001.
- [11] D. KINDERLEHRER AND G. STAMPACCHIA, *An introduction to variational inequalities and their applications*, Academic Press, 1980.
- [12] H. LEBESGUE, *Leçons sur l'intégration et la recherche des fonctions primitives*, Gauthier-Villars, 1904.
- [13] D. G. LUENBERGER, *Optimization by vector space methods*. John Wiley and Sons, 1969.
- [14] B. B. MANDELBROT, *The Fractal Geometry of Nature*, W. H. Freeman and Company, 1982.

- [15] R. T. ROCKAFELLAR, *Convex analysis*, Princeton University Press, 1970.
- [16] G. SAMORODNITSKY AND M. S. TAQQU, *Stable non-gaussian random processes*, Chapman & Hall, 1994.
- [17] T. TAKAGI, *A simple example of a continuous function without derivative*, Proc. Phys.-Math. Soc. Japan, 1 (1903), pp. 124–125.