Análisis convexo y aplicaciones

Franz Chouly

En Construcción (4 de abril de 2026)

Tabla de contenido

Tabla de contenido **3**

1. Introducción **5**

2. Conjuntos convexos **7**
2.1. Definición y propiedades 8
2.1.1. Para empezar 8
2.1.2. Interior y clausura de un conjunto convexo 9
2.2. Cáscara convexa 10
2.3. Aplicaciones 11
2.3.1. Envoltura convexa de un conjunto de puntos . . . 11
2.3.2. Separación de conjuntos convexos 12
2.3.3. Algoritmo de Graham (1972) 12
2.3.4. Algoritmo de Jarvis (1973) 13
2.3.5. Clustering con cáscara convexa 14
2.3.6. Optimización convexa 14

3. Funciones convexas **15**
3.1. Caso general 15
3.2. Casos continuo y diferenciable 16

4. Métodos de minimización **17**
4.1. Gradiente descendente 17
4.2. Método de Newton 18
4.3. Método de punto fijo 18
4.4. Método de penalización 19
4.5. Método de Lagrange 19
4.6. Métodos cuasi-Newton (BFGS) 20

5. Medida y análisis funcional **21**
5.1. Medida 21

5.2. Hahn–Banach 21
5.3. Espacios de Hilbert 22
5.4. Espacios de Lebesgue 22
5.5. Derivada débil 23
5.6. Espacios de Sobolev 23

6. Dimensión infinita 25

7. Desigualdades variacionales 27
7.1. El obstáculo 27
7.1.1. Formulación fuerte 27
7.1.2. Desigualdad variacional 27
7.1.3. Existencia y unicidad 28
7.1.4. Aproximación de Galerkin 28
7.1.5. Penalización 28
7.1.6. Newton semi-suave 28
7.1.7. Implementación en scikit-fem 29
7.1.8. Comentarios adicionales 30

8. Conclusión y perspectivas 33
8.1. Optimización matemática 33
8.2. Control y sistemas dinámicos 33
8.3. Aprendizaje Automático 34
8.4. Economía y finanzas 34
8.5. Teoría de juegos 34
8.6. Geometría y computación 34
8.7. Procesamiento de señales e imágenes 35
8.8. Teoría de la Información 35

Referencias bibliográficas 37

Capítulo 1
Introducción

El **análisis convexo** es una rama fundamental de las matemáticas que estudia funciones y conjuntos convexos, ofreciendo herramientas teóricas y prácticas para resolver problemas complejos en ciencia, ingeniería y economía. Este libro aborda desde los fundamentos matemáticos del análisis convexo hasta sus aplicaciones más avanzadas, incluyendo optimización convexa, aprendizaje automático, geometría algorítmica y teoría de juegos.

Se presentan las definiciones y propiedades esenciales de conjuntos y funciones convexas, junto con conceptos clave como el subgradiente, la cáscara convexa y la dualidad. Estos fundamentos son la base para entender algoritmos de optimización y técnicas numéricas que se desarrollan en los capítulos posteriores. Se incluyen ejemplos ilustrativos, fórmulas matemáticas precisas y fragmentos de código en Python para facilitar la implementación de los métodos descritos.

El libro está diseñado para estudiantes de grado y posgrado. A lo largo del texto, se enfatiza la relación entre el análisis convexo y otras áreas de las matemáticas, como el análisis funcional, la teoría de la medida y la geometría computacional, mostrando cómo estas disciplinas se complementan para abordar desafíos modernos.

El enfoque pedagógico del libro facilita la comprensión de conceptos abstractos mediante ejemplos paso a paso, ejercicios propuestos y aplicaciones en contextos reales. Al final de cada capítulo, se proporcionan referencias bibliográficas clave para profundizar en los temas tratados, así como enlaces a recursos adicionales en línea, como repositorios de código y conjuntos de datos.

Capítulo 2

Conjuntos convexos

Los conjuntos convexos son fundamentales en geometría computacional, optimización y aprendizaje automático. Su estudio permite resolver problemas complejos mediante estructuras bien definidas y propiedades robustas. La importancia de estos conjuntos radica en su capacidad para modelar fenómenos reales de manera eficiente, desde la planificación de rutas hasta la clasificación de datos. Además, su definición intuitiva —un conjunto donde el segmento entre dos puntos cualesquiera siempre está contenido— facilita su aplicación en algoritmos y teoremas. En la práctica, los conjuntos convexos aparecen en problemas de minimización, donde garantizan la existencia de soluciones óptimas. Su utilidad se extiende también a la robótica, el procesamiento de imágenes y la inteligencia artificial, donde sirven como herramientas clave para el análisis y la toma de decisiones.

La cáscara convexa, (*convex hull*), es una de las aplicaciones más relevantes de estos conjuntos. Se trata del conjunto convexo más pequeño que contiene a un grupo dado de puntos, actuando como un envoltorio geométrico que preserva la estructura esencial del conjunto original. Este concepto es crucial en geometría computacional, donde permite resolver problemas como la detección de colisiones o la reconstrucción de superficies en tres dimensiones. En el aprendizaje automático, la cáscara convexa se utiliza para definir regiones de decisión en algoritmos de clasificación, como las máquinas de vectores de soporte. Su cálculo eficiente es posible gracias a algoritmos como el de Graham o QuickHull, que optimizan el proceso reduciendo la complejidad computacional. Además, su visualización intuitiva ayuda a comprender mejor la distribución de datos en espacios multidimensionales. Este capítulo explora tanto la teoría como las aplicaciones prácticas de los conjuntos convexos y la cáscara convexa. A través de ejemplos concretos y algoritmos, se busca proporcionar al lector una buena comprensión de estos conceptos.

2.1. Definición y propiedades

Los conjuntos convexos son uno de los conceptos más versátiles y poderosos en matemáticas, con aplicaciones que abarcan desde la optimización hasta el aprendizaje automático. Un conjunto es convexo si, intuitivamente, no presenta huecos ni entrantes: cualquier segmento de recta que una dos puntos del conjunto permanece completamente dentro de él. Esta propiedad, aparentemente simple, tiene implicaciones profundas en teoría y práctica, permitiendo resolver problemas de minimización, clasificación y modelado con garantías de eficiencia y robustez.

2.1.1. Para empezar

Definición 1 (Conjunto convexo)**.** *Un conjunto $C \subseteq \mathbb{R}^n$ es **convexo** si, para todo $x, y \in C$ y todo $\lambda \in [0,1]$, se cumple que:*

$$\lambda x + (1-\lambda)y \in C.$$

En otras palabras, el conjunto contiene todos los puntos del segmento de recta que une x e y.

Ejemplo 1. ***Ejemplos clásicos de conjuntos convexos:***

- *Un **segmento de recta** en $\mathbb{R}^n$: $[a,b] = \{\lambda a + (1-\lambda)b \mid \lambda \in [0,1]\}$.*
- *Un **disco** (o bola cerrada) en $\mathbb{R}^2$: $\{(x,y) \mid x^2 + y^2 \leq r^2\}$.*
- *Un **hiperplano** en $\mathbb{R}^n$: $\{x \mid a^T x = b\}$, donde $a \in \mathbb{R}^n$ y $b \in \mathbb{R}$.*
- *El **espacio vectorial** $\mathbb{R}^n$ en sí mismo.*

Teorema 1 (Intersección de conjuntos convexos)**.** *Sea $\{C_i\}_{i \in I}$ una familia de conjuntos convexos en $\mathbb{R}^n$. Entonces, su intersección $\bigcap_{i \in I} C_i$ también es un conjunto convexo.*

Demostración. Sea $x, y \in \bigcap_{i \in I} C_i$ y $\lambda \in [0,1]$. Por definición de intersección, $x, y \in C_i$ para todo $i \in I$. Como cada C_i es convexo,

$$\lambda x + (1-\lambda)y \in C_i$$

para todo $i \in I$. Por lo tanto, $\lambda x + (1-\lambda)y \in \bigcap_{i \in I} C_i$, lo que prueba que la intersección es convexa. $\square$

Definición 2 (Combinación convexa)**.** *Una* ***combinación convexa*** *de puntos* $x_1, x_2, \ldots, x_k \in \mathbb{R}^n$ *es una expresión de la forma:*

$$\sum_{i=1}^{k} \lambda_i x_i, \quad \textit{donde} \quad \lambda_i \geq 0 \quad \textit{y} \quad \sum_{i=1}^{k} \lambda_i = 1.$$

2.1.2. Interior y clausura de un conjunto convexo

Ahora exploramos propiedades esenciales de los conjuntos convexos: primero, su comportamiento respecto al interior y la clausura.

Proposición 1. *Sea* $C \subseteq \mathbb{R}^n$ *un conjunto convexo. Entonces, su interior* $\mathring{C}$ *y su clausura* $\overline{C}$ *son también conjuntos convexos.*

Demostración. Veamos ambos casos.

Sean $C \subseteq \mathbb{R}^n$ un conjunto convexo y $\mathring{C}$ su interior. Queremos demostrar que $\mathring{C}$ es convexo, es decir, que para todo $x, y \in \mathring{C}$ y todo $\lambda \in [0, 1]$, el punto $z = \lambda x + (1 - \lambda)y$ pertenece a $\mathring{C}$.

1. **Premisas:** Sean $x, y \in \mathring{C}$. Por definición de punto interior, existen bolas abiertas $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, donde $r_x, r_y > 0$. Sea $\lambda \in [0, 1]$. Definimos $z = \lambda x + (1 - \lambda)y$.

2. **Construcción de la bola centrada en z:** Sea $r = \text{mín}(r_x, r_y) > 0$. Consideremos la bola abierta $B(z, r)$. Para todo $w \in B(z, r)$, escribimos $w = z + v$, donde $\|v\| < r$.

3. **Expresión de w como combinación convexa:** Observamos que:

   $$w = z + v = \lambda x + (1 - \lambda)y + v.$$

   Podemos descomponer v como:

   $$v = \lambda v + (1 - \lambda)v,$$

   donde $\|v\| < r \leq r_x$ y $\|v\| < r \leq r_y$. Esto es posible porque $r = \text{mín}(r_x, r_y)$.

4. **Verificación de que $w \in C$:** Como $B(x, r_x) \subseteq C$ y $B(y, r_y) \subseteq C$, entonces:

$$x + v \in B(x, r_x) \subseteq C \quad \text{y} \quad y + v \in B(y, r_y) \subseteq C.$$

Por convexidad de C, la combinación convexa:

$$\lambda(x + v) + (1 - \lambda)(y + v) = z + v = w$$

también está en C.

Dado que para todo $w \in B(z, r)$ se tiene $w \in C$, entonces $B(z, r) \subseteq C$. Esto implica que $z \in \mathring{C}$. Como z es un punto arbitrario en el segmento $[x, y]$, se concluye que $[x, y] \subseteq \mathring{C}$.

Por lo tanto, $\mathring{C}$ es un conjunto convexo.

Caso de la clausura $\overline{C}$: Sean $x, y \in \overline{C}$ y $\lambda \in [0, 1]$. Existen sucesiones $\{x_k\}$ e $\{y_k\}$ en C tales que $x_k \to x$ e $y_k \to y$. Definimos $z_k = \lambda x_k + (1 - \lambda) y_k$. Como C es convexo, $z_k \in C$ para todo k. Además, $z_k \to \lambda x + (1 - \lambda) y = z$, por lo que $z \in \overline{C}$. □

2.2. Cáscara convexa

Definición 3 (Cáscara convexa)**.** *La **cáscara convexa** de un conjunto $S \subseteq \mathbb{R}^n$, denotada conv(S), es el conjunto convexo más pequeño que contiene a S. Formalmente,*

$$conv(S) = \left\{ \sum_{i=1}^{k} \lambda_i x_i \mid x_i \in S, \lambda_i \geq 0, \sum_{i=1}^{k} \lambda_i = 1, k \in \mathbb{N} \right\}.$$

Teorema 2 (Caracterización de la cáscara convexa)**.** *Si $S \subseteq \mathbb{R}^n$, entonces*

$$conv(S) = \bigcap \{C \subseteq \mathbb{R}^n \mid C \text{ es convexo y } S \subseteq C\}.$$

En dimensión 2, la cáscara convexa de un conjunto finito de puntos es un polígono convexo cuyos vértices son un subconjunto de los puntos dados.

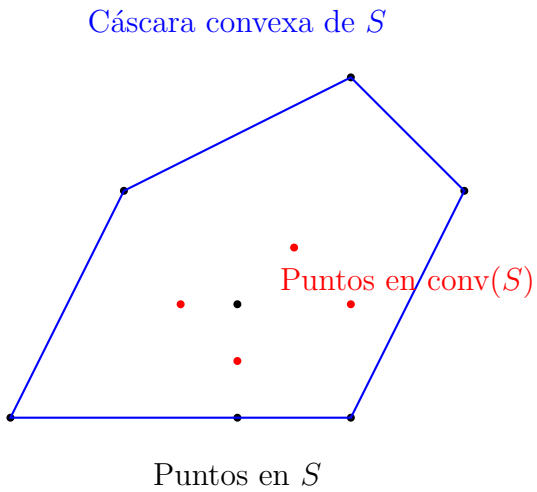

Figura 2.1: Visualización de la cáscara convexa de un conjunto de puntos en $\mathbb{R}^2$.

2.3. Aplicaciones

2.3.1. Envoltura convexa de un conjunto de puntos

La **envoltura convexa** (o cáscara convexa) de un conjunto finito de puntos en el plano es el polígono convexo más pequeño que contiene a todos los puntos. Este concepto es esencial en:

- **Geometría computacional**: Para problemas de colisión, localización de puntos y clustering.
- **Visión por computadora**: En reconstrucción 3D y reconocimiento de formas.
- **Robótica**: Para planificación de caminos y evitación de obstáculos.
- **Aprendizaje automático**: En clustering (por ejemplo, el algoritmo DBSCAN).

2.3.2. Separación de conjuntos convexos

Teorema 3 (Teorema de separación de hiperplanos)**.** *Si C y D son dos conjuntos convexos disjuntos en $\mathbb{R}^n$, entonces existe un hiperplano H que separa C y D, es decir, existe $a \in \mathbb{R}^n$ y $b \in \mathbb{R}$ tales que*

$$a^T x \leq b \quad \forall x \in C, \quad a^T y \geq b \quad \forall y \in D.$$

Este teorema es la base de algoritmos de separación en optimización convexa y aprendizaje automático (por ejemplo, máquinas de vectores de soporte).

2.3.3. Algoritmo de Graham (1972)

El algoritmo de Graham es uno de los métodos más eficientes para calcular la envoltura convexa de un conjunto de puntos en el plano, con una complejidad de $O(n \log n)$.

```python
import numpy as np
from math import atan2

def graham_scan(points):
    # Ordenar los puntos por coordenada x (y luego por y)
    points = sorted(points, key=lambda p: (p[0], p[1]))

    # Función para calcular el ángulo polar
    def polar_angle(p0, p1=None):
        if p1 is None:
            p1 = points[0]
        y_span = p0[1] - p1[1]
        x_span = p0[0] - p1[0]
        return atan2(y_span, x_span)

    # Ordenar por ángulo polar
    points = sorted(points[1:], key=polar_angle)

    # Inicializar la pila
    stack = [points[0], points[1]]

    for i in range(2, len(points)):
        while len(stack) > 1 and cross_product(stack[-2],
            stack[-1], points[i]) <= 0:
```

```
            stack.pop()
        stack.append(points[i])

    return stack

def cross_product(o, a, b):
    return (a[0] - o[0]) * (b[1] - o[1]) - (a[1] - o[1]) *
        (b[0] - o[0])
```

Listado 2.1: Implementación del algoritmo de Graham en Python

2.3.4. Algoritmo de Jarvis (1973)

El algoritmo de Jarvis, también conocido como el "marching ants", tiene una complejidad de $O(nh)$, donde h es el número de puntos en la envoltura convexa.

```
def jarvis_march(points):
    # Encontrar el punto más a la izquierda (punto inicial
        )
    start = min(points, key=lambda p: (p[0], p[1]))

    hull = []
    current = start
    while True:
        hull.append(current)
        next_point = points[0]
        for p in points:
            if p == current:
                continue
            # Calcular el ángulo cruzado
            cross = (p[0] - current[0]) * (next_point[1] -
                current[1]) - \
                    (p[1] - current[1]) * (next_point[0] -
                        current[0])
            if cross > 0 or (cross == 0 and distance(
                current, p) > distance(current, next_point)
                ):
                next_point = p

        if next_point == start:
            break
        current = next_point
```

```python

    return hull

def distance(p1, p2):
    return (p1[0] - p2[0])**2 + (p1[1] - p2[1])**2
```

Listado 2.2: Implementación del algoritmo de Jarvis en Python

2.3.5. Clustering con cáscara convexa

En aprendizaje automático, la cáscara convexa se utiliza en algoritmos de clustering como **DBSCAN** para identificar regiones densas y separar clusters. La idea es que los puntos dentro de una misma cáscara convexa pertenecen al mismo cluster.

2.3.6. Optimización convexa

En problemas de optimización, la cáscara convexa de un conjunto de restricciones define la región factible. La optimalidad de un punto x^* puede caracterizarse utilizando el teorema de separación de hiperplanos y las propiedades de la cáscara convexa.

Capítulo 3
Funciones convexas

Este capítulo aborda el análisis de funciones convexas en dimensión finita, un concepto central en optimización, economía matemática y aprendizaje automático. Se estudian dos contextos principales: el caso general (no necesariamente continuo) y el caso continuo (donde la convexidad implica continuidad local). Para cada contexto, se presentan definiciones, propiedades fundamentales, caracterizaciones de mínimos locales y globales, y herramientas como el subgradiente y la Hessiana.

3.1. Caso general

Definición 4 (Función convexa en dimensión finita)**.** *Una función* $f : \mathbb{R}^n \to (-\infty, +\infty]$ *es* ***convexa*** *si su dominio* $dom(f) = \{x \in \mathbb{R}^n \mid f(x) < +\infty\}$ *es convexo y para todo* $x, y \in dom(f)$ *y* $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Definición 5 (Subgradiente)**.** *Sea* $f : \mathbb{R}^n \to (-\infty, +\infty]$ *una función convexa. Un vector* $g \in \mathbb{R}^n$ *es un* ***subgradiente*** *de* f *en* x *si*

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in \mathbb{R}^n.$$

El conjunto de todos los subgradientes de f *en* x *se denota* $\partial f(x)$.

Teorema 4 (Caracterización de mínimos)**.** *Sea* $f : \mathbb{R}^n \to (-\infty, +\infty]$ *una función convexa. Un punto* $x^* \in dom(f)$ *es un mínimo global de* f *si y solo si*

$$0 \in \partial f(x^*).$$

Las funciones convexas en dimensión finita pueden ser discontinuas en la frontera de su dominio. Sin embargo, siempre son **localmente acotadas por arriba** en el interior de su dominio y, por lo tanto, son continuas en el interior de $\mathrm{dom}(f)$.

3.2. Casos continuo y diferenciable

Definición 6 (Función convexa diferenciable)**.** *Si $f : \mathbb{R}^n \to \mathbb{R}$ es convexa y diferenciable en x, entonces*

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad \forall y \in \mathbb{R}^n.$$

Además, $\nabla f(x)$ es el único subgradiente de f en x.

Definición 7 (Función convexa dos veces diferenciable)**.** *Si $f : \mathbb{R}^n \to \mathbb{R}$ es convexa y dos veces diferenciable, entonces su matriz Hessiana $\nabla^2 f(x)$ es* ***semidefinida positiva*** *para todo $x \in \mathbb{R}^n$. Recíprocamente, si $\nabla^2 f(x)$ es semidefinida positiva para todo x, entonces f es convexa.*

Teorema 5 (Caracterización de mínimos con gradiente)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global de f si y solo si*

$$\nabla f(x^*) = 0.$$

Teorema 6 (Caracterización de mínimos con Hessiana)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y dos veces diferenciable. Un punto $x^* \in \mathbb{R}^n$ es un mínimo global estricto de f si y solo si*

$$\nabla f(x^*) = 0 \quad y \quad \nabla^2 f(x^*) \text{ es definida positiva.}$$

Capítulo 4
Métodos de minimización

Los métodos de minimización son herramientas fundamentales en matemática aplicada, optimización, aprendizaje automático y ciencia de datos. Este capítulo aborda los principios y algoritmos más relevantes para resolver problemas de minimización de funciones, desde enfoques clásicos hasta técnicas avanzadas basadas en análisis convexo y métodos numéricos. Cada sección incluye las fórmulas clave de los métodos y, cuando es posible, su relación con ecuaciones diferenciales que modelan la dinámica de la minimización.

4.1. Gradiente descendente

El **gradiente descendente** es un método iterativo para minimizar una función $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable. El algoritmo se define como:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k),$$

donde $\alpha_k > 0$ es el tamaño de paso (o tasa de aprendizaje) y $\nabla f(x_k)$ es el gradiente de f en x_k.

Vínculo con ecuaciones diferenciales: El método de gradiente descendente puede interpretarse como una discretización de la ecuación diferencial ordinaria (EDO) asociada al flujo gradiente:

$$\frac{dx}{dt} = -\nabla f(x(t)).$$

La solución de esta EDO, bajo condiciones adecuadas, converge a un mínimo local de f.

4.2. Método de Newton

El **método de Newton** utiliza aproximaciones cuadráticas locales para acelerar la convergencia. La iteración se define como:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k),$$

donde $\nabla^2 f(x_k)$ es la matriz Hessiana de f en x_k. Este método converge cuadráticamente cerca de mínimos locales.

> **Vínculo con ecuaciones diferenciales:** El método de Newton puede verse como una aproximación de la dinámica de segundo orden:
>
> $$\frac{d^2x}{dt^2} + \gamma \frac{dx}{dt} = -\nabla f(x),$$
>
> donde γ es un parámetro de amortiguamiento. Esta ecuación modela el movimiento de una partícula en un paisaje de energía potencial f.

4.3. Método de punto fijo

El **método de punto fijo** busca resolver $x = g(x)$, donde g es una función iterativa. Para minimización, se define $g(x) = x - \alpha \nabla f(x)$, y la iteración es:

$$x_{k+1} = g(x_k).$$

La convergencia depende de que g sea una contracción.

> **Vínculo con ecuaciones diferenciales:** Si $g(x) = x - \alpha \nabla f(x)$, el método de punto fijo puede relacionarse con la EDO:
>
> $$\frac{dx}{dt} = -\nabla f(x).$$
>
> Este es el mismo flujo gradiente del método de gradiente descendente.

4.4. Método de penalización

El **método de penalización** transforma un problema con restricciones $\min f(x)$ sujeto a $c_i(x) = 0$ en un problema sin restricciones:

$$\min f(x) + \mu \sum_{i=1}^{m} c_i(x)^2,$$

donde $\mu > 0$ es el parámetro de penalización.

Vínculo con ecuaciones diferenciales: La dinámica asociada puede modelarse como:

$$\frac{dx}{dt} = -\nabla f(x) - 2\mu \sum_{i=1}^{m} c_i(x) \nabla c_i(x),$$

que combina el gradiente de la función objetivo con el gradiente de las restricciones.

4.5. Método de Lagrange

El **método de Lagrange** introduce multiplicadores λ para problemas con restricciones $c_i(x) = 0$. La función Lagrangiana es:

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^{m} \lambda_i c_i(x).$$

Las condiciones de optimalidad son:

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0, \quad c_i(x^*) = 0.$$

Vínculo con ecuaciones diferenciales: La dinámica de los multiplicadores de Lagrange puede describirse mediante:

$$\frac{dx}{dt} = -\nabla_x \mathcal{L}(x, \lambda), \quad \frac{d\lambda}{dt} = c(x).$$

Esta ecuación diferencial parcial (EDP) describe la evolución de x y λ hacia un punto de equilibrio.

4.6. Métodos cuasi-Newton (BFGS)

El método **BFGS** aproxima la inversa de la Hessiana H_k mediante actualizaciones iterativas:

$$H_{k+1} = \left(I - \frac{y_k s_k^T}{y_k^T s_k}\right) H_k \left(I - \frac{s_k y_k^T}{y_k^T s_k}\right) + \frac{s_k s_k^T}{y_k^T s_k},$$

donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$. La iteración es:

$$x_{k+1} = x_k - \alpha_k H_k \nabla f(x_k).$$

Vínculo con ecuaciones diferenciales: Los métodos cuasi-Newton pueden interpretarse como aproximaciones de la dinámica de segundo orden:

$$\frac{d^2x}{dt^2} + \gamma \frac{dx}{dt} = -H^{-1} \nabla f(x),$$

donde H es la aproximación de la Hessiana.

Capítulo 5
Medida y análisis funcional

Este capítulo está dedicado a profundizar en los fundamentos matemáticos esenciales para el análisis avanzado: la **teoría de medida**, la **integral de Lebesgue** y los **espacios funcionales**. Estos conceptos son pilares en el estudio de la probabilidad, la ecuación diferencial parcial, el análisis funcional y la teoría de control. A través de un enfoque riguroso, se presentan las herramientas teóricas necesarias para abordar problemas complejos en matemática, sentando las bases para el desarrollo de métodos modernos en optimización, física matemática y ciencia de datos.

5.1. Medida

La noción de **medida** generaliza el concepto clásico de longitud, área y volumen a conjuntos abstractos, permitiendo cuantificar el "tamaño"de subconjuntos en espacios arbitrarios. Esta teoría es fundamental para definir integrales generalizadas, como la integral de Lebesgue, y para analizar funciones medibles. Se exploran las propiedades de los espacios de medida, la construcción de medidas a partir de premedidas, y la relación entre la medida y la topología. Además, se estudian los teoremas clásicos de convergencia, como el de la convergencia monótona y el de la convergencia dominada, que son esenciales en el análisis funcional y en la teoría de la probabilidad.

5.2. Hahn–Banach

El **teorema de Hahn–Banach** es uno de los resultados más profundos y útiles del análisis funcional. Este teorema garantiza la existencia de extensiones lineales y continuas de funcionales definidos en subespacios

de un espacio vectorial normado, preservando su norma. Sus consecuencias son vastas: permite demostrar la existencia de funcionales lineales continuos no triviales, la separación de conjuntos convexos disjuntos, y la unicidad de normas equivalentes. El teorema de Hahn–Banach es clave en la dualidad entre espacios de Banach y en el estudio de la convergencia en espacios de funciones.

5.3. Espacios de Hilbert

Los **espacios de Hilbert** son generalizaciones del espacio euclidiano a dimensiones infinitas, donde la noción de ortogonalidad y proyección juega un papel central. Estos espacios poseen una estructura geométrica rica, basada en el producto interno, y permiten desarrollar teorías de series de Fourier generalizadas, bases ortonormales y operadores compactos. Se analizan propiedades como la completitud, la descomposición ortogonal y la representación de funcionales lineales continuos mediante el teorema de representación de Riesz. Los espacios de Hilbert son fundamentales en mecánica cuántica, teoría de aproximación y procesamiento de señales.

5.4. Espacios de Lebesgue

Los **espacios de Lebesgue** L^p son espacios funcionales que generalizan el concepto de integrabilidad en el sentido de Lebesgue. Estos espacios, parametrizados por $p \in [1, \infty]$, consisten en clases de equivalencia de funciones medibles cuyas potencias p-ésimas son integrables. Se estudian sus propiedades topológicas, la densidad de funciones continuas, y los teoremas de densidad y aproximación. Además, se exploran las desigualdades fundamentales, como las de Hölder y Minkowski, y su relación con la convergencia en medida y la continuidad de operadores lineales.

5.5. Derivada débil

La **derivada débil** extiende el concepto clásico de derivada a funciones que no son diferenciables en el sentido usual, pero que poseen una derivada generalizada en un sentido distribucional. Esta noción es esencial en la teoría de distribuciones y en el estudio de ecuaciones diferenciales parciales, donde muchas soluciones no son clásicas. Se definen los espacios de Sobolev y se analizan sus propiedades, incluyendo los teoremas de inmersión y traza, que permiten entender cómo las propiedades de regularidad de una función se transfieren a su frontera. La derivada débil es una herramienta poderosa para formular problemas variacionales y analizar su solubilidad.

5.6. Espacios de Sobolev

Los **espacios de Sobolev** son espacios funcionales que combinan propiedades de diferenciabilidad y integrabilidad, siendo fundamentales en el estudio de ecuaciones diferenciales parciales y en el análisis numérico. Estos espacios consisten en funciones cuyas derivadas débiles hasta cierto orden pertenecen a espacios de Lebesgue. Se analizan sus propiedades de completitud, densidad, y los teoremas de compactación, que son cruciales para demostrar la existencia de soluciones débiles. Los espacios de Sobolev también permiten formular problemas de minimización en cálculo de variaciones y en la teoría del potencial, proporcionando un marco riguroso para el análisis de regularidad y unicidad de soluciones.

Capítulo 6
Dimensión infinita

El estudio de la **dimensión infinita** en el ámbito del análisis convexo y la optimización permite abordar problemas complejos que surgen en mecánica de sólidos, teoría de control, economía y aprendizaje automático. En este contexto, las funciones y conjuntos convexos se definen en espacios de Hilbert o de Banach, donde las herramientas del análisis funcional son esenciales para garantizar la existencia de soluciones y su caracterización. La optimización en dimensión infinita extiende los principios de la programación convexa clásica, permitiendo modelar fenómenos con restricciones no lineales y operadores diferenciales. Este enfoque es fundamental para desarrollar métodos numéricos robustos y teoremas de dualidad que subyacen en aplicaciones modernas como el control óptimo y la teoría de juegos.

Capítulo 7
Desigualdades variacionales

Las desigualdades variacionales son útiles para modelar numerosos problemas de la física o la ingeniería [1, 2, 3]. Sin embargo, rara vez se abordan en los cursos de posgrado de análisis numérico. El objetivo de esta breve nota es presentar el análisis numérico del problema del obstáculo, cuando se discretiza mediante elementos finitos. El problema del obstáculo es, de hecho, el prototipo ideal de una desigualdad variacional y, quizás, el más sencillo de ellos.

Denotamos por $H^s(\cdot)$, $s \in \mathbb{R}$, a los espacios de Sobolev. Para un subconjunto abierto D de $\mathbb{R}^n$, la norma usual de $H^s(D)$ se denota por $\|\cdot\|_{s,D}$. El espacio $H_0^1(D)$ es el subespacio de funciones en $H^1(D)$ con traza nula en ∂D. La letra C representa una constante genérica, independiente de los parámetros de discretización.

7.1. El obstáculo

7.1.1. Formulación fuerte

Este enfoque clásico del problema del obstáculo presenta la formulación en términos de ecuaciones diferenciales parciales y condiciones de contorno.

7.1.2. Desigualdad variacional

Las desigualdades variacionales proporcionan un marco general para estudiar problemas con restricciones, como el del obstáculo. Este planteamiento permite modelar fenómenos físicos donde las soluciones deben satisfacer condiciones de desigualdad en lugar de igualdades. La teoría de desigualdades variacionales es fundamental para entender la estructura matemática del problema.

7.1.3. Existencia y unicidad

El estudio de la existencia y unicidad de soluciones es crucial para garantizar la validez de los modelos matemáticos. En el caso del obstáculo, se demuestra que, bajo condiciones adecuadas, existe una solución única que satisface las restricciones físicas del problema. Este análisis sienta las bases para el desarrollo de métodos numéricos confiables.

7.1.4. Aproximación de Galerkin

La aproximación de Galerkin es un método numérico ampliamente utilizado para resolver problemas descritos por desigualdades variacionales. Este enfoque permite discretizar el problema y transformarlo en un sistema algebraico resoluble. Su simplicidad y eficacia lo convierten en una herramienta estándar en el análisis numérico.

7.1.5. Penalización

El método de penalización reemplaza las restricciones del problema original por términos en la función objetivo. Este enfoque simplifica la implementación numérica y permite aplicar técnicas estándar de resolución. Sin embargo, la elección del parámetro de penalización es clave para la estabilidad y precisión del método.

7.1.6. Newton semi-suave

El método de Newton semi-suave es una técnica avanzada para resolver problemas de desigualdades variacionales, combinando ideas de métodos de Newton y subgradientes. Este enfoque aprovecha la estructura diferenciable a trozos de las funciones involucradas, mejorando la convergencia en problemas no lineales. Su aplicación es especialmente relevante en contextos donde la solución puede presentar comportamientos complejos.

7.1.7. Implementación en scikit-fem

scikit-fem es una biblioteca de Python que facilita la implementación de métodos de elementos finitos para resolver problemas variacionales. Su integración con NumPy y SciPy permite desarrollar soluciones eficientes y modulares. Esta herramienta es ideal para prototipar y validar algoritmos numéricos en entornos académicos y de investigación. Veamos el listado siguiente, escrito por Lucas Curci.

```
"""Diferenciación automática.
Utiliza diferenciación automática para derivar el sistema tangente
para el método de Newton.
"""

from skfem import *
from skfem.autodiff import NonlinearForm
from skfem.autodiff.helpers import grad, dot
import numpy as np
import jax.numpy as jnp

m = MeshTri().refined(5)

@NonlinearForm(hessian=True)
def J(u, _):
    eps = 1e-2
    return (1/2 * dot(grad(u), grad(u)) - u
            + (1 / eps) * ((u - jnp.minimum(u.value, 0.01))**2))

basis = Basis(m, ElementTriP1())

D = m.boundary_nodes()
x = np.zeros(basis.N)

for itr in range(100):
    x_prev = x.copy()
    x += solve(*condense(*J.assemble(basis, x=x), D=D))
    res = np.linalg.norm(x - x_prev)
    if res < 1e-8:
        break
    if __name__ == "__main__":
        print(res)
```

```python

if __name__ == "__main__":
    from skfem.visuals.matplotlib import plot3, show
    plot3(m, x)
    show()
```

Listado 7.1: Diferenciación automática con scikit-fem

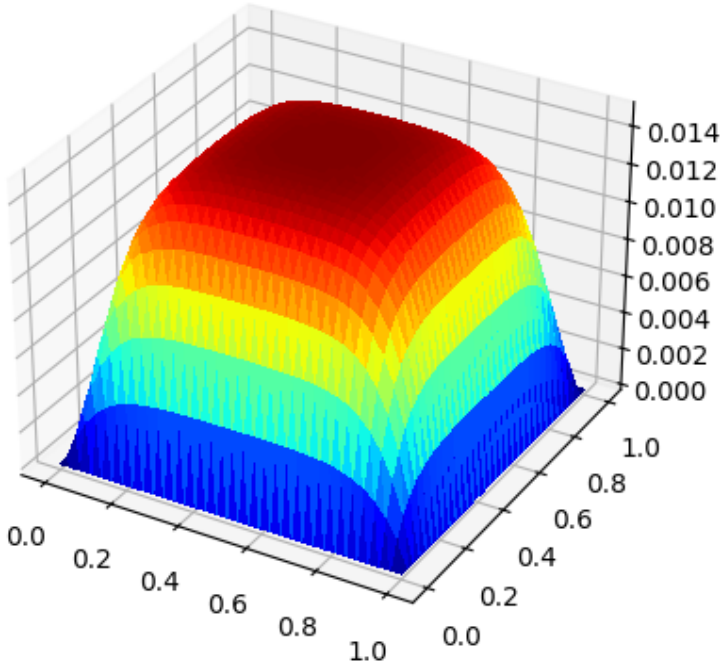

Figura 7.1: Solución del obstáculo penalizado con scikit-fem

7.1.8. Comentarios adicionales

- **Método de Nitsche o multiplicadores**: Estas técnicas alternativas permiten incorporar las restricciones del problema de manera explícita en la formulación débil, mejorando la estabilidad numérica en ciertos casos. El método de Nitsche, en particular, ofrece una forma elegante de manejar las condiciones de desigualdad.

- **Aplicaciones**: El problema del obstáculo tiene aplicaciones en mecánica de sólidos, fluidos, finanzas y otras áreas de la ciencia e ingeniería. Su versatilidad lo convierte en un modelo fundamental para estudiar fenómenos con restricciones geométricas o físicas.

Capítulo 8
Conclusión y perspectivas

Para concluir nuestra breve introducción, damos unas sugerencias que permitirán al lector ir más allá en el tema y/o descubrir otros campos relacionados.

8.1. Optimización matemática

El análisis convexo es fundamental en la teoría de la optimización, especialmente en problemas de programación matemática. Las funciones convexas y los conjuntos convexos permiten modelar y resolver problemas de minimización o maximización con restricciones, garantizando la existencia de soluciones globales óptimas. Por ejemplo, en **programación convexa**, se minimiza una función convexa sobre un conjunto convexo, lo que asegura convergencia a soluciones globales.

$$\begin{aligned} &\text{Minimizar } f(x) \\ &\quad \text{Sujeto a } g_i(x) \leq 0, \quad i = 1, \ldots, m \\ &\qquad\qquad\quad h_j(x) = 0, \quad j = 1, \ldots, p, \end{aligned}$$

donde f es convexa y g_i, h_j son funciones convexas.

8.2. Control y sistemas dinámicos

En teoría de control, el análisis convexo se aplica para estabilizar sistemas dinámicos y diseñar controladores robustos. Los **conos tangentes** y las **funciones de Lyapunov convexas** son herramientas clave para analizar la estabilidad asintótica y diseñar estrategias de control óptimo.

8.3. Aprendizaje Automático

En aprendizaje automático, el análisis convexo es esencial en algoritmos como **Support Vector Machines (SVM)** y **regresión logística**. Las SVM, por ejemplo, buscan el hiperplano que maximice el margen entre clases, lo que se formula como un problema de optimización convexa. La convexidad garantiza que el algoritmo encuentre la solución globalmente óptima.

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{sujeto a} \quad y_i(w \cdot x_i + b) \geq 1 \quad \forall i.$$

8.4. Economía y finanzas

En economía, el análisis convexo se utiliza para modelar preferencias de agentes económicos, funciones de producción y problemas de equilibrio general. Por ejemplo, las **funciones de utilidad cuasi-convexas** permiten analizar decisiones bajo incertidumbre, mientras que la convexidad de las funciones de costo es clave en la teoría de la firma.

8.5. Teoría de juegos

En teoría de juegos, los conceptos de convexidad son centrales para analizar equilibrios de Nash en juegos no cooperativos. Las estrategias mixtas y las funciones de pago convexas permiten demostrar la existencia de equilibrios y estudiar su estabilidad.

8.6. Geometría y computación

En geometría computacional, el análisis convexo se aplica en algoritmos de **envueltas convexas** (como el algoritmo de Graham) y en problemas de localización de puntos. La convexidad permite diseñar algoritmos eficientes para encontrar soluciones aproximadas o exactas en conjuntos de datos de alta dimensionalidad.

8.7. Procesamiento de señales e imágenes

En procesamiento de imágenes, técnicas como la **reconstrucción convexa** y la **regularización total variación (TV)** se basan en la convexidad para minimizar artefactos y mejorar la calidad de la imagen. Estas técnicas son fundamentales en tomografía, resonancia magnética y reconstrucción 3D.

8.8. Teoría de la Información

En teoría de la información, las funciones convexas como la **entropía relativa** (o divergencia de Kullback-Leibler) son herramientas esenciales para analizar la capacidad de canales de comunicación y diseñar códigos eficientes.

Referencias bibliográficas

[1] G. Duvaut and J.-L. Lions, *Inequalities in mechanics and physics*, Springer-Verlag, 1976.

[2] R. Glowinski, *Lectures on numerical methods for nonlinear variational problems*, Springer-Verlag, 1980.

[3] D. Kinderlehrer and G. Stampacchia, *An introduction to variational inequalities and their applications*, vol. 88, Academic Press, 1980.