

Prácticos de Análisis Convexo

Franz Chouly

Federico Correa

16 de agosto de 2026

Índice general

1. Descenso de gradiente	2
1.1. Para empezar	2

Capítulo 1

Descenso de gradiente

1.1. Para empezar

Ejercicio 1 Recordamos la formulación de la regresión Ridge. Dada una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$, un vector de etiquetas $\mathbf{y} \in \mathbb{R}^n$, y un vector de pesos $\mathbf{w} \in \mathbb{R}^d$, la funcional a minimizar es:

$$\mathcal{J}(\mathbf{w}) := \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_V^2 + \varepsilon \|\mathbf{w}\|_V^2$$

donde $\varepsilon > 0$ es el parámetro de regularización, y

$$\|\mathbf{y}\|_V^2 := y_1^2 + \dots + y_n^2, \quad \|\mathbf{w}\|_V^2 := w_1^2 + \dots + w_d^2.$$

Aquí tenemos $V = V_d = \mathbb{R}^d$, con la norma Euclidiana.

1. Mostrar que el problema

$$\min_V \mathcal{J}$$

se puede reformular como la resolución de un sistema lineal.

2. Cual es el tamaño de este sistema ?
3. Mostrar que el sistema es invertible para todo $\varepsilon > 0$.
4. Dar explícitamente la única solución.
5. Que pasa si $\varepsilon = 0$?
6. Escribir la iteración de descenso de gradiente para Ridge.

Nota cultural: la *regresión Ridge* (o *Ridge Regression*) fue introducida por Arthur E. Hoerl en 1962 como una solución para abordar problemas de *multicolinealidad* e *inestabilidad de los coeficientes* en modelos de regresión lineal clásica. En un modelo lineal estándar $\mathbf{y} \sim \mathbf{X}\mathbf{w}$, si las variables explicativas $\mathbf{X}$ están fuertemente correlacionadas entre sí, la matriz $\mathbf{X}^T \mathbf{X}$ se vuelve **mal condicionada** (cercana a la singularidad), lo que hace que la estimación de los coeficientes $\mathbf{w}$ sea imprecisa y muy sensible a pequeñas variaciones en los datos.

Referencia: Hoerl, A. E., & Kennard, R. W. (1970). *Ridge Regression: Biased Estimation for Nonorthogonal Problems*.

Ejercicio 2 Existe un valor del parámetro α que permite una convergencia mas rápida para el descenso de gradiente a paso constante ? Cual es la tasa de convergencia en este caso ?

Ejercicio 3 Sean $a > 0$ y $b > 0$ y definimos

$$V = \mathbb{R}^2, \quad \mathcal{J}(x, y) := ax^2 + by^2.$$

Estudiar la convergencia del descenso de gradiente a paso constante en este caso en función del parámetro α .

1. Que valores de α entregan convergencia ?
2. Cual es el valor de α que permite una convergencia la mas rápida ?

Ejercicio 4 Sea $\mathcal{J}(x) = x^4 - 4x^3 + 4x^2 + x$, definida en $\mathbb{R}$.

1. Encuentra los puntos críticos de $\mathcal{J}$ (mínimos, máximos y puntos de inflexión).
2. Aplica el algoritmo de descenso de gradiente con paso constante $\alpha = 0,1$ y punto inicial $x_0 = 0,5$. ¿A qué punto converge el algoritmo?
Implementa manualmente las primeras 5 iteraciones.
3. ¿Qué pasa si eliges $x_0 = 2,5$? ¿Y si $\alpha = 1$?
4. Discute cómo el punto inicial y el tamaño del paso afectan la convergencia en funciones no convexas.

Ejercicio 5 Veamos el descenso de gradiente en regresión lineal (Ridge con $\varepsilon = 0 \dots$). Dada una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$, un vector de etiquetas $\mathbf{y} \in \mathbb{R}^n$, y un vector de pesos $\mathbf{w} \in \mathbb{R}^d$, la funcional a minimizar es:

$$\mathcal{J}(\mathbf{w}) := \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_V^2.$$

1. Escribe la expresión explícita del gradiente de la función de costo.
2. Demuestra que el paso óptimo constante para este problema está dado por:

$$\alpha^* = \frac{2}{\lambda_{\max}(\mathbf{X}^T \mathbf{X})},$$

donde $\lambda_{\max}(\mathbf{X}^T \mathbf{X})$ es el valor propio máximo de $\mathbf{X}^T \mathbf{X}$.

3. ¿Qué ocurre si $\alpha > \alpha^*$? ¿El algoritmo aún converge?